

Análisis de Datos - TFM

Adrián Martínez Requena

2024-2025

Contents

Importación de los datos	3
Importación del .rds generado en la simulación de datos	3
Exploración del dataframe	3
Visualización y Análisis de los datos	5
Conversión de las variables a factores	5
Comprobación de normalidad y presencia de outliers	6
Test de Shapiro-Wilk	6
Presencia de Outliers con el método IQR	6
Gráficos de barras de variables categóricas	7
Gráficos de variables numéricas	11
Análisis de relación de covariables vs. resultado	17
Boxplots para variables numéricas según el resultado	17
Histogramas/densidades por nivel de resultado:	20
Evaluación de multicolinealidad entre las variables numéricas	22
Matriz de correlación	22
Análisis de relación de las covariables vs. exposición	24
Gráficos de barras y boxplots	24
Prueba Chi-cuadrado (Covariables categóricas vs Exposición)	29
Prueba Mann-Whitney U (Covariables numéricas vs Exposición)	30
Análisis de Regresión Logística	31
Modelo Inicial (Incluye todas las covariables)	31
Gráfico de residuos	34
Distancias de Cook	35
Curva ROC	36
Modelo refinado con Stepwise	36

Residuos del modelo	39
Distancias de Cook	40
Curva ROC	40
Validación cruzada con 10 pliegues	41
Propensity Scores	41
Generación de datos y calculo de Propensity Scores	41
Tabla de Balance Inicial	41
LovePlot del Balance Inicial	42
Matching (Emparejamiento)	43
Matching Inicial con Reemplazamiento	43
Tabla de balance del Matching Inicial con Reemplazamiento	45
Matching aplicando todas las variables cuyo SMD > 0.1	45
Tabla de Balance del Matching con variables cuyo SMD > 0.1	47
Matching con sexo, edad, estado funcional y comorbilidades (Version Final)	48
Tabla de balance del Matching Final	49
Comparativa del balance de los 4 modelos	49
Love Plot del Matching Completo	50
Love Plot del Matching Final	50
Análisis de Regresión Logística con los datos balanceados por PS Matching	51
Asociación de los nuevos datos con Exposición	52
Modelo balanceado con Matching (PS)	54
Gráfico de residuos	56
Distancias de Cook	57
Curva ROC	57
Modelo balanceado refinado con Stepwise	58
Residuos del modelo	61
Distancias de Cook	62
Curva ROC	62
Validación cruzada con 10 pliegues	63
Comparación Modelos con y sin Propensity Scores	63
Ponderación (Weighting)	64
Cálculo de Pesos Inversos de Probabilidad de Tratamiento (IPW)	64
Evaluación del Balance de Covariables Posterior a la Ponderación	64

Modelo ponderado usando los pesos IPW	65
Residuos del modelo	67
Distancias de Cook	67
Curva ROC	68
Validación cruzada con 10 pliegues	68
Apéndice	69
Código	69

```
# Maquetación del documento
library(knitr)
# Para maquetación de tablas
library(kableExtra)
# Para resúmenes detallados de datos
library(skimr)
# Manipulación y transformación de datos
library(dplyr)
# Creación de gráficos
library(ggplot2)
# Funciones estadísticas (incluye glm)
library(stats)
# Herramientas para la creación y evaluación de modelos
library(caret)
# Visualización y análisis de curvas ROC
library(pROC)
# Para mapas de calor
library(reshape2)
# Genera gráficos y tablas de equilibrio
library(cobalt)
# Para tablas de datos que nos permitan calcular SMD
library(tableone)
# Para Propensity Scores y Matching
library(MatchIt)
# Para manejo de estadísticas en modelos lineales
library(survey)
```

Importación de los datos

Importación del .rds generado en la simulación de datos

```
datos <- readRDS("C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
```

Exploración del dataframe

```
## Clase del dataframe

## [1] "data.table" "data.frame"
```

```
## Primeras 3 filas
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
1	1	0	3	47.79371	1	0	1	3	51	0.8027880	0	0.9493709	0.7209886	0
2	0	0	2	51.77346	0	0	1	1	52	0.7655234	1	1.8173460	0.8602474	1
3	0	1	2	20.19209	4	0	2	1	27	0.2985447	1	-0.7707915	0.3163079	1

```
## Últimas 3 filas
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
998	1	0	1	83.915613	0	0	2	1	43	0.9086672	1	5.291561	0.9949913	1
999	1	1	3	55.555770	4	1	2	2	27	0.6494615	0	2.265577	0.9059857	1
1000	1	0	1	6.638573	0	1	2	3	62	0.6385687	1	-3.076143	0.0441021	0

```
## Estructura del dataframe
```

```
## Classes 'data.table' and 'data.frame': 1000 obs. of 15 variables:
## $ id : int 1 2 3 4 5 6 7 8 9 10 ...
## $ sexo : int 1 0 0 1 0 1 0 0 1 0 ...
## $ tabaquismo : int 0 0 1 0 1 0 0 0 0 0 ...
## $ nivel_socioeconomico: int 3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional : num 47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int 1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: int 0 0 0 1 0 0 1 0 0 0 ...
## $ apoyo_familiar : int 1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion : int 3 1 1 1 3 3 1 2 1 2 ...
## $ edad : num 51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion : num 0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion : int 0 1 1 1 1 1 0 0 1 1 ...
## $ log_odds_Y : num 0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y : num 0.721 0.86 0.316 0.993 0.339 ...
## $ resultado : int 0 1 1 1 0 1 0 0 1 0 ...
## - attr(*, ".internal.selfref")=<externalptr>
## - attr(*, "sorted")= chr "id"
```

```
## Resumen general del dataframe
```

Table 1: Data summary

Name	datos
Number of rows	1000
Number of columns	15
Key	id
Column type frequency:	
numeric	15
Group variables	None

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
id	0	1	500.50	288.82	1.00	250.75	500.50	750.25	1000.00	
sexo	0	1	0.50	0.50	0.00	0.00	1.00	1.00	1.00	
tabaquismo	0	1	0.29	0.45	0.00	0.00	0.00	1.00	1.00	
nivel_socioeconomico	0	1	1.91	0.70	1.00	1.00	2.00	2.00	3.00	
estado_funcional	0	1	49.99	29.23	0.05	25.49	49.97	76.16	99.98	
comorbilidades	0	1	2.02	1.44	0.00	1.00	2.00	3.00	8.00	
cuidado_dependientes	0	1	0.21	0.41	0.00	0.00	0.00	0.00	1.00	
apoyo_familiar	0	1	1.90	0.72	1.00	1.00	2.00	2.00	3.00	
nivel_educacion	0	1	2.25	0.73	1.00	2.00	2.00	3.00	3.00	
edad	0	1	50.25	14.42	18.00	41.00	50.00	60.00	104.00	
prob_exposicion	0	1	0.72	0.18	0.20	0.59	0.76	0.87	0.98	
exposicion	0	1	0.71	0.46	0.00	0.00	1.00	1.00	1.00	
log_odds_Y	0	1	1.41	3.06	-	-1.14	1.48	4.07	7.62	
					4.73					
prob_Y	0	1	0.63	0.37	0.01	0.24	0.81	0.98	1.00	
resultado	0	1	0.62	0.48	0.00	0.00	1.00	1.00	1.00	

Visualización y Análisis de los datos

Conversión de las variables a factores

```
# Duplicamos el dataframe
datostransformados = data.frame(datos)

# Convertimos las variables a factores usando el paquete
# dplyr
datostransformados <- datostransformados %>%
  mutate(sexo = factor(sexo, levels = c(0, 1), labels = c("Femenino",
    "Masculino")), tabaquismo = factor(tabaquismo, levels = c(0,
    1), labels = c("No", "Sí")), nivel_socioeconomico = factor(nivel_socioeconomico,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
  cuidado_dependientes = factor(cuidado_dependientes, levels = c(0,
    1), labels = c("No", "Sí")), apoyo_familiar = factor(apoyo_familiar,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio",
    "Alto")), nivel_educacion = factor(nivel_educacion,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio",
    "Alto")), exposicion = factor(exposicion, levels = c(0,
    1), labels = c("No", "Sí")), resultado = factor(resultado,
    levels = c(0, 1), labels = c("No mejora", "Mejora")))

# Vemos que se hayan convertido
str(datostransformados)

## 'data.frame':   1000 obs. of  15 variables:
## $ id           : int  1 2 3 4 5 6 7 8 9 10 ...
## $ sexo         : Factor w/ 2 levels "Femenino","Masculino": 2 1 1 2 1 2 1 1 2 1 ...
## $ tabaquismo   : Factor w/ 2 levels "No","Sí": 1 1 2 1 2 1 1 1 1 1 ...
## $ nivel_socioeconomico: Factor w/ 3 levels "Bajo","Medio",...: 3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional : num  47.8 51.8 20.2 89.9 34 ...
```

```
## $ comorbilidades      : int  1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: Factor w/ 2 levels "No","Sí": 1 1 1 2 1 1 2 1 1 1 ...
## $ apoyo_familiar      : Factor w/ 3 levels "Bajo","Medio",...: 1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion     : Factor w/ 3 levels "Bajo","Medio",...: 3 1 1 1 3 3 1 2 1 2 ...
## $ edad                : num  51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion     : num  0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion          : Factor w/ 2 levels "No","Sí": 1 2 2 2 2 2 1 1 2 2 ...
## $ log_odds_Y          : num  0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y              : num  0.721 0.86 0.316 0.993 0.339 ...
## $ resultado           : Factor w/ 2 levels "No mejora","Mejora": 1 2 2 2 1 2 1 1 2 1 ...
```

Se ha duplicado el dataframe original para tenerlo intacto y se han transformado diversas variables en la copia llamada ahora 'datostransformados'. **Se han convertido las siguientes variables en factores:** sexo, tabaquismo, nivel_socioeconomico, cuidado_dependientes, apoyo_familiar, nivel_educacion, exposicion y resultado

Comprobación de normalidad y presencia de outliers

Test de Shapiro-Wilk

```
## Resultados test de Shapiro-Wilk
```

```
##          estado_funcional comorbilidades      edad prob_exposicion
## statistic.W      9.504027e-01  9.225290e-01 9.927595e-01  9.405449e-01
## p_value          7.555354e-18  2.966285e-22 8.460238e-05  1.413741e-19
##          log_odds_Y      prob_Y
## statistic.W 9.634191e-01 8.129798e-01
## p_value      3.849268e-15 1.668164e-32
```

Los datos no siguen la distribución normal, esto es normal para el estilo de variables que son, especialmente log_odds_Y y prob_Y

Presencia de Outliers con el método IQR

```
## Outliers de estado_funcional
```

```
## $limites
## inferior.25% superior.75%
##      -50.52325      152.17254
##
## $outliers
## integer(0)
```

```
## Outliers de edad
```

```
## $limites
## inferior.25% superior.75%
##          12.5          88.5
##
## $outliers
## integer(0)
```

```
## Outliers de prob_exposicion
```

```
## $limites
## inferior.25% superior.75%
##      0.1821079      1.2814788
##
## $outliers
## integer(0)
```

```
## Outliers de log_odds_Y
```

```
## $limites
## inferior.25% superior.75%
##      -8.94656      11.87617
##
## $outliers
## integer(0)
```

```
## Outliers de comorbilidades
```

```
## $limites
## inferior.25% superior.75%
##          -2          6
##
## $outliers
## integer(0)
```

```
## Outliers de prob_Y
```



```
## $limites
## inferior.25% superior.75%
##    -0.8680115     2.0938792
##
## $outliers
## integer(0)
```



No se han detectado outliers



Gráficos de barras de variables categóricas

```
# Creamos una lista que incluya todas las variables
# categóricas
categoricas <- c("sexo", "tabaquismo", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")



# Hacemos un bucle for para sacar todos los gráficos
for (variable in categoricas) {
  plot_categoricas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_bar(fill = "slateblue3", color = "black") + labs(title = paste("Distribución de",
    variable), x = variable, y = "Frecuencia") + theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_categoricas)
}
```









Gráficos de variables numéricas







Histograma y densidad de edad







Histograma y densidad de prob_exposicion

















Análisis de relación de covariables vs. resultado



Boxplots para variables numéricas según el resultado











Histogramas/densidades por nivel de resultado:








Evaluación de multicolinealidad entre las variables numéricas

Matriz de correlación



	estado_funcional	comorbilidades	edad	prob_exposicion	log_odds_Y	prob_Y
estado_funcional	1.0000000	0.0392922	-0.0182999	0.8590554	0.9808638	0.9387940
comorbilidades	0.0392922	1.0000000	-0.0234687	-0.0774455	-0.0090231	0.0046628
edad	-0.0182999	-0.0234687	1.0000000	0.3890940	0.1904099	0.1562687
prob_exposicion	0.8590554	-0.0774455	0.3890940	1.0000000	0.7786849	0.7788618
log_odds_Y	0.9808638	-0.0090231	0.1904099	0.7786849	1.0000000	0.9520679
prob_Y	0.9387940	0.0046628	0.1562687	0.7788618	0.9520679	1.0000000




Hay fuertes correlaciones entre estado_funcional, prob_exposicion, log_odds_Y y prob_Y, mientras que comorbilidades y edad muestran una menor correlación con las otras variables. Esto es lógico porque ya hemos ido viendo que en la simulación ha salido que el estado_funcional ha tenido mucho impacto a la hora de la exposición y resultado.

Análisis de relación de las covariables vs. exposición


Gráficos de barras y boxplots







Distribución de nivel_socioeconomico por Exposición







Distribución de cuidado_dependientes por Exposición











Prueba Chi-cuadrado (Covariables categóricas vs Exposición)

```
## [1] "Prueba Chi-cuadrado para sexo"
##
```

```
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 7.1874, df = 1, p-value = 0.007342
##
## [1] "Prueba Chi-cuadrado para tabaquismo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 0.33132, df = 1, p-value = 0.5649
##
## [1] "Prueba Chi-cuadrado para nivel_socioeconomico"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 4.0228, df = 2, p-value = 0.1338
##
## [1] "Prueba Chi-cuadrado para cuidado_dependientes"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 0.0057768, df = 1, p-value = 0.9394
##
## [1] "Prueba Chi-cuadrado para apoyo_familiar"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 3.5424, df = 2, p-value = 0.1701
##
## [1] "Prueba Chi-cuadrado para nivel_educacion"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 5.8662, df = 2, p-value = 0.05323
```

Solo sexo muestra una asociación significativa con exposicion (se ha inducido correctamente el sesgo), mientras que las otras variables categóricas no muestran asociaciones significativas con exposicion.

Prueba Mann-Whitney U (Covariables numéricas vs Exposición)

```
## [1] "Prueba de Mann-Whitney para estado_funcional"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 58202, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
```

```
## [1] "Prueba de Mann-Whitney para comorbilidades"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 112015, p-value = 0.0377
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para edad"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 79154, p-value = 4.196e-09
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_exposicion"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 50406, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para log_odds_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 55232, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 55232, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
```

Todas las variables numéricas muestran diferencias significativas entre los grupos de exposicion.

Los que han sido expuestos tienen un mejor estado funcional, menor comorbilidades, mayor edad. Además, como es lógico también tiene mayor probabilidad de mejora.

Análisis de Regresión Logística

Modelo Inicial (Incluye todas las covariables)

```
modelo_inicial <- glm(exposicion ~ sexo + edad + estado_funcional +
  nivel_socioeconomico + cuidado_dependientes + apoyo_familiar +
```

```
nivel_educacion + tabaquismo + comorbilidades, data = datostransformados,
family = binomial)
modelo_inicial
```

```
##
## Call: glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## cuidado_dependientes + apoyo_familiar + nivel_educacion +
## tabaquismo + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             (Intercept)             sexoMasculino
##             -2.74440             0.44582
##             edad             estado_funcional
##             0.03833             0.03149
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##             0.24390             -0.13573
## cuidado_dependientesSí             apoyo_familiarMedio
##             0.01807             0.24127
##             apoyo_familiarAlto             nivel_educacionMedio
##             -0.10265             0.06243
##             nivel_educacionAlto             tabaquismoSí
##             0.45557             0.10185
##             comorbilidades
##             -0.14684
##
## Degrees of Freedom: 999 Total (i.e. Null); 987 Residual
## Null Deviance: 1210
## Residual Deviance: 1010 AIC: 1036
```

Según el modelo sexo, edad, estado_funcional, nivel_socioeconomico, apoyo_familiar y nivel_educacion tienen un efecto significativo sobre las probabilidades de exposicion.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## cuidado_dependientes + apoyo_familiar + nivel_educacion +
## tabaquismo + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)      -2.744400   0.438751  -6.255 3.97e-10 ***
## sexoMasculino       0.445821   0.156067   2.857 0.00428 **
## edad               0.038334   0.005818   6.589 4.43e-11 ***
## estado_funcional    0.031493   0.002969  10.607 < 2e-16 ***
## nivel_socioeconomicoMedio 0.243901   0.178713   1.365 0.17233
## nivel_socioeconomicoAlto -0.135730   0.216615  -0.627 0.53092
## cuidado_dependientesSí  0.018075   0.191209   0.095 0.92469
## apoyo_familiarMedio   0.241270   0.179993   1.340 0.18010
## apoyo_familiarAlto   -0.102652   0.213028  -0.482 0.62990
## nivel_educacionMedio   0.062433   0.216231   0.289 0.77278
```



```

## nivel_educacionAlto          0.455566    0.218123    2.089    0.03675 *
## tabaquismoSí                 0.101849    0.172154    0.592    0.55411
## comorbilidades               -0.146844    0.053540   -2.743    0.00609 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1209.6 on 999 degrees of freedom
## Residual deviance: 1010.3 on 987 degrees of freedom
## AIC: 1036.3
##
## Number of Fisher Scoring iterations: 4

## Odd Ratios

## (Intercept)                  sexoMasculino                  edad
## 0.06428685                   1.56177184                   1.03907806
## estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
## 1.03199432                   1.27621779                   0.87307844
## cuidado_dependientesSí apoyo_familiarMedio apoyo_familiarAlto
## 1.01823925                   1.27286416                   0.90244084
## nivel_educacionMedio nivel_educacionAlto tabaquismoSí
## 1.06442330                   1.57706625                   1.10721665
## comorbilidades
## 0.86342870

## Intervalos de Confianza para los Odds Ratios

## 2.5 % 97.5 %
## (Intercept) 0.0268764 0.1503480
## sexoMasculino 1.1514787 2.1240770
## edad 1.0274751 1.0512004
## estado_funcional 1.0261198 1.0381444
## nivel_socioeconomicoMedio 0.8982410 1.8110552
## nivel_socioeconomicoAlto 0.5711574 1.3364880
## cuidado_dependientesSí 0.7023681 1.4878275
## apoyo_familiarMedio 0.8938312 1.8113087
## apoyo_familiarAlto 0.5946386 1.3719286
## nivel_educacionMedio 0.6945459 1.6230558
## nivel_educacionAlto 1.0262031 2.4160927
## tabaquismoSí 0.7918679 1.5561521
## comorbilidades 0.7771861 0.9589514

```

Ser hombre aumenta las probabilidades de exposición (OR = 1.5618).


Cuanta más edad más probabilidades de exposición (OR = 1.0391).

Mejor estado funcional está asociado con mayores probabilidades de exposición (OR = 1.0320).

Tener un nivel alto de educación se asocia con un aumento en las probabilidades de exposición (OR = 1.5771).


Tener más comorbilidades disminuye las probabilidades de exposición (OR = 0.8634).

Gráfico de residuos




El modelo tiene un ajuste correcto

Distancias de Cook



El modelo tiene un ajuste bueno, con diversas muestras más influyentes que otras

Curva ROC



```
## Area under the curve: 0.7688
```

La curva ROC nos indica que el modelo está bien ajustado

Modelo refinado con Stepwise

```
# Aplicamos una regresión stepwise al modelo  
modelo_refinado <- step(modelo_inicial, direction = "both")
```

```
## Start: AIC=1036.26  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
##   cuidado_dependientes + apoyo_familiar + nivel_educacion +  
##   tabaquismo + comorbilidades  
##  
##           Df Deviance    AIC  
## - cuidado_dependientes 1  1010.3 1034.3  
## - tabaquismo            1  1010.6 1034.6  
## - apoyo_familiar        2  1013.8 1035.8  
## <none>                  1010.3 1036.3  
## - nivel_socioeconomico  2  1014.3 1036.3  
## - nivel_educacion       2  1017.2 1039.2  
## - comorbilidades        1  1017.8 1041.8  
## - sexo                  1  1018.5 1042.5  
## - edad                  1  1057.9 1081.9
```

```

## - estado_funcional      1   1144.9 1168.9
##
## Step: AIC=1034.27
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + nivel_educacion + tabaquismo + comorbilidades
##
##              Df Deviance    AIC
## - tabaquismo      1   1010.6 1032.6
## - apoyo_familiar   2   1013.9 1033.8
## <none>              1010.3 1034.3
## - nivel_socioeconomico 2   1014.3 1034.3
## + cuidado_dependientes 1   1010.3 1036.3
## - nivel_educacion    2   1017.2 1037.2
## - comorbilidades     1   1017.8 1039.8
## - sexo               1   1018.6 1040.6
## - edad               1   1058.0 1080.0
## - estado_funcional   1   1144.9 1166.9
##
## Step: AIC=1032.62
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + nivel_educacion + comorbilidades
##
##              Df Deviance    AIC
## - apoyo_familiar     2   1014.2 1032.2
## <none>                1010.6 1032.6
## - nivel_socioeconomico 2   1014.7 1032.7
## + tabaquismo          1   1010.3 1034.3
## + cuidado_dependientes 1   1010.6 1034.6
## - nivel_educacion     2   1017.7 1035.7
## - comorbilidades      1   1018.1 1038.1
## - sexo                1   1018.8 1038.8
## - edad                1   1058.2 1078.2
## - estado_funcional    1   1145.4 1165.4
##
## Step: AIC=1032.19
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + comorbilidades
##
##              Df Deviance    AIC
## <none>              1014.2 1032.2
## - nivel_socioeconomico 2   1018.3 1032.3
## + apoyo_familiar      2   1010.6 1032.6
## + tabaquismo          1   1013.9 1033.8
## + cuidado_dependientes 1   1014.2 1034.2
## - nivel_educacion     2   1021.5 1035.5
## - comorbilidades      1   1022.0 1038.0
## - sexo                1   1022.0 1038.0
## - edad                1   1061.3 1077.3
## - estado_funcional    1   1148.9 1164.9

# Vemos el resultado
modelo_refinado

##

```

```
## Call: glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## nivel_educacion + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             (Intercept)                sexoMasculino
##             -2.58821                0.43230
##             edad                estado_funcional
##             0.03801                0.03139
## nivel_socioeconomicoMedio  nivel_socioeconomicoAlto
##             0.24419                -0.13578
## nivel_educacionMedio      nivel_educacionAlto
##             0.05168                0.45933
##             comorbilidades
##             -0.14903
##
## Degrees of Freedom: 999 Total (i.e. Null); 991 Residual
## Null Deviance: 1210
## Residual Deviance: 1014 AIC: 1032
```

El stepwise ha eliminado las variables: cuidado_dependientes, tabaquismo y apoyo_familiar

Las variables significativas en el modelo refinado son: sexoMasculino, edad, estado_funcional, nivel_educacionAlto y comorbilidades

Summary del modelo

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## nivel_educacion + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -2.588213   0.405924  -6.376 1.82e-10 ***
## sexoMasculino     0.432304   0.155074   2.788 0.00531 **
## edad              0.038005   0.005794   6.559 5.40e-11 ***
## estado_funcional  0.031394   0.002956  10.619 < 2e-16 ***
## nivel_socioeconomicoMedio 0.244186   0.178258   1.370 0.17074
## nivel_socioeconomicoAlto -0.135783   0.215978  -0.629 0.52955
## nivel_educacionMedio    0.051681   0.215356   0.240 0.81035
## nivel_educacionAlto     0.459331   0.218213   2.105 0.03529 *
## comorbilidades    -0.149032   0.053361  -2.793 0.00522 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1209.6 on 999 degrees of freedom
## Residual deviance: 1014.2 on 991 degrees of freedom
## AIC: 1032.2
##
## Number of Fisher Scoring iterations: 4
##
## Odd Ratios
```


```
##              (Intercept)              sexoMasculino              edad
##              0.07515419              1.54080331              1.03873672
##      estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##              1.03189148              1.27658112              0.87303223
##      nivel_educacionMedio      nivel_educacionAlto      comorbilidades
##              1.05303983              1.58301474              0.86154127
```

Intervalos de Confianza para los Odds Ratios


```
##              2.5 %      97.5 %
## (Intercept)      0.03353802 0.1649546
## sexoMasculino      1.13814619 2.0912896
## edad              1.02718375 1.0508030
## estado_funcional      1.02604159 1.0380135
## nivel_socioeconomicoMedio 0.89927969 1.8099026
## nivel_socioeconomicoAlto 0.57183511 1.3347228
## nivel_educacionMedio      0.68825440 1.6028269
## nivel_educacionAlto      1.02989492 2.4256297
## comorbilidades      0.77575224 0.9565043
```

Resultados parecidos a los del modelo sin refinar.


Residuos del modelo



Distancias de Cook



Curva ROC




```
## Area under the curve: 0.7678
```

Igual que el modelo inicial

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 1000 samples
##    6 predictor
##    2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 900, 900, 900, 900, 901, 900, ...
## Resampling results:
##
##    ROC          Sens          Spec
## 0.7607771 0.3790805 0.9080282
```

El valor de ROC es bueno, la sensibilidad es bastante baja y la especificidad es muy buena.

Propensity Scores

Generación de datos y calculo de Propensity Scores

```
# Establecemos semilla
set.seed(19780301)

# Copiamos los datos
datos_ps <- data.frame(dataostransformados)

# Extraemos los Propensity Scores
datos_ps$propensity_score <- predict(modelo_inicial, type = "response")

# Calculamos la desviación estándar de los PS en caso de
# que sean necesarias
sd_ps <- sd(datos_ps$distance, na.rm = TRUE)

# Sacamos el summary
summary(datos_ps$propensity_score)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.1394  0.5684  0.7563  0.7070  0.8790  0.9855
```

Tabla de Balance Inicial

```
# Definimos las covariables a evaluar
covariables <- c("sexo", "tabaquismo", "nivel_socioeconomico",
  "estado_funcional", "comorbilidades", "cuidado_dependientes",
  "apoyo_familiar", "nivel_educacion", "edad")

# Creamos la tabla de balance inicial para ver las
# diferencias de medias estandarizadas (SMD)
tabla_balance <- CreateTableOne(vars = covariables, strata = "exposicion",
  data = datos_ps, test = FALSE)
```

```
## [1] "Tabla de Balance con los resultados de SMD"
```

```
##
##               Stratified by exposicion
##               No           Sí           SMD
##  n                293          707
##  sexo = Masculino (%)    127 (43.3)    374 (52.9)    0.192
##  tabaquismo = Sí (%)     81 (27.6)    210 (29.7)    0.046
##  nivel_socioeconomico (%)                                0.140
##    Bajo                97 (33.1)    201 (28.4)
##    Medio               131 (44.7)    365 (51.6)
##    Alto                65 (22.2)    141 (19.9)
##  estado_funcional (mean (SD)) 34.35 (27.06) 56.46 (27.61) 0.809
##  comorbilidades (mean (SD))   2.16 (1.44)  1.97 (1.44) 0.137
##  cuidado_dependientes = Sí (%)  60 (20.5)  148 (20.9) 0.011
##  apoyo_familiar (%)                                0.130
##    Bajo                94 (32.1)    219 (31.0)
##    Medio               128 (43.7)    349 (49.4)
##    Alto                71 (24.2)    139 (19.7)
##  nivel_educacion (%)                                0.170
##    Bajo                55 (18.8)    120 (17.0)
##    Medio               130 (44.4)    268 (37.9)
##    Alto               108 (36.9)    319 (45.1)
##  edad (mean (SD))          46.02 (13.35) 52.01 (14.49) 0.430
```

Las variables que presentan un peor balance son: Estado funcional (SMD = 0.809), Edad (SMD = 0.430) y Sexo (Masculino %, SMD = 0.192) Por otro lado, las variables que superan el umbral de SMD < 0.1 también incluyen: Nivel socioeconómico, Comorbilidades, Apoyo familiar y Nivel de educación:

LovePlot del Balance Inicial


```
# Establecemos la semilla
set.seed(19780301)

# Sacamos la formula del balance
formula_balance <- exposicion ~ sexo + tabaquismo + nivel_socioeconomico +
  estado_funcional + comorbilidades + cuidado_dependientes +
  apoyo_familiar + nivel_educacion + edad

# Utilizamos la formula para sacar los datos que nos
# permitan hacer el Love Plot
```

```
bal_tab <- bal.tab(formula_balance, data = datos_ps)

# Creamos el Love Plot para el balance inicial
love.plot(bal_tab, threshold = 0.1, var.order = "unadjusted",
  stat = "mean.diffs", abs = TRUE, colors = c("red", "blue"),
  stars = "raw")
```



El LovePlot muestra diferencias con la tabla de balance generada anteriormente. Esto puede ser debido a cómo calculan las diferencias cada uno. Así que en un principio vamos a tener en cuenta comorbilidades también para el balanceo.

Matching (Emparejamiento)

Se han realizado tres tipos de emparejamiento diferentes que se presentan a continuación y se ha seleccionado el que se ha considerado más apropiado para el estudio.

Matching Inicial con Reemplazamiento

Se realizó un análisis de balance de datos utilizando el método de emparejamiento por el vecino más cercano (nearest) con reemplazo.

```
# Establecemos la semilla
set.seed(19780301)

# Aplicamos el matching utilizando solo las 3 variables más
# desbalanceadas
```

```
matching_replace <- matchit(formula = exposicion ~ sexo + edad +
  estado_funcional, data = datos_ps, method = "nearest", distance = "logit",
  replace = TRUE)
```

```
# Mostramos los resultados
summary(matching_replace)
```

```
##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional,
## data = datos_ps, method = "nearest", distance = "logit",
## replace = TRUE)
##
## Summary of Balance for All Data:
##
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7578	0.5845	1.0757	0.6899
sexoFemenino	0.4710	0.5666	-0.1914	.
sexoMasculino	0.5290	0.4334	0.1914	.
edad	52.0057	46.0171	0.4133	1.1777
estado_funcional	56.4633	34.3543	0.8008	1.0409

```
##
## eCDF Mean eCDF Max
## distance 0.2529 0.3775
## sexoFemenino 0.0955 0.0955
## sexoMasculino 0.0955 0.0955
## edad 0.0773 0.1716
## estado_funcional 0.2190 0.3275
##
## Summary of Balance for Matched Data:
##
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7578	0.7575	0.0019	0.9929
sexoFemenino	0.4710	0.4993	-0.0567	.
sexoMasculino	0.5290	0.5007	0.0567	.
edad	52.0057	50.2560	0.1207	1.2425
estado_funcional	56.4633	58.6774	-0.0802	0.8912

```
##
## eCDF Mean eCDF Max Std. Pair Dist.
## distance 0.0033 0.0325 0.0095
## sexoFemenino 0.0283 0.0283 0.9748
## sexoMasculino 0.0283 0.0283 0.9748
## edad 0.0258 0.0877 0.9555
## estado_funcional 0.0330 0.0948 0.6187
##
## Sample Sizes:
##
```

	Control	Treated
All	293.	707
Matched (ESS)	83.66	707
Matched	184.	707
Unmatched	109.	0
Discarded	0.	0

Se ha reducido el desbalance en Sexo (Masculino %), ahora hay una proporción similar de hombres en ambos grupos (52.9% en expuestos vs 50.07% en controles), con un SMD de 0.0567.

Lo mismo con media de edad en los grupos emparejados se equilibró mejor (52.01 años en expuestos vs 50.26 años en controles), SMD de 0.1207.

La diferencia en el estado funcional también se redujo (media de 56.46 en expuestos vs 58.68 en controles), SMD de -0.0802.

El proceso de emparejamiento mejoró significativamente el balance entre los grupos expuestos y no expuestos en términos de sexo, edad y estado funcional. Las diferencias estandarizadas medias (SMD) disminuyeron, indicando una mayor equivalencia entre los grupos.

Tabla de balance del Matching Inicial con Reemplazamiento

##	Stratified by exposicion		SMD
	No	Sí	
## n	184	707	
## sexo = Masculino (%)	89 (48.4)	374 (52.9)	0.091
## tabaquismo = Sí (%)	54 (29.3)	210 (29.7)	0.008
## nivel_socioeconomico (%)			0.176
## Bajo	60 (32.6)	201 (28.4)	
## Medio	79 (42.9)	365 (51.6)	
## Alto	45 (24.5)	141 (19.9)	
## estado_funcional (mean (SD))	41.79 (27.90)	56.46 (27.61)	0.529
## comorbilidades (mean (SD))	2.28 (1.44)	1.97 (1.44)	0.216
## cuidado_dependientes = Sí (%)	34 (18.5)	148 (20.9)	0.062
## apoyo_familiar (%)			0.163
## Bajo	59 (32.1)	219 (31.0)	
## Medio	78 (42.4)	349 (49.4)	
## Alto	47 (25.5)	139 (19.7)	
## nivel_educacion (%)			0.193
## Bajo	39 (21.2)	120 (17.0)	
## Medio	79 (42.9)	268 (37.9)	
## Alto	66 (35.9)	319 (45.1)	
## edad (mean (SD))	48.67 (12.76)	52.01 (14.49)	0.244

El balance de: Sexo, Estado Funcional y Edad ha disminuido, pero los demás han aumentado.

Matching aplicando todas las variables cuyo SMD > 0.1

```
# Semilla
set.seed(19780301)

# Modelo de Matching
matching_replace_all <- matchit(formula = exposicion ~ sexo +
  edad + estado_funcional + comorbilidades + nivel_socioeconomico +
  apoyo_familiar + nivel_educacion, data = datos_ps, method = "nearest",
  distance = "logit", replace = TRUE)

# Resultados
summary(matching_replace_all)

##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional +
##   comorbilidades + nivel_socioeconomico + apoyo_familiar +
```

```

## nivel_educacion, data = datos_ps, method = "nearest", distance = "logit",
## replace = TRUE)
##
## Summary of Balance for All Data:
##
## Means Treated Means Control Std. Mean Diff.
## distance 0.7630 0.5718 1.1246
## sexoFemenino 0.4710 0.5666 -0.1914
## sexoMasculino 0.5290 0.4334 0.1914
## edad 52.0057 46.0171 0.4133
## estado_funcional 56.4633 34.3543 0.8008
## comorbilidades 1.9661 2.1638 -0.1373
## nivel_socioeconomicoBajo 0.2843 0.3311 -0.1037
## nivel_socioeconomicoMedio 0.5163 0.4471 0.1384
## nivel_socioeconomicoAlto 0.1994 0.2218 -0.0561
## apoyo_familiarBajo 0.3098 0.3208 -0.0239
## apoyo_familiarMedio 0.4936 0.4369 0.1136
## apoyo_familiarAlto 0.1966 0.2423 -0.1150
## nivel_educacionBajo 0.1697 0.1877 -0.0479
## nivel_educacionMedio 0.3791 0.4437 -0.1332
## nivel_educacionAlto 0.4512 0.3686 0.1660
##
## Var. Ratio eCDF Mean eCDF Max
## distance 0.7293 0.2690 0.4079
## sexoFemenino . 0.0955 0.0955
## sexoMasculino . 0.0955 0.0955
## edad 1.1777 0.0773 0.1716
## estado_funcional 1.0409 0.2190 0.3275
## comorbilidades 0.9965 0.0248 0.0725
## nivel_socioeconomicoBajo . 0.0468 0.0468
## nivel_socioeconomicoMedio . 0.0692 0.0692
## nivel_socioeconomicoAlto . 0.0224 0.0224
## apoyo_familiarBajo . 0.0111 0.0111
## apoyo_familiarMedio . 0.0568 0.0568
## apoyo_familiarAlto . 0.0457 0.0457
## nivel_educacionBajo . 0.0180 0.0180
## nivel_educacionMedio . 0.0646 0.0646
## nivel_educacionAlto . 0.0826 0.0826
##
## Summary of Balance for Matched Data:
##
## Means Treated Means Control Std. Mean Diff.
## distance 0.7630 0.7626 0.0024
## sexoFemenino 0.4710 0.4823 -0.0227
## sexoMasculino 0.5290 0.5177 0.0227
## edad 52.0057 53.2419 -0.0853
## estado_funcional 56.4633 58.3491 -0.0683
## comorbilidades 1.9661 2.3479 -0.2651
## nivel_socioeconomicoBajo 0.2843 0.2659 0.0408
## nivel_socioeconomicoMedio 0.5163 0.5050 0.0226
## nivel_socioeconomicoAlto 0.1994 0.2291 -0.0743
## apoyo_familiarBajo 0.3098 0.3055 0.0092
## apoyo_familiarMedio 0.4936 0.4371 0.1132
## apoyo_familiarAlto 0.1966 0.2574 -0.1530
## nivel_educacionBajo 0.1697 0.1980 -0.0754
## nivel_educacionMedio 0.3791 0.4229 -0.0904
## nivel_educacionAlto 0.4512 0.3791 0.1450

```

```
##                               Var. Ratio eCDF Mean eCDF Max Std. Pair Dist.
## distance                     0.9895    0.0043    0.0410          0.0111
## sexoFemenino                 .         0.0113    0.0113          0.9578
## sexoMasculino                .         0.0113    0.0113          0.9578
## edad                         1.0064    0.0230    0.0962          0.9913
## estado_funcional             0.9358    0.0273    0.0778          0.6701
## comorbilidades               1.2701    0.0484    0.1881          1.0525
## nivel_socioeconomicoBajo     .         0.0184    0.0184          0.8560
## nivel_socioeconomicoMedio    .         0.0113    0.0113          0.9850
## nivel_socioeconomicoAlto     .         0.0297    0.0297          0.7965
## apoyo_familiarBajo           .         0.0042    0.0042          0.9085
## apoyo_familiarMedio          .         0.0566    0.0566          1.0072
## apoyo_familiarAlto           .         0.0608    0.0608          0.9075
## nivel_educacionBajo          .         0.0283    0.0283          0.7686
## nivel_educacionMedio         .         0.0438    0.0438          0.9475
## nivel_educacionAlto         .         0.0721    0.0721          0.8954
##
## Sample Sizes:
##               Control Treated
## All           293.       707
## Matched (ESS)  61.22     707
## Matched       178.       707
## Unmatched     115.        0
## Discarded      0.         0
```

El balanceo general ha mejorado, pero sigue habiendo valores altos de SMD que nos indican que la selección de todas las variables puede haber sido muy agresivo.

Tabla de Balance del Matching con variables cuyo SMD > 0.1

```
##                               Stratified by exposicion
##                               No      Sí      SMD
## n                             178      707
## sexo = Masculino (%)           80 (44.9) 374 (52.9) 0.160
## tabaquismo = Sí (%)            52 (29.2) 210 (29.7) 0.011
## nivel_socioeconomico (%)
##   Bajo                         56 (31.5) 201 (28.4)
##   Medio                        83 (46.6) 365 (51.6)
##   Alto                         39 (21.9) 141 (19.9)
## estado_funcional (mean (SD))  42.64 (27.83) 56.46 (27.61) 0.499
## comorbilidades (mean (SD))    2.16 (1.41)  1.97 (1.44) 0.138
## cuidado_dependientes = Sí (%)  35 (19.7)  148 (20.9) 0.032
## apoyo_familiar (%)
##   Bajo                         54 (30.3) 219 (31.0)
##   Medio                        85 (47.8) 349 (49.4)
##   Alto                         39 (21.9) 139 (19.7)
## nivel_educacion (%)
##   Bajo                         29 (16.3) 120 (17.0)
##   Medio                        77 (43.3) 268 (37.9)
##   Alto                         72 (40.4) 319 (45.1)
## edad (mean (SD))              47.76 (13.55) 52.01 (14.49) 0.303
```

Los valores de SMD son más bajos, indicando que ha habido un mejor balanceo que con el método que incluía solo 3 variables.

Matching con sexo, edad, estado funcional y comorbilidades (Version Final)

```
set.seed(19780301)
matching_replace_comorb <- matchit(formula = exposicion ~ sexo +
  edad + estado_funcional + comorbilidades, data = datos_ps,
  method = "nearest", distance = "logit", replace = TRUE)
summary(matching_replace_comorb)
```

```
##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional +
##   comorbilidades, data = datos_ps, method = "nearest", distance = "logit",
##   replace = TRUE)
##
## Summary of Balance for All Data:
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7595	0.5803	1.0989	0.6815
sexoFemenino	0.4710	0.5666	-0.1914	.
sexoMasculino	0.5290	0.4334	0.1914	.
edad	52.0057	46.0171	0.4133	1.1777
estado_funcional	56.4633	34.3543	0.8008	1.0409
comorbilidades	1.9661	2.1638	-0.1373	0.9965

```
##
## eCDF Mean eCDF Max
```

	eCDF Mean	eCDF Max
distance	0.2575	0.3945
sexoFemenino	0.0955	0.0955
sexoMasculino	0.0955	0.0955
edad	0.0773	0.1716
estado_funcional	0.2190	0.3275
comorbilidades	0.0248	0.0725

```
##
## Summary of Balance for Matched Data:
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7595	0.7589	0.0039	0.9951
sexoFemenino	0.4710	0.4583	0.0255	.
sexoMasculino	0.5290	0.5417	-0.0255	.
edad	52.0057	52.2376	-0.0160	1.1654
estado_funcional	56.4633	56.2264	0.0086	0.9536
comorbilidades	1.9661	2.1358	-0.1178	1.3409

```
##
## eCDF Mean eCDF Max Std. Pair Dist.
```

	eCDF Mean	eCDF Max	Std. Pair Dist.
distance	0.0040	0.0566	0.0115
sexoFemenino	0.0127	0.0127	0.9549
sexoMasculino	0.0127	0.0127	0.9549
edad	0.0172	0.0523	0.9630
estado_funcional	0.0143	0.0537	0.6668
comorbilidades	0.0361	0.1216	1.0722

```
##
## Sample Sizes:
```

	Control	Treated
All	293.	707
Matched (ESS)	71.77	707
Matched	188.	707
Unmatched	105.	0
Discarded	0.	0

Aunque todavía presenta leves desbalances, es el método que mejor ha balanceado globalmente todas las variable ya que las variables claves, que presentan más correlación con la exposición, han disminuído más.

Tabla de balance del Matching Final


		Stratified by exposicion		
		No	Sí	SMD
##	n	188	707	
##	sexo = Masculino (%)	92 (48.9)	374 (52.9)	0.079
##	tabaquismo = Sí (%)	57 (30.3)	210 (29.7)	0.013
##	nivel_socioeconomico (%)			0.207
##	Bajo	62 (33.0)	201 (28.4)	
##	Medio	78 (41.5)	365 (51.6)	
##	Alto	48 (25.5)	141 (19.9)	
##	estado_funcional (mean (SD))	41.85 (27.65)	56.46 (27.61)	0.529
##	comorbilidades (mean (SD))	2.19 (1.41)	1.97 (1.44)	0.158
##	cuidado_dependientes = Sí (%)	42 (22.3)	148 (20.9)	0.034
##	apoyo_familiar (%)			0.182
##	Bajo	63 (33.5)	219 (31.0)	
##	Medio	77 (41.0)	349 (49.4)	
##	Alto	48 (25.5)	139 (19.7)	
##	nivel_educacion (%)			0.137
##	Bajo	39 (20.7)	120 (17.0)	
##	Medio	76 (40.4)	268 (37.9)	
##	Alto	73 (38.8)	319 (45.1)	
##	edad (mean (SD))	48.74 (12.81)	52.01 (14.49)	0.239

Comparativa del balance de los 4 modelos

		Variable	Modelo_Original	Reemplazo	Reemplazo_Completo
##	1	n	293/707	184/707	178/707
##	2	sexo = Masculino (%)	0.192	0.091	0.160
##	3	tabaquismo = Sí (%)	0.046	0.008	0.011
##	4	nivel_socioeconomico	0.140	0.176	0.100
##	5	estado_funcional (mean (SD))	0.809	0.529	0.499
##	6	comorbilidades (mean (SD))	0.137	0.216	0.138
##	7	cuidado_dependientes = Sí (%)	0.011	0.062	0.032
##	8	apoyo_familiar	0.130	0.163	0.056
##	9	nivel_educacion	0.170	0.193	0.112
##	10	edad (mean (SD))	0.430	0.244	0.303
##	Reemplazo_Comorbilidades				
##	1	188/707			
##	2	0.079			
##	3	0.013			
##	4	0.207			
##	5	0.529			
##	6	0.158			
##	7	0.034			
##	8	0.182			
##	9	0.137			
##	10	0.239			


Love Plot del Matching Completo

```
love.plot(bal.tab(matching_replace_all), threshold = 0.1, var.order = "unadjusted",
  stat = "mean.diffs", abs = TRUE, colors = c("red", "blue"),
  stars = "raw")
```



Love Plot del Matching Final

```
# Visualizamos el Love Plot después del emparejamiento con
# comorbilidades
love.plot(bal.tab(matching_replace_comorb), threshold = 0.1,
  var.order = "unadjusted", stat = "mean.diffs", abs = TRUE,
  colors = c("red", "blue"), stars = "raw")
```



El emparejamiento con reemplazo añadiendo la variable comorbilidades parece ser la mejor opción en términos de balance y tamaño de muestra igualada.

Ya que este es el mejor balanceo para las variables más críticas, nos quedaremos con este.

Análisis de Regresión Logística con los datos balanceados por PS Matching

Vamos a trabajar con los datos que hemos obtenido del modelo que incluía el balanceo de edad, estado_funcional, sexo y comorbilidades.

```
## Classes 'matchdata' and 'data.frame': 895 obs. of 18 variables:
## $ id : int 1 2 3 4 5 6 7 9 10 11 ...
## $ sexo : Factor w/ 2 levels "Femenino","Masculino": 2 1 1 2 1 2 1 2 1 1 ...
## $ tabaquismo : Factor w/ 2 levels "No","Sí": 1 1 2 1 2 1 1 1 1 1 ...
## $ nivel_socioeconomico: Factor w/ 3 levels "Bajo","Medio",...: 3 2 2 2 2 2 2 2 1 2 ...
## $ estado_funcional : num 47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int 1 0 4 3 1 3 0 3 1 2 ...
## $ cuidado_dependientes: Factor w/ 2 levels "No","Sí": 1 1 1 2 1 1 2 1 1 1 ...
## $ apoyo_familiar : Factor w/ 3 levels "Bajo","Medio",...: 1 1 2 3 2 2 1 1 2 1 ...
## $ nivel_educacion : Factor w/ 3 levels "Bajo","Medio",...: 3 1 1 1 3 3 1 1 2 2 ...
## $ edad : num 51 52 27 60 70 63 62 57 56 52 ...
## $ prob_exposicion : num 0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion : Factor w/ 2 levels "No","Sí": 1 2 2 2 2 2 1 2 2 2 ...
## $ log_odds_Y : num 0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y : num 0.721 0.86 0.316 0.993 0.339 ...
## $ resultado : Factor w/ 2 levels "No mejora","Mejora": 1 2 2 2 1 2 1 2 1 2 ...
## $ propensity_score : num 0.792 0.755 0.255 0.928 0.871 ...
```

```
## $ distance          : num  0.803 0.784 0.235 0.941 0.781 ...
## $ weights           : num  1.86 1 1 1 1 ...
## - attr(*, "distance")= chr "distance"
## - attr(*, "weights")= chr "weights"
```

Asociación de los nuevos datos con Exposición

```
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
  tabla_balanceado <- table(datos_replace_comorb[[variable]],
    datos_replace_comorb$exposicion)
  prueba_chi_balanceado <- chisq.test(tabla_balanceado)
  print(paste("Prueba Chi-cuadrado para", variable))
  print(prueba_chi_balanceado)
}

## [1] "Prueba Chi-cuadrado para sexo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.78268, df = 1, p-value = 0.3763
##
## [1] "Prueba Chi-cuadrado para tabaquismo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.0055423, df = 1, p-value = 0.9407
##
## [1] "Prueba Chi-cuadrado para nivel_socioeconomico"
##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 6.3253, df = 2, p-value = 0.04231
##
## [1] "Prueba Chi-cuadrado para cuidado_dependientes"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.10172, df = 1, p-value = 0.7498
##
## [1] "Prueba Chi-cuadrado para apoyo_familiar"
##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 4.9578, df = 2, p-value = 0.08383
##
## [1] "Prueba Chi-cuadrado para nivel_educacion"
```

```

##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 2.776, df = 2, p-value = 0.2496

# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon
# Rank-Sum Test)
for (variable in numericas) {
  wilcox_test_balanceado <- wilcox.test(datos_replace_comorb[[variable]] ~
    datos_replace_comorb$exposicion)

  print(paste("Prueba de Mann-Whitney para", variable))
  print(wilcox_test_balanceado)
}

## [1] "Prueba de Mann-Whitney para estado_funcional"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 46739, p-value = 3.868e-10
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para comorbilidades"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 72774, p-value = 0.04009
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para edad"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 57612, p-value = 0.004976
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_exposicion"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43222, p-value = 1.636e-13
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para log_odds_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43007, p-value = 9.776e-14

```

```
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43007, p-value = 9.776e-14
## alternative hypothesis: true location shift is not equal to 0
```

La principal diferencia es que al balancear los datos, el sexo ya no es significativo (se ha reducido el sesgo de género) y ha aparecido una asociación con el nivel socioeconómico.

Modelo balanceado con Matching (PS)

```
modelo_balanceado_matching <- glm(exposicion ~ sexo + edad +
  estado_funcional + nivel_socioeconomico + nivel_educacion +
  cuidado_dependientes + apoyo_familiar + tabaquismo + comorbilidades,
  data = datos_replace_comorb, family = binomial)
modelo_balanceado_matching
```

```
##
## Call:  glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##        nivel_educacion + cuidado_dependientes + apoyo_familiar +
##        tabaquismo + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              (Intercept)              sexoMasculino
##                -1.04259                  0.22680
##                edad                estado_funcional
##                 0.02268                  0.02083
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##                 0.31308                  -0.19085
##      nivel_educacionMedio      nivel_educacionAlto
##                 0.13461                  0.40119
##   cuidado_dependientesSí   apoyo_familiarMedio
##                 -0.06475                  0.24727
##      apoyo_familiarAlto      tabaquismoSí
##                 -0.19941                  -0.01229
##      comorbilidades
##                 -0.13595
##
## Degrees of Freedom: 894 Total (i.e. Null);  882 Residual
## Null Deviance:      920.1
## Residual Deviance: 847.1    AIC: 873.1
```

Ser hombre, tener mayor edad o un nivel educativo alto aumenta las probabilidades de exposición, mientras que más comorbilidades las reducen. El AIC (873.1) sugiere que es un buen modelo.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)      -1.042590   0.486688  -2.142 0.032176 *
## sexoMasculino       0.226799   0.172535   1.315 0.188676
## edad               0.022684   0.006360   3.567 0.000361 ***
## estado_funcional    0.020825   0.003209   6.490 8.58e-11 ***
## nivel_socioeconomicoMedio 0.313077   0.199511   1.569 0.116595
## nivel_socioeconomicoAlto -0.190853   0.232068  -0.822 0.410849
## nivel_educacionMedio  0.134606   0.236773   0.569 0.569694
## nivel_educacionAlto   0.401187   0.235521   1.703 0.088493 .
## cuidado_dependientesSí -0.064755   0.208129  -0.311 0.755704
## apoyo_familiarMedio   0.247270   0.199837   1.237 0.215954
## apoyo_familiarAlto   -0.199413   0.230454  -0.865 0.386871
## tabaquismoSí         -0.012293   0.188451  -0.065 0.947988
## comorbilidades       -0.135954   0.058923  -2.307 0.021037 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 920.11  on 894  degrees of freedom
## Residual deviance: 847.09  on 882  degrees of freedom
## AIC: 873.09
##
## Number of Fisher Scoring iterations: 4

## Odd Ratios

##              (Intercept)              sexoMasculino              edad
##              0.3525403              1.2545773              1.0229428
##      estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##              1.0210435              1.3676271              0.8262541
##      nivel_educacionMedio      nivel_educacionAlto      cuidado_dependientesSí
##              1.1440857              1.4935959              0.9372975
##      apoyo_familiarMedio      apoyo_familiarAlto      tabaquismoSí
##              1.2805242              0.8192112              0.9877820
##      comorbilidades
##              0.8728831


## Intervalos de Confianza para los Odds Ratios

##              2.5 %      97.5 %
## (Intercept)      0.1349187 0.9113903
## sexoMasculino      0.8949286 1.7613805
## edad              1.0104141 1.0359478
## estado_funcional    1.0147272 1.0275877
## nivel_socioeconomicoMedio 0.9232237 2.0205138
```


```
## nivel_socioeconomicoAlto 0.5246048 1.3049727
## nivel_educacionMedio     0.7150578 1.8124305
## nivel_educacionAlto      0.9362904 2.3617349
## cuidado_dependientesSí   0.6273995 1.4210233
## apoyo_familiarMedio      0.8639118 1.8931801
## apoyo_familiarAlto       0.5218309 1.2898908
## tabaquismoSí             0.6853100 1.4361495
## comorbilidades           0.7778147 0.9802792
```

El modelo nos indica que la exposición está más relacionada con factores como la edad, el estado funcional y comorbilidades, mientras que las demás variables tienen menor impacto al no ser significativas.


Gráfico de residuos



Distancias de Cook



Curva ROC



```
## Area under the curve: 0.6969
```

Modelo balanceado refinado con Stepwise

```
modelo_refinado_balanceado <- step(modelo_balanceado_matching,  
  direction = "both")
```

```
## Start: AIC=873.09  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
##   nivel_educacion + cuidado_dependientes + apoyo_familiar +  
##   tabaquismo + comorbilidades  
##  
##           Df Deviance   AIC  
## - tabaquismo      1   847.09 871.09  
## - cuidado_dependientes 1   847.19 871.19  
## - nivel_educacion    2   850.59 872.59  
## - sexo              1   848.82 872.82  
## <none>              847.09 873.09  
## - apoyo_familiar    2   851.50 873.50  
## - nivel_socioeconomico 2   852.94 874.94  
## - comorbilidades    1   852.35 876.35  
## - edad              1   860.32 884.32  
## - estado_funcional  1   892.39 916.39  
##  
## Step: AIC=871.09  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
##   nivel_educacion + cuidado_dependientes + apoyo_familiar +  
##   comorbilidades  
##  
##           Df Deviance   AIC  
## - cuidado_dependientes 1   847.19 869.19  
## - nivel_educacion    2   850.60 870.60  
## - sexo              1   848.84 870.84  
## <none>              847.09 871.09  
## - apoyo_familiar    2   851.51 871.51  
## - nivel_socioeconomico 2   852.94 872.94  
## + tabaquismo        1   847.09 873.09  
## - comorbilidades    1   852.36 874.36  
## - edad              1   860.35 882.35  
## - estado_funcional  1   892.39 914.39  
##  
## Step: AIC=869.19  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
##   nivel_educacion + apoyo_familiar + comorbilidades  
##  
##           Df Deviance   AIC  
## - nivel_educacion    2   850.70 868.70  
## - sexo              1   848.89 868.89  
## <none>              847.19 869.19  
## - apoyo_familiar    2   851.60 869.60  
## - nivel_socioeconomico 2   853.09 871.09  
## + cuidado_dependientes 1   847.09 871.09
```

```

## + tabaquismo          1   847.19 871.19
## - comorbilidades      1   852.50 872.50
## - edad                1   860.36 880.36
## - estado_funcional    1   892.59 912.59
##
## Step: AIC=868.7
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades
##
##              Df Deviance    AIC
## - sexo          1   852.36 868.36
## <none>           850.70 868.70
## - apoyo_familiar  2   855.14 869.14
## + nivel_educacion  2   847.19 869.19
## - nivel_socioeconomico  2   856.43 870.43
## + cuidado_dependientes  1   850.60 870.60
## + tabaquismo      1   850.70 870.70
## - comorbilidades  1   855.79 871.79
## - edad            1   864.08 880.08
## - estado_funcional  1   895.55 911.55
##
## Step: AIC=868.36
## exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades
##
##              Df Deviance    AIC
## <none>           852.36 868.36
## - apoyo_familiar  2   856.63 868.63
## + sexo            1   850.70 868.70
## + nivel_educacion  2   848.89 868.89
## - nivel_socioeconomico  2   858.13 870.13
## + cuidado_dependientes  1   852.29 870.29
## + tabaquismo      1   852.35 870.35
## - comorbilidades  1   857.21 871.21
## - edad            1   865.44 879.44
## - estado_funcional  1   896.80 910.80

```

modelo_refinado_balanceado

```

##
## Call: glm(formula = exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              (Intercept)                  edad
##              -0.70600                  0.02235
##              estado_funcional nivel_socioeconomicoMedio
##              0.02047                  0.31256
## nivel_socioeconomicoAlto      apoyo_familiarMedio
##              -0.18366                  0.24422
##              apoyo_familiarAlto      comorbilidades
##              -0.19338                  -0.12960
##
## Degrees of Freedom: 894 Total (i.e. Null); 887 Residual

```

```
## Null Deviance:      920.1
## Residual Deviance: 852.4      AIC: 868.4
```

El modelo refinado balanceado con Propensity Scores tiene un mejor ajuste (AIC más bajo) en comparación con el modelo inicial con Propensity Scores. Las variables clave que permanecen significativas son la edad, el estado funcional y las comorbilidades.

Las variables eliminadas son: sexo, nivel_educacion, tabaquismo, y cuidado_dependientes.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.705997   0.427835  -1.650 0.098910 .
## edad              0.022353   0.006301   3.548 0.000389 ***
## estado_funcional  0.020473   0.003180   6.438 1.21e-10 ***
## nivel_socioeconomicoMedio 0.312562   0.199006   1.571 0.116272
## nivel_socioeconomicoAlto -0.183658   0.231182  -0.794 0.426944
## apoyo_familiarMedio  0.244221   0.198363   1.231 0.218254
## apoyo_familiarAlto  -0.193381   0.229435  -0.843 0.399309
## comorbilidades    -0.129595   0.058527  -2.214 0.026809 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 920.11  on 894  degrees of freedom
## Residual deviance: 852.36  on 887  degrees of freedom
## AIC: 868.36
##
## Number of Fisher Scoring iterations: 4
```

```
## Odd Ratios
```

```
##              (Intercept)              edad              estado_funcional
##              0.4936163              1.0226046              1.0206843
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto apoyo_familiarMedio
##              1.3669223              0.8322201              1.2766270
##              apoyo_familiarAlto              comorbilidades
##              0.8241682              0.8784508
```


```
## Intervalos de Confianza para los Odds Ratios
```

```
##              2.5 %      97.5 %
## (Intercept)    0.2122114 1.1376333
## edad           1.0101944 1.0354841
## estado_funcional 1.0144240 1.0271642
## nivel_socioeconomicoMedio 0.9235926 2.0173088
```


```
## nivel_socioeconomicoAlto  0.5293033 1.3120848
## apoyo_familiarMedio      0.8637861 1.8819535
## apoyo_familiarAlto       0.5261089 1.2952551
## comorbilidades           0.7833827 0.9857793
```

edad y estado_funcional son consistentemente significativos y positivos en todos los modelos.
comorbilidades es significativo y negativo en el modelo refinado balanceado.


Residuos del modelo



Distancias de Cook



Curva ROC



```
## Area under the curve: 0.6846
```

AUC igual de buena que el modelo no refinado.

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 895 samples
## 5 predictor
## 2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 806, 805, 805, 806, 806, 805, ...
## Resampling results:
##
## ROC      Sens      Spec
## 0.672776 0.05321637 0.9901408
```

Comparación Modelos con y sin Propensity Scores

```
# Creamos una tabla con la información de ambos modelos
comparacion_modelos_pliegues <- data.frame(Métrica = c("Tamaño de muestra",
  "Número de predictores", "ROC", "Sensibilidad", "Especificidad"),
  Modelo_1_Propensity_Scores = c(895, 5, 0.672776, 0.05321637,
    0.9901408), Modelo_2_Sin_Propensity_Scores = c(1000,
    6, 0.7607771, 0.3790805, 0.9080282))

kable(comparacion_modelos_pliegues)
```

Métrica	Modelo_1_Propensity_Scores	Modelo_2_Sin_Propensity_Scores
Tamaño de muestra	895.0000000	1000.0000000
Número de predictores	5.0000000	6.0000000
ROC	0.6727760	0.7607771
Sensibilidad	0.0532164	0.3790805
Especificidad	0.9901408	0.9080282

Modelo con Propensity Scores:

Ventajas: Alta especificidad, lo que significa que es excelente para identificar correctamente a los no expuestos.

Desventajas: Muy baja sensibilidad, lo que significa que no es efectivo en la identificación de los expuestos.

Modelo sin Propensity Scores:

Ventajas: Mejor capacidad predictiva global (ROC AUC), mayor sensibilidad, lo que significa que es más equilibrado en la identificación de expuestos y no expuestos.

Desventajas: Especificidad un poco más baja en comparación con el modelo con Propensity Scores, pero aún alta.

Ponderación (Weighting)

Se procede a realizar otro balanceo con Propensity Scores, esta vez utilizando el método de Weighting, también conocido como Ponderación.


Cálculo de Pesos Inversos de Probabilidad de Tratamiento (IPW)

```
# Calculamos los pesos
datos_ps$peso_ipw <- ifelse(datos_ps$exposicion == "Sí", 1/datos_ps$propensity_score,
  1/(1 - datos_ps$propensity_score))
summary(datos_ps$peso_ipw)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.015   1.151   1.413   1.996   1.960   31.732
```

Los pesos tienen una gran diversidad de rangos como puede observarse también en el histograma. Sin embargo, vamos a continuar analizando los pesos tal y como están, aunque la opción de truncar esta distribución estaría pendiente para futuros trabajos

Distribución de Pesos IPW



Evaluación del Balance de Covariables Posterior a la Ponderación

```
##                               Stratified by exposicion
##                               No           Sí           SMD
##  n                           997.3       998.6
##  sexo = Masculino (%)        474.9 (47.6)  493.0 (49.4)  0.035
```


##	tabaquismo = Sí (%)	327.8 (32.9)	296.7 (29.7)	0.068
##	nivel_socioeconomico (%)			0.019
##	Bajo	288.2 (28.9)	297.1 (29.7)	
##	Medio	493.0 (49.4)	487.5 (48.8)	
##	Alto	216.1 (21.7)	214.0 (21.4)	
##	estado_funcional (mean (SD))	51.16 (30.36)	50.34 (28.51)	0.028
##	comorbilidades (mean (SD))	2.14 (1.31)	2.03 (1.44)	0.083
##	cuidado_dependientes = Sí (%)	183.3 (18.4)	204.5 (20.5)	0.053
##	apoyo_familiar (%)			0.094
##	Bajo	360.9 (36.2)	320.3 (32.1)	
##	Medio	431.8 (43.3)	474.6 (47.5)	
##	Alto	204.6 (20.5)	203.8 (20.4)	
##	nivel_educacion (%)			0.025
##	Bajo	178.2 (17.9)	184.0 (18.4)	
##	Medio	408.1 (40.9)	396.8 (39.7)	
##	Alto	411.0 (41.2)	417.8 (41.8)	
##	edad (mean (SD))	49.97 (13.39)	50.34 (14.33)	0.027

Todas las variables han sido balanceadas correctamente, siendo éste el método que mejor ha balanceado.

Modelo ponderado usando los pesos IPW

```

modelo_ipw <- glm(exposicion ~ sexo + edad + estado_funcional +
  nivel_socioeconomico + nivel_educacion + cuidado_dependientes +
  apoyo_familiar + tabaquismo + comorbilidades, data = datos_ps,
  weights = peso_ipw, family = binomial)
modelo_ipw

##
## Call:  glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_ps,
##      weights = peso_ipw)
##
## Coefficients:
##      (Intercept)              sexoMasculino
##      -0.0803645                0.0700738
##      edad              estado_funcional
##      0.0025800              -0.0003704
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##      -0.0183995              -0.0396119
##      nivel_educacionMedio      nivel_educacionAlto
##      -0.0768244                0.0098788
##      cuidado_dependientesSi      apoyo_familiarMedio
##      0.1258257                0.2151341
##      apoyo_familiarAlto          tabaquismoSí
##      0.1049593              -0.1272392
##      comorbilidades
##      -0.0585827
##
## Degrees of Freedom: 999 Total (i.e. Null);  987 Residual

```

```
## Null Deviance:      2767
## Residual Deviance: 2754 AIC: 2693
```

```
summary(modelo_ipw)
```


```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_ps,
##      weights = peso_ipw)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.0803645   0.2429836  -0.331   0.7408
## sexoMasculino     0.0700738   0.0901850   0.777   0.4372
## edad             0.0025800   0.0032716   0.789   0.4303
## estado_funcional -0.0003704   0.0015414  -0.240   0.8101
## nivel_socioeconomicoMedio -0.0183995   0.1060445  -0.174   0.8623
## nivel_socioeconomicoAlto -0.0396119   0.1281254  -0.309   0.7572
## nivel_educacionMedio -0.0768244   0.1281158  -0.600   0.5487
## nivel_educacionAlto  0.0098788   0.1270526   0.078   0.9380
## cuidado_dependientesSí  0.1258257   0.1144299   1.100   0.2715
## apoyo_familiarMedio  0.2151341   0.1029154   2.090   0.0366 *
## apoyo_familiarAlto   0.1049593   0.1268454   0.827   0.4080
## tabaquismoSí       -0.1272392   0.0985617  -1.291   0.1967
## comorbilidades     -0.0585827   0.0331270  -1.768   0.0770 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2766.9  on 999  degrees of freedom
## Residual deviance: 2754.0  on 987  degrees of freedom
## AIC: 2693.3
##
## Number of Fisher Scoring iterations: 5
```

apoyo_familiarMedio: Es la única covariable significativa con un valor $p < 0.05$. La estimación positiva (0.2151) sugiere que tener un apoyo familiar medio aumenta la probabilidad de exposición en comparación con el apoyo familiar bajo.


comorbilidades: Aunque no es estadísticamente significativo al nivel 0.05, está cerca ($p = 0.0770$) y su estimación negativa (-0.0586) sugiere que un mayor número de comorbilidades podría estar asociado con una menor probabilidad de exposición.

Por otro lado, el Residual Deviance sugiere que los predictores no están proporcionando un ajuste mucho mejor que el modelo nulo.


Residuos del modelo



Distancias de Cook



Curva ROC



Area under the curve: 0.5616

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 1000 samples
##   9 predictor
##   2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 900, 900, 900, 900, 901, 900, ...
## Resampling results:
##
##      ROC      Sens      Spec
## 0.4805103 0.4175862 0.5345473
```

El modelo no discrimina bien entre las clases de exposición. Esto se ve en la sensibilidad que indica que el modelo identifica correctamente el 41.76% de los casos positivos y en la especificidad que indica que el modelo identifica correctamente el 53.45% de los casos negativos

Apéndice

Código

```
# Establecer opciones globales para todos los chunks
knitr::opts_chunk$set(
  warning = FALSE,
  message = FALSE,
  tidy.opts = list(width.cutoff = 60),
  tidy = TRUE
)
# Maquetación del documento
library(knitr)
# Para maquetación de tablas
library(kableExtra)
# Para resúmenes detallados de datos
library(skimr)
# Manipulación y transformación de datos
library(dplyr)
# Creación de gráficos
library(ggplot2)
# Funciones estadísticas (incluye glm)
library(stats)
# Herramientas para la creación y evaluación de modelos
library(caret)
# Visualización y análisis de curvas ROC
library(pROC)
# Para mapas de calor
library(reshape2)
# Genera gráficos y tablas de equilibrio
library(cobalt)
# Para tablas de datos que nos permitan calcular SMD
library(tableone)
# Para Propensity Scores y Matching
library(MatchIt)
# Para manejo de estadísticas en modelos lineales
library(survey)
datos <- readRDS("C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
# Clase del dataframe
cat("Clase del dataframe\n")
class(datos)

# Primeras y últimas 3 filas
cat("Primeras 3 filas\n")
head(datos, n = 3) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"))

cat("Últimas 3 filas\n")
tail(datos, n = 3) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"))
```

```

# Estructura del dataframe
cat("Estructura del dataframe\n")
str(datos)

# Vemos la estructura de los datos usando el paquete skimr
cat("Resumen general del dataframe\n")
skim(datos)
kable(table(datos$sexo), caption = "Tabla de frecuencias de Sexo")
kable(table(datos$tabaquismo), caption = "Tabla de frecuencias de Tabaquismo")
kable(table(datos$nivel_socioeconomico), caption = "Tabla de frecuencias de Nivel Socioeconómico")
kable(table(datos$comorbilidades), caption = "Tabla de frecuencias de Comorbilidades")
kable(table(datos$cuidado_dependientes), caption = "Tabla de frecuencias de Cuidado de Dependientes")
kable(table(datos$apoyo_familiar), caption = "Tabla de frecuencias de Apoyo Familiar")
kable(table(datos$nivel_educacion), caption = "Tabla de frecuencias de Nivel de Educación")
kable(table(datos$exposicion), caption = "Tabla de frecuencias de Exposición")
kable(table(datos$resultado), caption = "Tabla de frecuencias de Resultado")
# Duplicamos el dataframe
datostransformados = data.frame(datos)

# Convertimos las variables a factores usando el paquete dplyr
datostransformados <- datostransformados %>%
  mutate(
    sexo = factor(sexo, levels = c(0, 1), labels = c("Femenino", "Masculino")),
    tabaquismo = factor(tabaquismo, levels = c(0, 1), labels = c("No", "Sí")),
    nivel_socioeconomico = factor(nivel_socioeconomico, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    cuidado_dependientes = factor(cuidado_dependientes, levels = c(0, 1), labels = c("No", "Sí")),
    apoyo_familiar = factor(apoyo_familiar, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    nivel_educacion = factor(nivel_educacion, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    exposicion = factor(exposicion, levels = c(0, 1), labels = c("No", "Sí")),
    resultado = factor(resultado, levels = c(0, 1), labels = c("No mejora", "Mejora"))
  )

# Vemos que se hayan convertido
str(datostransformados)
# Creamos una lista que incluya todas las variables numéricas
numericas <- c("estado_funcional", "comorbilidades", "edad",
               "prob_exposicion", "log_odds_Y", "prob_Y")

# Aplicamos el shapiro.test y guardamos en una variable
normalidad <- lapply(datostransformados[numericas], function(x) shapiro.test(x))

# Sacamos los resultados
normalidad_resultados <- sapply(normalidad, function(test) c(statistic = test$statistic, p_value = test$p.value))
cat("Resultados test de Shapiro-Wilk\n")
normalidad_resultados
# Detectamos outliers con el método IQR
outliers <- lapply(datostransformados[numericas], function(x) {
  iqr <- IQR(x, na.rm = TRUE)
  q1 <- quantile(x, 0.25, na.rm = TRUE)
  q3 <- quantile(x, 0.75, na.rm = TRUE)
  limites <- c(inferior = q1 - 1.5 * iqr, superior = q3 + 1.5 * iqr)
  outliers <- which(x < limites["inferior"] | x > limites["superior"])
  return(list(limites = limites, outliers = outliers))
})

```

```

})

# Vemos los resultados
cat("Outliers de estado_funcional\n")
outliers[["estado_funcional"]]
cat("Outliers de edad\n")
outliers[["edad"]]
cat("Outliers de prob_exposicion\n")
outliers[["prob_exposicion"]]
cat("Outliers de log_odds_Y\n")
outliers[["log_odds_Y"]]
cat("Outliers de comorbilidades\n")
outliers[["comorbilidades"]]
cat("Outliers de prob_Y\n")
outliers[["prob_Y"]]
# Creamos una lista que incluya todas las variables categóricas
categoricas <- c("sexo", "tabaquismo", "nivel_socioeconomico",
                 "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")

# Hacemos un bucle for para sacar todos los gráficos
for (variable in categoricas) {
  plot_categoricas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_bar(fill = "slateblue3", color = "black") +
    labs(title = paste("Distribución de", variable), x = variable, y = "Frecuencia") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_categoricas)
}

# Histogramas de densidades
for (variable in numericas) {
  plot_hist_numericas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_histogram(aes(y = ..density..), bins = 30, fill = "#A888B5", color = "black", alpha = 0.7) +
    geom_density(color = "#441752", size = 1) +
    labs(title = paste("Histograma y densidad de", variable), x = variable, y = "Densidad") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_hist_numericas)
}

# Boxplots
for (variable in numericas) {
  plot_box_numericas <- ggplot(datostransformados, aes_string(y = variable)) +
    geom_boxplot(fill = "#EFB6C8", color = "black", outlier.color = "red", outlier.size = 2) +
    labs(title = paste("Boxplot de", variable), x = "", y = variable) +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_box_numericas)
}

# Creamos boxplots de cada variable continua según 'resultado'
for (variable in numericas) {
  plot_box_con_resultado <- ggplot(datostransformados, aes_string(x = "resultado", y = variable, fill =
    geom_boxplot(outlier.color = "red", outlier.size = 2) +
    labs(title = paste("Boxplot de", variable, "según el resultado"),

```

```

      x = "Resultado", y = variable) +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_box_con_resultado)
}

for (variable in numericas) {
  plot_hist_con_resultado <- ggplot(datostransformados, aes_string(x = variable, fill = "resultado")) +
    geom_density(alpha = 0.5) +
    labs(title = paste("Densidad de", variable, "según el resultado"),
         x = variable, y = "Densidad") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_hist_con_resultado)
}

# Seleccionamos solos los datos numéricos y creamos otra tabla
datos_numericos <- datostransformados[numericas]

# Calculamos la matriz de correlación
cor_matrix_numericas <- cor(datos_numericos, use = "complete.obs")

# Mostramos la matriz de correlación
kable(cor_matrix_numericas)

# Visualizamos la matriz de correlación
cor_data <- melt(cor_matrix_numericas)
ggplot(cor_data, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(low = "#FABC3F", high = "#821131", mid = "#E85C0D",
                      midpoint = 0, limit = c(-1, 1), space = "Lab",
                      name = "Correlación") +
  theme_minimal() +
  labs(title = "Matriz de correlación") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
# Gráficos de barras para variables categóricas por exposición
for (variable in categoricas) {
  print(
    ggplot(datostransformados, aes_string(x = variable, fill = "exposicion")) +
    geom_bar(position = "dodge", color = "black") +
    labs(title = paste("Distribución de", variable, "por Exposición"),
         x = variable, y = "Frecuencia") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  )
}

# Boxplots para variables numericas por exposición
for (variable in numericas) {
  print(
    ggplot(datostransformados, aes_string(x = "exposicion", y = variable, fill = "exposicion")) +
    geom_boxplot(outlier.color = "red", outlier.shape = 16) +
    labs(title = paste("Boxplot de", variable, "por Exposición"),

```



```

        x = "Exposición", y = variable) +
        theme_minimal() +
        theme(plot.title = element_text(hjust = 0.5))
    )
}
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
    tabla <- table(datostransformados[[variable]], datostransformados$exposicion)
    prueba_chi <- chisq.test(tabla)
    print(paste("Prueba Chi-cuadrado para", variable))
    print(prueba_chi)
}
# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon Rank-Sum Test)
for (variable in numericas) {
    wilcox_test <- wilcox.test(datostransformados[[variable]] ~ datostransformados$exposicion)
    print(paste("Prueba de Mann-Whitney para", variable))
    print(wilcox_test)
}
modelo_inicial <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + cuidado_deper,
                      data = datostransformados,
                      family = binomial)
modelo_inicial
cat("Summary del modelo\n")
summary(modelo_inicial)
cat("Odd Ratios\n")
exp(coef(modelo_inicial))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_inicial))
plot(residuals(modelo_inicial, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_inicial),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datostransformados) - length(coef(modelo_inicial))), col = "red", lty = 2)

roc_curve <- roc(datostransformados$exposicion, fitted(modelo_inicial))
plot(roc_curve, main = "Curva ROC")
auc(roc_curve)
# Aplicamos una regresión stepwise al modelo
modelo_refinado <- step(modelo_inicial, direction = "both")

# Vemos el resultado
modelo_refinado
cat("Summary del modelo\n")
summary(modelo_refinado)
cat("Odd Ratios\n")
exp(coef(modelo_refinado))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_refinado))

```

```

plot(residuals(modelo_refinado, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_refinado),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datostransformados) - length(coef(modelo_refinado))), col = "red", lty = 2)
roc_curve_refinado <- roc(datostransformados$exposicion, fitted(modelo_refinado))
plot(roc_curve_refinado, main = "Curva ROC")
auc(roc_curve_refinado)
# Configuramos la validación cruzada
train_control <- trainControl(
  method = "cv",
  number = 10,
  summaryFunction = twoClassSummary,
  classProbs = TRUE
)

# Entrenamos el modelo
set.seed(19780301)
modelo_cv <- train(
  exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
    nivel_educacion + comorbilidades,
  data = datostransformados,
  method = "glm",
  family = "binomial",
  trControl = train_control,
  metric = "ROC"
)

print(modelo_cv)
# Establecemos semilla
set.seed(19780301)

# Copiamos los datos
datos_ps <- data.frame(datostransformados)

# Extraemos los Propensity Scores
datos_ps$propensity_score <- predict(modelo_inicial, type = "response")

# Calculamos la desviación estándar de los PS en caso de que sean necesarias
sd_ps <- sd(datos_ps$distance, na.rm = TRUE)

# Sacamos el summary
summary(datos_ps$propensity_score)
# Definimos las covariables a evaluar
covariables <- c("sexo", "tabaquismo", "nivel_socioeconomico", "estado_funcional",
  "comorbilidades", "cuidado_dependientes", "apoyo_familiar",
  "nivel_educacion", "edad")

```

```

# Creamos la tabla de balance inicial para ver las diferencias de medias estandarizadas (SMD)
tabla_balance <- CreateTableOne(vars = covariables,
                                strata = "exposicion",
                                data = datos_ps,
                                test = FALSE)

# Mostramos los resultados
print("Tabla de Balance con los resultados de SMD")
print(tabla_balance, smd = TRUE)
# Establecemos la semilla
set.seed(19780301)

# Sacamos la formula del balance
formula_balance <- exposicion ~ sexo + tabaquismo + nivel_socioeconomico + estado_funcional + comorbili

# Utilizamos la formula para sacar los datos que nos permitan hacer el Love Plot
bal_tab <- bal.tab(formula_balance, data = datos_ps)

# Creamos el Love Plot para el balance inicial
love.plot(bal_tab,
           threshold = 0.1,
           var.order = "unadjusted",
           stat = "mean.diffs",
           abs = TRUE,
           colors = c("red", "blue"),
           stars = "raw")

# Establecemos la semilla
set.seed(19780301)

# Aplicamos el matching utilizando solo las 3 variables más desbalanceadas
matching_replace <- matchit(
  formula = exposicion ~ sexo + edad + estado_funcional,
  data = datos_ps,
  method = "nearest",
  distance = "logit",
  replace = TRUE
)

# Mostramos los resultados
summary(matching_replace)
# Extraemos los datos
datos_replace <- match.data(matching_replace)

# Creamos la tabla de balance
tabla_balance_replace <- CreateTableOne(
  vars = covariables,
  strata = "exposicion",
  data = datos_replace,
  test = FALSE
)

# Mostramos el balance
print(tabla_balance_replace, smd = TRUE)

```

```

# Semilla
set.seed(19780301)

# Modelo de Matching
matching_replace_all <- matchit(
  formula = exposicion ~ sexo + edad + estado_funcional + comorbilidades + nivel_socioeconomico + apo
  data = datos_ps,
  method = "nearest",
  distance = "logit",
  replace = TRUE
)

# Resultados
summary(matching_replace_all)
datos_replace_all <- match.data(matching_replace_all)
tabla_balance_replace_all <- CreateTableOne(
  vars = covariables,
  strata = "exposicion",
  data = datos_replace_all,
  test = FALSE
)
print(tabla_balance_replace_all, smd = TRUE)
set.seed(19780301)
matching_replace_comorb <- matchit(
  formula = exposicion ~ sexo + edad + estado_funcional + comorbilidades,
  data = datos_ps,
  method = "nearest",
  distance = "logit",
  replace = TRUE
)
summary(matching_replace_comorb)
datos_replace_comorb <- match.data(matching_replace_comorb)
tabla_balance_replace_comorb <- CreateTableOne(
  vars = covariables,
  strata = "exposicion",
  data = datos_replace_comorb,
  test = FALSE
)
print(tabla_balance_replace_comorb, smd = TRUE)
# Cogemos los datos de SMD para comparar
tabla_comparativa_SMD <- data.frame(
  Variable = c("n", "sexo = Masculino (%)", "tabaquismo = Sí (%)", "nivel_socioeconomico", "estado_func
  Modelo_Original = c("293/707", "0.192", "0.046", "0.140", "0.809", "0.137", "0.011", "0.130", "0.170"
  Reemplazo = c("184/707", "0.091", "0.008", "0.176", "0.529", "0.216", "0.062", "0.163", "0.193", "0.2
  Reemplazo_Completo = c("178/707", "0.160", "0.011", "0.100", "0.499", "0.138", "0.032", "0.056", "0.1
  Reemplazo_Comorbilidades = c("188/707", "0.079", "0.013", "0.207", "0.529", "0.158", "0.034", "0.182"
)

# Mostramos la tabla
print(tabla_comparativa_SMD)
love.plot(bal.tab(matching_replace_all),
  threshold = 0.1,
  var.order = "unadjusted",

```

```

    stat = "mean.diffs",
    abs = TRUE,
    colors = c("red", "blue"),
    stars = "raw")
# Visualizamos el Love Plot después del emparejamiento con comorbilidades
love.plot(bal.tab(matching_replace_comorb),
  threshold = 0.1,
  var.order = "unadjusted",
  stat = "mean.diffs",
  abs = TRUE,
  colors = c("red", "blue"),
  stars = "raw")
str(datos_replace_comorb)
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
  tabla_balanceado <- table(datos_replace_comorb[[variable]], datos_replace_comorb$exposicion)
  prueba_chi_balanceado <- chisq.test(tabla_balanceado)
  print(paste("Prueba Chi-cuadrado para", variable))
  print(prueba_chi_balanceado)
}

# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon Rank-Sum Test)
for (variable in numericas) {
  wilcox_test_balanceado <- wilcox.test(datos_replace_comorb[[variable]] ~ datos_replace_comorb$exposicion)

  print(paste("Prueba de Mann-Whitney para", variable))
  print(wilcox_test_balanceado)
}

modelo_balanceado_matching <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + nivel_educacional,
  data = datos_replace_comorb,
  family = binomial)
modelo_balanceado_matching
cat("Summary del modelo\n")
summary(modelo_balanceado_matching)
cat("Odd Ratios\n")
exp(coef(modelo_balanceado_matching))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_balanceado_matching))
plot(residuals(modelo_balanceado_matching, type = "deviance"),
  main = "Residuos de Deviance",
  ylab = "Residuos de Deviance",
  xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)

plot(cooks.distance(modelo_balanceado_matching),
  main = "Distancia de Cook",
  ylab = "Distancia de Cook",
  xlab = "Índice de observación")
abline(h = 4/(nrow(datos_replace_comorb) - length(coef(modelo_balanceado_matching))), col = "red", lty = 2)

roc_curve_balanceado <- roc(datos_replace_comorb$exposicion, fitted(modelo_balanceado_matching))
plot(roc_curve_balanceado, main = "Curva ROC")

```

```

auc(roc_curve_balanceado)
modelo_refinado_balanceado <- step(modelo_balanceado_matching, direction = "both")
modelo_refinado_balanceado
cat("Summary del modelo\n")
summary(modelo_refinado_balanceado)
cat("Odd Ratios\n")
exp(coef(modelo_refinado_balanceado))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_refinado_balanceado))
plot(residuals(modelo_refinado_balanceado, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_refinado_balanceado),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datos_replace_comorb) - length(coef(modelo_refinado_balanceado))), col = "red", lty = 2)

roc_curve_refinado_balanceado <- roc(datos_replace_comorb$exposicion, fitted(modelo_refinado_balanceado))
plot(roc_curve_refinado_balanceado, main = "Curva ROC")
auc(roc_curve_refinado_balanceado)
# Entrenamos el modelo
set.seed(19780301)
modelo_cv_balanceado_refinado <- train(
  exposicion ~ edad + estado_funcional + nivel_socioeconomico +
  apoyo_familiar + comorbilidades,
  data = datos_replace_comorb,
  method = "glm",
  family = "binomial",
  trControl = train_control,
  metric = "ROC"
)

print(modelo_cv_balanceado_refinado)
# Creamos una tabla con la información de ambos modelos
comparacion_modelos_pliegues <- data.frame(
  Métrica = c("Tamaño de muestra", "Número de predictores", "ROC", "Sensibilidad", "Especificidad"),
  Modelo_1_Propensity_Scores = c(895, 5, 0.672776, 0.05321637, 0.9901408),
  Modelo_2_Sin_Propensity_Scores = c(1000, 6, 0.7607771, 0.3790805, 0.9080282)
)

kable(comparacion_modelos_pliegues)
# Calculamos los pesos
datos_ps$peso_ipw <- ifelse(datos_ps$exposicion == "Sí",
                           1 / datos_ps$propensity_score,
                           1 / (1 - datos_ps$propensity_score))
summary(datos_ps$peso_ipw)
# Histograma de Distribución de Pesos IPW
hist(datos_ps$peso_ipw, breaks = 50,
     main = "Distribución de Pesos IPW",
     xlab = "Peso IPW",

```

```

col = "skyblue", # Color de las barras
border = "darkblue", # Color del borde de las barras
ylim = c(0, max(hist(datos_ps$peso_ipw, plot = FALSE)$counts) * 1.1)) # Ajuste del eje Y
abline(v = mean(datos_ps$peso_ipw), col = "purple", lwd = 2, lty = 2)
legend("topright", legend = c("Densidad", "Media"),
      col = c("red", "purple"), lwd = 2, lty = c(1, 2))
# Utilizamos Survey para generar un diseño con los pesos que nos permita generar la Tabla One
design_ipw <- svydesign(ids = ~1, data = datos_ps, weights = ~peso_ipw)

# Creamos la tabla
table_balance_ipw <- svyCreateTableOne(vars = covariables,
                                       strata = "exposicion",
                                       data = design_ipw,
                                       test = FALSE)

# Mostramos los resultados
print(table_balance_ipw, smd = TRUE)
modelo_ipw <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + nivel_educacion +
                 data = datos_ps,
                 weights = peso_ipw,
                 family = binomial)

modelo_ipw
summary(modelo_ipw)
plot(residuals(modelo_ipw, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_ipw),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datos_ps) - length(coef(modelo_ipw))), col = "red", lty = 2)
roc_curve_ponderado <- roc(datos_ps$exposicion, fitted(modelo_ipw))
plot(roc_curve_ponderado, main = "Curva ROC")
auc(roc_curve_ponderado)
# Definimos una función personalizada para entrenar el modelo con pesos
train_weighted_glm <- function(data, formula, weights) {
  glm(formula, data = data, family = "binomial", weights = weights)
}

# Usamos el modelo ponderado con validación cruzada
set.seed(19780301)
modelo_cv_ponderado <- train(
  exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + nivel_educacion +
    cuidado_dependientes + apoyo_familiar + tabaquismo + comorbilidades,
  data = datos_ps,
  method = "glm",
  family = "binomial",
  weights = datos_ps$peso_ipw,
  trControl = train_control,
  metric = "ROC"
)

```

```
print(modelo_cv_ponderado)
```