

Datos Simulados - TFM Evaluación de Propensity Scores

Adrián Martínez Requena

2024-2025

Contents

Paquetes utilizados	1
Generación de Variable Exposición (X), Resultado (Y) y Covariables	1
Exploración de los datos	3
Gráficos	6
Distribución de sexos	6
Mapa de calor de las correlaciones	7

Paquetes utilizados

```
# Para maquetación
library(knitr)
# Simulación de datos
library(simstudy)
# Manipulación de datos
library(dplyr)
# Diseño de Gráficos
library(ggplot2)
# Transformación de datos para el mapa de calor
library(reshape2)
# Función para truncar una variable (en este caso la edad)
library(truncnorm)
truncar <- function(n, mean, sd, min_val) {
  valores <- rtruncnorm(n, a = min_val, mean = mean, sd = sd)
  return(round(valores))
}
```

Generación de Variable Exposición (X), Resultado (Y) y Covariables

```

# Se ha utilizado como semilla una fecha conocida por el
# autor
set.seed(19780301)

# Sexo donde 0 = Mujer, 1 = Hombre (misma probabilidad)
def <- defData(varname = "sexo", dist = "binary", formula = 0.5)

# Tabaquismo donde 0 = No, 1 = Sí (30% fumadores)
def <- defData(def, varname = "tabaquismo", dist = "binary",
  formula = 0.3)

# Nivel Socioeconómico donde 1 = Bajo, 2 = Medio, 3 = Alto
# (30%, 50%, 20%)
def <- defData(def, varname = "nivel_socioeconomico", dist = "categorical",
  formula = "0.3;0.5;0.2")

# Estado funcional, Uniforme entre 0 y 100
def <- defData(def, varname = "estado_funcional", dist = "uniform",
  formula = "0;100")

# Comorbilidades desde 0 a más, media de 2
def <- defData(def, varname = "comorbilidades", dist = "poisson",
  formula = 2)

# Cuidado de dependientes donde 0 = No, 1 = Sí (20%
# cuidadores)
def <- defData(def, varname = "cuidado_dependientes", dist = "binary",
  formula = 0.2)

# Apoyo familiar donde 1 = Bajo, 2 = Medio, 3 = Alto (30%,
# 50%, 20%)
def <- defData(def, varname = "apoyo_familiar", dist = "categorical",
  formula = "0.3;0.5;0.2")

# Nivel de educación: 1 = Básico, 2 = Intermedio, 3 =
# Avanzado (proporciones 20%, 40%, 40%)
def <- defData(def, varname = "nivel_educacion", dist = "categorical",
  formula = "0.2;0.4;0.4")

# Reunimos todas estas covariables en un dataframe y
# añadimos 1000 participantes
datos <- genData(1000, def)

# Ahora, añadimos en el dataframe la edad, truncandola con
# la función.
datos[, edad := truncar(.N, 50, 15, 18)] # Desviación típica de 15

# Damos valor a cada peso para la función de Exposición (X)
pesoX_sexo <- 0.4
pesoX_edad <- 0.03
pesoX_tabaquismo <- -0.05
pesoX_comorbilidades <- -0.08
pesoX_estadofuncional <- 0.03

```

```

pesoX_nivelsocioeconomico <- 0.01
pesoX_cuidadodependientes <- -0.02
pesoX_apoyofamiliar <- 0.03
pesoX_niveleducacion <- 0.02

# Establecemos el intercepto
intercepto <- -2

# Sacamos la probabilidad de exposición
datos[, prob_exposicion := plogis(intercepto + pesoX_sexo *
  sexo + pesoX_edad * edad + pesoX_tabaquismo * tabaquismo +
  pesoX_comorbilidades * comorbilidades + pesoX_estadofuncional *
  estado_funcional + pesoX_nivelsocioeconomico * nivel_socioeconomico +
  pesoX_cuidadodependientes * cuidado_dependientes + pesoX_apoyofamiliar *
  apoyo_familiar + pesoX_niveleducacion * nivel_educacion)]

# Generamos la variable Exposición (X)
datos[, exposicion := rbinom(.N, size = 1, prob = prob_exposicion)]

# Damos valor a cada peso para la función del Resultado (Y)
pesoY_sexo <- -0.1
pesoY_edad <- -0.04
pesoY_tabaquismo <- -0.08
pesoY_comorbilidades <- -0.1
pesoY_estadofuncional <- 0.1
pesoY_nivelsocioeconomico <- 0.05
pesoY_cuidadodependientes <- -0.02
pesoY_apoyofamiliar <- 0.05
pesoY_niveleducacion <- 0.07
pesoY_exposicion <- 0.5

# Calcular log-odds para el resultado (Y)
datos[, log_odds_Y := intercepto + pesoY_sexo * sexo + pesoY_edad *
  edad + pesoY_tabaquismo * tabaquismo + pesoY_comorbilidades *
  comorbilidades + pesoY_estadofuncional * estado_funcional +
  pesoY_nivelsocioeconomico * nivel_socioeconomico + pesoY_cuidadodependientes *
  cuidado_dependientes + pesoY_apoyofamiliar * apoyo_familiar +
  pesoY_niveleducacion * nivel_educacion + pesoY_exposicion *
  exposicion]

# Convertimos log-odds a probabilidades
datos[, prob_Y := plogis(log_odds_Y)]

# Generamos la variable binaria de resultado (0 = no
# mejora, 1 = mejora)
datos[, resultado := rbinom(.N, size = 1, prob = prob_Y)]

```

Exploración de los datos

```

# Exploramos los datos que se han generado
str(datos)

```

```
## Classes 'data.table' and 'data.frame': 1000 obs. of 15 variables:
## $ id : int 1 2 3 4 5 6 7 8 9 10 ...
## $ sexo : int 1 0 0 1 0 1 0 0 1 0 ...
## $ tabaquismo : int 0 0 1 0 1 0 0 0 0 0 ...
## $ nivel_socioeconomico: int 3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional : num 47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int 1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: int 0 0 0 1 0 0 1 0 0 0 ...
## $ apoyo_familiar : int 1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion : int 3 1 1 1 3 3 1 2 1 2 ...
## $ edad : num 51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion : num 0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion : int 0 1 1 1 1 1 0 0 1 1 ...
## $ log_odds_Y : num 0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y : num 0.721 0.86 0.316 0.993 0.339 ...
## $ resultado : int 0 1 1 1 0 1 0 0 1 0 ...
## - attr(*, ".internal.selfref")=<externalptr>
## - attr(*, "sorted")= chr "id"
```

```
head(datos) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
1	1	0	3	47.79371	1	0	1	3	51	0.8027880	0	0.9493709	0.7209886	0
2	0	0	2	51.77346	0	0	1	1	52	0.7655234	1	1.8173460	0.8602474	1
3	0	1	2	20.19209	4	0	2	1	27	0.2985447	1	-0.7707915	0.3163079	1
4	1	0	2	89.86442	3	1	3	1	60	0.9408069	1	4.9864423	0.9932164	1
5	0	1	2	34.01018	1	0	2	3	70	0.7558952	1	-0.6689822	0.3387248	0
6	1	0	2	40.11481	3	0	2	3	63	0.8011415	1	0.0014809	0.5003702	1

```
tail(datos) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
995	1	0	3	85.743637	1	0	2	2	41	0.9048495	1	5.624364	0.9964041	1
996	0	0	3	9.189060	1	0	1	3	84	0.6975529	0	-4.131094	0.0158113	0
997	0	0	3	11.126783	0	0	3	2	53	0.5209386	1	-2.067322	0.1123138	0
998	1	0	1	83.915613	0	0	2	1	43	0.9086672	1	5.291561	0.9949913	1
999	1	1	3	55.555770	4	1	2	2	27	0.6494615	0	2.265577	0.9059857	1
1000	1	0	1	6.638573	0	1	2	3	62	0.6385687	1	-3.076143	0.0441021	0

```
# Observamos la variable Exposición (X)
summary(datos$prob_exposicion)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.2012  0.5944  0.7578  0.7207  0.8692  0.9754
```

```
kable(table(datos$exposicion))
```

Var1	Freq
0	293
1	707

```
# Y los Resultados (Y)
kable(table(datos$resultado))
```

Var1	Freq
0	376
1	624

```
# Usamos Dplyr para generar nuevas tablas que nos permitan
# seguir explorando
id_prob_exposicion <- datos %>%
  select(id, prob_exposicion, exposicion)

# Seleccionamos a todos los participantes y los dividimos
# por sexo y si están expuestos o no
id_exposicion_sexo <- datos %>%
  select(id, sexo, prob_exposicion, exposicion)
resumen_exposicion <- id_exposicion_sexo %>%
  group_by(sexo, exposicion) %>%
  summarise(n = n()) %>%
  arrange(sexo, exposicion)
kable(resumen_exposicion)
```

sexo	exposicion	n
0	0	166
0	1	333
1	0	127
1	1	374

```
# Sacamos la tasa de exposición por sexo
tasas_exposicion_sexo <- datos[, .(tasa_exposicion = mean(exposicion)),
  by = sexo]
kable(tasas_exposicion_sexo)
```

sexo	tasa_exposicion
1	0.7465070
0	0.6673347

```
# Calculamos las correlaciones para la exposición (X)
correlaciones <- datos[, lapply(.SD, function(x) cor(x, exposicion,
  use = "complete.obs")), .SDcols = c("edad", "sexo", "tabaquismo",
  "comorbilidades", "estado_funcional", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")]
```

```
correlaciones %>%
  kable(format = "latex", booktabs = TRUE, caption = "Correlaciones de las covariables
    con la exposición (X)") %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

Table 5: Correlaciones de las covariables con la exposición (X)

edad	sexo	tabaquismo	comorbilidades	estado_funcional	nivel_socioeconomico	cuidado_dependientes	apoyo_familiar	nivel_educacion
0.1891018	0.0869759	0.0206206	-0.0623909	0.3444763	0.0157432	0.0051102	-0.0220353	0.0623849

```
# Calculamos las correlaciones con el resultado (Y)
correlaciones_y <- datos[, lapply(.SD, function(x) cor(x, resultado,
  use = "complete.obs")), .SDcols = c("edad", "sexo", "tabaquismo",
  "comorbilidades", "estado_funcional", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")]
correlaciones_y %>%
  kable(format = "latex", booktabs = TRUE, caption = "Correlaciones de las covariables
    con el resultado (Y)") %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```


Table 6: Correlaciones de las covariables con el resultado (Y)

edad	sexo	tabaquismo	comorbilidades	estado_funcional	nivel_socioeconomico	cuidado_dependientes	apoyo_familiar	nivel_educacion
-0.108946	-0.0232215	0.0246163	0.0172061	0.7399989	0.0862465	-0.0345475	-0.0165202	-0.0063244

Gráficos

Distribución de sexos

```
# Gráfico para ver cómo se han distribuido los dos sexos
ggplot(datos, aes(x = prob_exposicion, fill = as.factor(sexo))) +
  geom_density(alpha = 0.5) + scale_fill_manual(values = c(`0` = "red",
  `1` = "darkblue"), labels = c("Mujer", "Hombre")) + labs(title = "Probabilidad de
    exposición por sexo",
  fill = "Sexo", x = "Probabilidad de Exposición", y = "Densidad") +
  theme_minimal() + theme(plot.title = element_text(hjust = 0.5,
  size = 14), legend.position = "top")
```




Mapa de calor de las correlaciones

```
# Convertimos el data.table a data.frame para facilitar el
# manejo
correlaciones_df <- as.data.frame(t(correlaciones))

# Añadimos una columna con los nombres de las variables
correlaciones_df$Variable <- rownames(correlaciones_df)


# Generamos el Mapa de Calor
correlaciones_melt <- melt(correlaciones_df, id.vars = "Variable")
library(ggplot2)
ggplot(correlaciones_melt, aes(x = Variable, y = variable, fill = value)) +
  geom_tile(color = "white") + scale_fill_gradient2(low = "blue",
    high = "#C30E59", mid = "white", midpoint = 0, limit = c(-1,
    1), space = "Lab", name = "Correlación") + theme_minimal() +
  labs(title = "Mapa de calor de correlaciones con la exposición",
    x = "Covariables", y = "Exposición") + theme(axis.text.x = element_text(angle = 45,
    vjust = 1, hjust = 1), plot.title = element_text(hjust = 0.5,
    size = 14))
```



```
# Convertimos el data.table a data.frame para el mapa de
# calor
correlaciones_y_df <- as.data.frame(t(correlaciones_y))

# Añadimos una columna con los nombres de las variables
correlaciones_y_df$Variable <- rownames(correlaciones_y_df)

# Generamos el Mapa de Calor
correlaciones_y_melt <- melt(correlaciones_y_df, id.vars = "Variable")
ggplot(correlaciones_y_melt, aes(x = Variable, y = variable,
  fill = value)) + geom_tile(color = "white") + scale_fill_gradient2(low = "blue",
  high = "#C30E59", mid = "white", midpoint = 0, limit = c(-1,
  1), space = "Lab", name = "Correlación") + theme_minimal() +
  labs(title = "Mapa de calor de correlaciones con el resultado",
    x = "Covariables", y = "Resultado") + theme(axis.text.x = element_text(angle = 45,
  vjust = 1, hjust = 1), plot.title = element_text(hjust = 0.5,
  size = 14))
```

```
# Por último exportamos los datos en .csv y en .rds para
# trabajar con ellos durante el análisis
write.csv(datos, "C:/Users/navia/Desktop/TFM/Datos Simulados/datos.csv",
          row.names = FALSE)
saveRDS(datos, "C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
```