

Evaluación de Propensity Scores en estudios observacionales: simulación de datos y sesgo de género en la adherencia a tratamientos



Universitat Oberta
de Catalunya

Adrián Martínez Requena

Estudios Clínicos y Epidemiológicos

Máster en Bioinformática y bioestadística

Nombre del director/a de TF:

Susana Pérez Álvarez

Nombre del/de la PRA:

Laia Subirats Maté

14 de Enero de 2025



Esta obra esta sujeta a una licencia de Reconocimiento-NoComercial
<https://creativecommons.org/licenses/by-nc/3.0/es/>

Ficha Del Trabajo Final

Título del trabajo:	Evaluación de Propensity Scores en estudios observacionales: simulación de datos y sesgo de género en la adherencia a tratamientos
Nombre del autor/a:	Adrián Martínez Requena
Nombre del director/a de TF:	Susana Pérez Álvarez
Nombre del/de la PRA:	Laia Subirats Maté
Fecha de entrega:	14 de Enero de 2025
Titulación o programa:	Máster en Bioinformática y bioestadística
Área del trabajo final:	Estudios Clínicos y Epidemiológicos
Idioma del trabajo:	Castellano
Palabras clave:	propensity Scores, estudios observacionales, simulación de datos, sesgo de género, adherencia a tratamientos

Resumen del trabajo

Este trabajo de fin de máster evalúa la eficacia de los Propensity Scores como herramienta estadística para mejorar la validez de los estudios observacionales y mitigar el sesgo de género en la adherencia a tratamientos médicos. En un contexto donde los métodos tradicionales, como la regresión, presentan limitaciones para abordar variables confusoras, los PS ofrecen una alternativa robusta para equilibrar características entre grupos de tratamiento y control.

El estudio utilizó datos simulados diseñados para reflejar escenarios de sesgo, como una menor probabilidad de tratamiento en mujeres. La metodología incluyó la simulación de covariables relevantes y la aplicación de técnicas de PS, como emparejamiento y ponderación, comparándolas con métodos estadísticos tradicionales. Se implementó un enfoque basado en la metodología CRISP-DM, que abarca desde la comprensión del problema hasta la evaluación de los resultados.

Los resultados muestran que los PS logran un mejor balance de covariables y reducen significativamente el sesgo de género, mejorando la comparabilidad entre grupos y proporcionando estimaciones más precisas. Además, los modelos basados en PS demostraron ser más efectivos en términos de validez interna, aunque en detrimento de validez predictiva.

En conclusión, este estudio valida la utilidad de los PS en la investigación observacional, destacando su capacidad para corregir sesgos y promover una investigación médica más inclusiva. Esto refuerza su potencial como herramienta clave para abordar desigualdades de género en el ámbito clínico y epidemiológico.

Abstract

This master's thesis evaluates the efficacy of Propensity Scores as a statistical tool to improve the validity of observational studies and mitigate gender bias in medical treatment adherence. In a context where traditional methods, such as regression, have limitations in addressing confounding variables, PS offers a robust alternative for balancing characteristics between treatment and control groups.

The study used simulated data designed to reflect bias scenarios, such as a lower probability of treatment in women. The methodology included the simulation of relevant covariates and the application of PS techniques, such as matching and weighting, compared with traditional statistical methods. An approach based on the CRISP-DM methodology was implemented, ranging from understanding the problem to evaluating the results.

The results show that PS achieves a better balance of covariates and significantly reduces gender bias, improving comparability between groups and providing more accurate estimates. In addition, PS-based models proved to be more effective in terms of internal validity, although at the expense of predictive validity.

In conclusion, this study validates the usefulness of PS in observational research, highlighting its ability to correct biases and promote more inclusive medical research. This reinforces its potential as a key tool for addressing gender inequalities in the clinical and epidemiological setting.

Índice general

Índice general	5
Índice de figuras	8
Índice de cuadros	9
1. Introducción	11
1.1. Contexto y justificación del trabajo	11
1.2. Descripción general	12
1.3. Objetivos del trabajo	12
1.4. Impacto en sostenibilidad, ético-social y de diversidad	12
1.5. Enfoque y método seguido	13
1.6. Planificación del trabajo	14
1.6.1. Tareas	14
1.6.2. Calendario	16
1.6.3. Hitos	17
1.7. Análisis de riesgos	17
1.8. Breve resumen de productos obtenidos	17
1.9. Breve descripción de los otros capítulos de la memoria	18
2. Estado del arte	19
2.1. Contextualización	19
2.2. Propensity Scores: Fundamentos Teóricos	19
2.2.1. ¿Qué son?	19
2.2.2. ¿Cómo funcionan?	20
2.2.3. Comparación con métodos tradicionales	20
2.2.4. Aplicaciones prácticas	21
2.3. Propensity Scores y Simulación de datos	21
2.4. Sesgo de género	22
2.5. Objetivos e hipótesis	22
3. Materiales y Métodos	23
3.1. Diseño Experimental	23
3.2. Materiales	23
3.3. Simulación de Datos	23

3.3.1.	Distribuciones y Semillas	23
3.3.2.	Variables Simuladas	23
3.3.3.	Parámetros de las Covariables	24
3.3.4.	Fórmulas Logísticas	25
3.3.5.	Justificación de las variables seleccionadas	26
3.3.6.	Diseño y Método	27
3.4.	Análisis de Datos	28
3.4.1.	Métodos Tradicionales: Regresión Logística	28
3.4.2.	Propensity Scores: Emparejamiento	29
3.4.3.	Regresión Logística con PS: Emparejamiento	30
3.4.4.	Propensity Scores: Ponderación	31
3.4.5.	Regresión Logística con PS: Ponderación	31
4.	Resultados	32
4.1.	Simulación de Datos: Adherencia al Tratamiento	32
4.2.	Análisis de los Datos	36
4.2.1.	Exploración y Análisis Descriptivo de los Datos	36
4.3.	Análisis de Regresión Logística	39
4.3.1.	Gráfico de residuos	40
4.3.2.	Distancias de Cook	41
4.3.3.	Curva ROC	41
4.4.	Modelo Refinado: Stepwise	42
4.4.1.	Gráfico de residuos para el modelo refinado	43
4.4.2.	Distancias de Cook para el modelo refinado	43
4.4.3.	Curva ROC para el modelo refinado	44
4.4.4.	Validación cruzada con 10 pliegues	44
4.5.	Propensity Scores	45
4.5.1.	Cálculo de los Propensity Scores	45
4.5.2.	Análisis de Balance Inicial de las Covariables	45
4.5.3.	Love Plot del Balance Inicial	47
4.6.	Balanceamiento con PS: Matching (Emparejamiento)	47
4.6.1.	Matching Inicial con Reemplazamiento	47
4.6.2.	Matching aplicando todas las variables con SMD mayor a 0.1	49
4.6.3.	Matching con Sexo, Edad, Estado Funcional y Comorbilidades (Versión Final)	50
4.6.4.	Comparativa del Balance entre los tres tipos de Emparejamiento	52
4.6.5.	Análisis de Asociación después del Emparejamiento	54
4.7.	Análisis de Regresión Logística con los datos balanceados por Matching	54
4.7.1.	Gráfico de residuos del Modelo Balanceado	56
4.7.2.	Distancias de Cook del Modelo Balanceado	56
4.7.3.	Curva ROC del Modelo Balanceado	57
4.8.	Modelo Balanceado refinado con Stepwise	57
4.8.1.	Gráfico de residuos del Modelo Balanceado Refinado	58
4.8.2.	Distancias de Cook del Modelo Balanceado Refinado	59
4.8.3.	Curva ROC del Modelo Balanceado Refinado	59

4.8.4. Validación cruzada con 10 pliegues (Modelo Balanceado Refinado)	60
4.9. Balanceamiento con PS: Weighting (Ponderación)	60
4.9.1. Distribución de los Pesos IPW	60
4.9.2. Tabla de Balance tras la Ponderación	61
4.10. Análisis de Regresión Logística con los datos balanceados por Ponderación . . .	62
4.10.1. Gráfico de residuos del Modelo Ponderado	64
4.10.2. Distancias de Cook del Modelo Ponderado	64
4.10.3. Curva ROC del Modelo Ponderado	65
4.10.4. Validación cruzada con 10 pliegues (Modelo Ponderado)	65
4.11. Comparación de los resultados de los Modelos	66
5. Discusión	68
5.1. Importancia de los Datos Simulados	68
5.2. Balance y Sesgo de Género	69
5.3. Diferencias en los Modelos de Regresión Logística	69
5.3.1. Diferencias en la validación de los Modelos	70
5.4. Limitaciones y Trabajos Futuros	71
5.4.1. Métodos Alternativos de Propensity Scores	71
5.4.2. Limitaciones de la Simulación de Datos	71
5.4.3. Evaluación del Sesgo Interseccional	71
5.4.4. Inclusión de Interacciones en los Modelos	72
5.4.5. Impacto de las Covariables en los Resultados Clínicos	72
6. Conclusiones	73
6.1. Reflexión crítica sobre el logro de los objetivos planteados inicialmente	73
Glosario	75
Anexos	76
A.1. Tablas de Frecuencia	76
A.2. RMarkdown de Datos Simulados	79
A.3. RMarkdown de Análisis de Datos	88
A.4. Repositorio GitHub con los archivos del TFM	168
Bibliografía	169

Índice de figuras

1.1. Ventaja de los Propensity Scores. Extraída de Quantzig[4], adaptada por autor.	11
1.2. Metodología CRISP-DM. Extraída del IIC[9]	13
1.3. Diagrama de Gantt (Original).	16
1.4. Diagrama de Gantt (Con Cambios Incluidos).	16
4.1. Probabilidad de Exposición por Sexo	34
4.2. Heatmap de las Correlaciones entre las variables seleccionadas y la exposición.	35
4.3. Heatmap de las Correlaciones entre las variables seleccionadas y el resultado.	35
4.4. Mapa de calor de la matriz de correlación.	38
4.5. Gráfico de residuos para el modelo inicial.	40
4.6. Distancias de Cook para el modelo inicial.	41
4.7. Curva ROC para el modelo inicial. Area bajo la curva: 0,7688	41
4.8. Gráfico de residuos para el modelo refinado con Stepwise.	43
4.9. Distancias de Cook para el modelo refinado con Stepwise.	43
4.10. Curva ROC para el modelo refinado con Stepwise. Area bajo la curva: 0,7678	44
4.11. Love Plot del Balance Inicial.	47
4.12. Love Plot del Emparejamiento Completo.	53
4.13. Love Plot del Balance Final.	53
4.14. Gráfico de residuos para el Modelo Balanceado.	56
4.15. Distancias de Cook para el Modelo Balanceado.	56
4.16. Curva ROC para el Modelo Balanceado. Area bajo la curva: 0,6969	57
4.17. Gráfico de residuos para el Modelo Balanceado Refinado.	58
4.18. Distancias de Cook para el Modelo Balanceado Refinado.	59
4.19. Curva ROC para el Modelo Balanceado Refinado. Area bajo la curva: 0,6846	59
4.20. Distribución de los IPW	61
4.21. Gráfico de residuos para el Modelo Ponderado.	64
4.22. Distancias de Cook para el Modelo Ponderado.	64
4.23. Curva ROC para el Modelo Ponderado. Area bajo la curva: 0,5616	65

Índice de cuadros

4.1. Primeras 6 observaciones de los datos simulados.	32
4.2. Frecuencia de la variable de exposición.	32
4.3. Resumen estadístico de la probabilidad de exposición.	33
4.4. Frecuencia de la variable Resultado.	33
4.5. Resumen de participantes divididos por Sexo y Exposición.	33
4.6. Tasa de exposición promedio según el sexo.	33
4.7. Correlaciones entre las variables seleccionadas y la exposición.	34
4.8. Correlaciones entre las covariables seleccionadas y el resultado.	34
4.9. Resumen de las variables, tipo y niveles.	36
4.10. Resultados del test de Shapiro-Wilk para las variables continuas.	37
4.11. Límites intercuartílicos para detección de outliers.	37
4.12. Matriz de correlación entre las variables numéricas.	37
4.13. Resultados de la prueba de Chi-cuadrado para las covariables categóricas. *Indica significancia estadística ($p < 0,05$).	38
4.14. Resultados de la prueba de Mann-Whitney U para las covariables numéricas. *Indica significancia estadística ($p < 0,05$).	39
4.15. Resultados significativos del modelo de regresión logística	39
4.16. Coeficientes del modelo refinado	42
4.17. Estadísticas descriptivas de los <i>Propensity Scores</i>	45
4.18. Tabla de balance inicial de las covariables.	46
4.19. Distribución del tamaño muestral tras el emparejamiento.	48
4.20. Tabla de balance tras el emparejamiento inicial con reemplazamiento.	48
4.21. Distribución del tamaño muestral tras el emparejamiento (SMD mayor a 0.1).	49
4.22. Balance de Covariables tras el Matching (SMD mayor a 0.1)	49
4.23. Distribución del tamaño muestral tras el emparejamiento (Final).	50
4.24. Balance de las covariables tras el Matching Final	51
4.25. Comparativa del balance de las covariables entre los modelos (SMD)	52
4.26. Resultados de la prueba de Chi-cuadrado para las covariables categóricas. *Indica significancia estadística ($p < 0,05$).	54
4.27. Resultados de la prueba de Mann-Whitney U para las covariables numéricas. *Indica significancia estadística ($p < 0,05$).	54
4.28. Resultados del Modelo Balanceado de regresión logística	55
4.29. Coeficientes del modelo refinado balanceado	57
4.30. Resumen estadístico de los IPW	61
4.31. Tabla de balance tras el ajuste con IPW.	62

4.32. Resultados del Modelo Ponderado	63
4.33. Resumen de Resultados con y sin Propensity Scores	66
4.34. Área Bajo la Curva (AUC) para Diferentes Modelos de Regresión	67
4.35. Comparación de ROC, Sensibilidad y Especificidad para los Diferentes Modelos	67
4.36. Comparación de balances entre modelos para Edad, Sexo, Estado Funcional y Comorbilidades	67
A.1. Tabla de frecuencias de Sexo.	76
A.2. Tabla de frecuencias de Tabaquismo.	76
A.3. Tabla de frecuencias de Nivel Socioeconómico.	76
A.4. Tabla de frecuencias de Comorbilidades.	77
A.5. Tabla de frecuencias de Cuidado de Dependientes.	77
A.6. Tabla de frecuencias de Apoyo Familiar.	77
A.7. Tabla de frecuencias de Nivel de Educación.	77
A.8. Tabla de frecuencias de Exposición.	77
A.9. Tabla de frecuencias de Resultado.	78

Capítulo 1

Introducción

1.1. Contexto y justificación del trabajo

En los estudios observacionales, una de las principales dificultades es el control de las co-variables que influyen en la asignación de tratamientos, lo que puede generar sesgos y afectar la validez de los resultados[1]. Los Propensity Scores (PS) son una metodología estadística que permite ajustar estos sesgos balanceando las covariables, ofreciendo una alternativa más robusta frente a métodos tradicionales como los modelos de regresión[2]. Esto se explica porque los modelos de regresión, en conjuntos de datos observacionales, pueden producir un tamaño de efecto sesgado de la intervención, dado que las variables independientes no han sido manipuladas de manera exógena[3].



Figura 1.1: Ventaja de los Propensity Scores. Extraída de Quantzig[4], adaptada por autor.

Por ello, este Trabajo de Fin de Máster (TFM) se centrará en evaluar cómo los PS pueden mejorar la validez de estudios observacionales mediante la simulación de datos. Además, en el contexto médico, las mujeres han sido históricamente subrepresentadas en estudios clínicos[5], lo que ha llevado a sesgos en la investigación y tratamientos menos efectivos para este grupo como por ejemplo en enfermedades cardíacas[6]. Este trabajo también tiene como objetivo demostrar cómo los PS pueden utilizarse para corregir estos sesgos de género, para obtener una investigación más inclusiva y precisa que la de los métodos tradicionales.

1.2. Descripción general

Este trabajo se enfocará en la realización de un estudio observacional utilizando datos simulados, con el objetivo de comparar los resultados obtenidos mediante PS con aquellos derivados de métodos tradicionales de análisis. Para lograrlo, se diseñarán escenarios donde covariables como el género y la edad influyan en la asignación de tratamientos. Los datos simulados se generarán a través de software como R o Python, empleando paquetes especializados para la manipulación de datos y el cálculo de PS. El objetivo principal de la simulación será representar estudios observacionales sobre la adherencia a tratamientos. Tras ello, se aplicarán diferentes enfoques de PS, como el emparejamiento (matching)[7] y la ponderación (weighting)[8] para balancear las covariables entre los grupos. Los resultados se compararán posteriormente con aquellos obtenidos mediante técnicas estadísticas tradicionales. La simulación debería permitir controlar el impacto de covariables como el género, la edad y otras características relevantes. Finalmente, se evaluará si los PS logran mejorar el balance entre los grupos de tratamiento y control, y si esta técnica puede corregir el sesgo de género en los estudios. La validación de los resultados incluirá una comparación de las características de los grupos antes y después del ajuste, además de evaluar el impacto en el sesgo de género.

1.3. Objetivos del trabajo

Objetivos generales

- Evaluar si los Propensity Scores mejoran la validez de los estudios observacionales mediante la simulación de datos y su comparación con métodos tradicionales.
- Evaluar si los Propensity Scores nos permiten ajustar los datos para que las diferencias de género no influyan en los resultados.

Objetivos específicos

- Simular datos de un estudio observacional sobre adherencia a tratamientos (grupo tratamiento y grupo control).
- Aplicar Propensity Scores para balancear/ajustar las covariables entre los grupos de tratamiento y control.
- Comparar los resultados obtenidos con los Propensity Scores frente a los obtenidos con métodos tradicionales como la regresión multivariante o lineal.
- Analizar el impacto de los Propensity Scores respecto al género y ver si estos pueden ayudar a corregir el sesgo de género en los estudios observacionales.

1.4. Impacto en sostenibilidad, ético-social y de diversidad

Siguiendo los principios de **ODS** (Objetivos de Desarrollo Sostenible 2030, ONU), encontraríamos que en este trabajo se aplicarían las dimensiones de:

Sostenibilidad: al aplicar datos simulados en este TFM, ya que se evita la necesidad de recursos adicionales para la recolección de datos reales. Por otro lado, los resultados obtenidos pueden aplicarse en el ámbito médico, mejorando la efectividad de los tratamientos y disminuyendo la utilización de recursos. Este enfoque impacta positivamente en varios ODS, como el ODS 9 (Industria, innovación e infraestructura) y el ODS 12 (Producción y consumo responsables), al promover prácticas más eficientes y sostenibles en la investigación médica.

Comportamiento Ético y Responsabilidad Social: al abordar el sesgo de género y contribuir a la generación de conocimiento aplicable a estudios con humanos, orientados a la mejora de la salud. Además, el estudio de los PS se centra en que éstos pueden mejorar la validez de los estudios observacionales, reduciendo así sesgos y proporcionando resultados más precisos y justos. Este enfoque se alinearía con los principios de responsabilidad social y ética en la investigación comentados anteriormente.

Diversidad y Derechos Humanos: al tratar el tema de subrepresentación de las mujeres en los estudios observacionales y el sesgo respecto a las diferencias de género. Al utilizar PS para corregir estos sesgos, se promueve una investigación más inclusiva y precisa. Esto contribuye al ODS 5 (Igualdad de género) y al ODS 10 (Reducción de las desigualdades), fomentando una mayor equidad en la investigación médica y en los tratamientos derivados de ella.

1.5. Enfoque y método seguido



Figura 1.2: Metodología CRISP-DM. Extraída del IIC[9]

El enfoque y la metodología a seguir va a ser la de CRISP-DM (Cross Industry Standard Process for Data Mining). Esto se debe a que esta metodología se adapta a los objetivos del proyecto y suele aplicarse en proyectos de análisis de datos, por lo que abarca todas las fases desde la comprensión del problema hasta la implementación de resultados[9]. El primer

paso sería el entendimiento del negocio, donde se estudiará el estado del arte de los PS y posteriormente la comprensión profunda de toda esta información. Después se procederá con la preparación de nuestros propios datos simulados, así como el diseño del modelo que vamos a implementar para obtener los resultados. Esto culminará en la evaluación de los resultados obtenidos y su despliegue en forma de memoria.

1.6. Planificación del trabajo

1.6.1. Tareas

1. **Revisión del estado de arte** (11/10/2024 - 20/10/2024)
Recopilar información relevante sobre el estado actual de los Propensity Scores.
2. **Planteamiento estadístico** (21/10/2024 - 3/11/2024)
Definir metodologías estadísticas, variables y materiales a utilizar.
3. **Primera revisión del tutor** (4/11/2024 - 7/11/2024)
Validar el proyecto con el tutor tras la revisión del estado de arte.
4. **Generación de datos simulados** (8/11/2024 - 28/11/2024)
Crear datos simulados que cumplimenten con los objetivos del estudio.
5. **Análisis de datos** (29/11/2024 - 7/12/2024)
Aplicar Propensity Scores y otros métodos para analizar los datos simulados.
6. **Segunda revisión del tutor** (8/12/2024 - 14/12/2024)
Revisar el análisis estadístico y la simulación de datos con el tutor.
7. **Análisis de resultados** (15/12/2024 - 18/12/2024)
Evaluar los resultados y comparar la efectividad de los Propensity Scores.
8. **Comparación de resultados** (19/12/2024 - 23/12/2024)
Realizar una comparación detallada de los resultados obtenidos.
9. **Redacción de la memoria final** (26/12/2024 - 2/01/2025)
Documentar el proceso, resultados y conclusiones del trabajo.
10. **Revisión final del tutor** (3/01/2025 - 7/01/2025)
Revisar y ajustar la memoria con el tutor.
11. **Revisión final del autor** (8/01/2025 - 12/01/2025)
Realizar los últimos cambios en la memoria.
12. **Elaboración de la presentación (diapositivas y video)** (13/01/2025 - 16/01/2025)
Preparar el material para la defensa pública.

13. Ensayo defensa pública (17/01/2025 - 20/01/2025)

Practicar la presentación y defensa del trabajo.

Cambios en la planificación de las tareas

A lo largo del semestre se han modificado el tiempo de las tareas debido a imprevistos que se han ido informando en las entregas de evaluación continua. Estos cambios incluyen:

- **Revisión del estado de arte**
Fecha original: 11/10/2024 - 20/10/2024
Nueva fecha: 11/10/2024 - 15/11/2024
- **Planteamiento estadístico**
Fecha original: 21/10/2024 - 3/11/2024
Nueva fecha: 16/11/2024 - 28/11/2024
- **Primera revisión del tutor**
Fecha original: 4/11/2024 - 7/11/2024
Nueva fecha: 29/11/2024 - 30/11/2024
- **Análisis de datos**
Fecha original: 29/11/2024 - 7/12/2024
Primer cambio: 1/12/2024 - 7/12/2024
Segundo cambio: 14/12/2024 - 18/12/2024
- **Análisis de resultados**
Fecha original: 15/12/2024 - 18/12/2024
Nueva fecha: 14/12/2024 - 18/12/2024
- **Elaboración de la presentación**
Fecha original: 13/01/2025 - 16/01/2025
Nueva fecha: 12/01/2025 - 14/01/2025

1.6.2. Calendario




Figura 1.3: Diagrama de Gantt (Original).




Figura 1.4: Diagrama de Gantt (Con Cambios Incluidos).

1.6.3. Hitos

1. **PEC 1:** Plan de trabajo (10/10/2024)
2. **PEC 2:** Desarrollo y seguimiento del proyecto. Fase 1 (07/11/2024)
3. **PEC 3:** Desarrollo y seguimiento del proyecto. Fase 2 (11/12/2024)
4. **PEC 4:** Cierre de la memoria y entrega final (14/01/2025)
5. **PEC 5:** Defensa pública del trabajo (21/01/2025)

1.7. Análisis de riesgos

Tras realizar un análisis de riesgos potenciales podemos ver que, en cuanto al **alcance del proyecto**, los cambios de requisitos a lo largo del trabajo pueden desviar el enfoque y afectar la calidad de los resultados. Para mitigar esto, se mantendrá una comunicación constante con la tutora y se documentarán los cambios. Respecto al **tiempo de disposición**, la sobrecarga de trabajo puede llevar a retrasos y afectar la calidad del trabajo. Se establecerá un cronograma realista y se reservará tiempo para imprevistos. Por otro lado, dentro de la metodología de datos del trabajo, encontramos que la simulación de datos puede alejarnos de la **validez externa**, por lo que se validarán los datos simulados mediante comparaciones con datos reales y análisis de sensibilidad. Por último, tener en cuenta que existen **limitaciones metodológicas** propias de los Propensity Scores, como no poder ajustar a todos los individuos. Esto puede producir sesgos que se intentarán mitigar con técnicas complementarias documentación.

1.8. Breve resumen de productos obtenidos

- **Memoria:** Memoria final del trabajo, que documenta todo el proceso, los análisis realizados, los resultados obtenidos y las conclusiones.
- **Datos Simulados Disponibles para Replicación:** Un conjunto de datos simulados que están disponibles para replicación y validación por otros investigadores.
- **Análisis de Datos:** Junto al conjunto de datos simulados, se añade también todo el análisis estadístico realizado para la obtención de los resultados.
- **Presentación Virtual:** Una presentación virtual, que incluye diapositivas y un video explicativo, preparada para la defensa pública del trabajo ante un tribunal.

1.9. Breve descripción de los otros capítulos de la memoria

A continuación, se presenta un resumen de los contenidos de cada capítulo y su relación con el proyecto global:

- **Introducción y Estado del Arte**

En este capítulo se contextualiza el trabajo, exponiendo los objetivos principales, la relevancia del uso de Propensity Scores en estudios observacionales y el enfoque en el sesgo de género en la adherencia a tratamientos médicos. Además, se revisa la literatura existente sobre Propensity Scores y metodologías relacionadas, abordando su aplicación en estudios observacionales y las implicaciones éticas y científicas del sesgo de género en la investigación médica.

- **Metodología**

Se detalla el diseño del estudio, la generación de datos simulados y el análisis de Propensity Scores como de métodos tradicionales.

- **Resultados**

Se presentan los hallazgos obtenidos a partir de los datos simulados y las pruebas estadísticas aplicadas, tanto de métodos tradicionales como de Propensity Scores.

- **Discusión y Conclusiones**

Este capítulo analiza los resultados en relación con los objetivos planteados, identificando fortalezas, limitaciones y oportunidades de mejora en el uso de Propensity Scores para reducir el sesgo frente a otros métodos estadísticos.

- **Anexos**

Incluye toda la información estadística y de código utilizada para la realización del trabajo.

- **Bibliografía**

Contiene la lista de referencias utilizadas en el desarrollo de la memoria, gestionadas con Zotero y compiladas en formato BibTeX.

Capítulo 2

Estado del arte

2.1. Contextualización

Los estudios observacionales son aquellos en los que el investigador no ejerce manipulación ni en las variables independientes ni dependientes, por lo que tal y como indica su nombre, tan solo observa[10]. Esta falta de control, aunque a veces pueda ser una ventaja, por ejemplo permitiendo que los resultados tengan mayor validez externa, es en muchos casos también una desventaja. Existen diversas limitaciones en estos estudios como la incapacidad de establecer relaciones causales directas debido a la presencia de variables confusoras y otros sesgos potenciales[11].

Algunos de los sesgos más comunes de los estudios observacionales son los de memoria (defectos en la medición de variables), confusión (una variable y su resultado es afectado por otro factor desconocido) o selección (relacionados con la selección de los participantes)[12]. No obstante, este tipo de estudios siguen siendo de vital importancia para la salud pública donde los ensayos aleatorizados no siempre son factibles o éticos, especialmente en intervenciones a gran escala, urgentes o con datos poblacionales; así como cuando se necesita evaluar intervenciones que ya están en marcha, como en estudios de farmacovigilancia o medidas regulatorias[13].

Tanto el valor de los estudios observacionales como sus desventajas llevan a la investigación a buscar soluciones que mejoren la validez interna de estos. Esta búsqueda de mayor fiabilidad ha impulsado el desarrollo de métodos estadísticos como los Propensity Scores (PS), diseñados específicamente para equilibrar las características de los grupos comparados y reducir el impacto de variables confusoras[2].

2.2. Propensity Scores: Fundamentos Teóricos

2.2.1. ¿Qué son?

Los Propensity Scores son una técnica estadística utilizada para reducir los efectos de confusión y sesgos en estudios observacionales formulada por Rosenbaum y Rubin en 1983[14]. La confusión ocurre cuando una variable extrínseca influye tanto en la exposición como en el resultado, distorsionando la verdadera relación entre ellos. Los PS se definen como la probabilidad de que un individuo reciba un tratamiento determinado, dada una serie de covariables

observadas[15].

Por esta razón, el propósito principal de los Propensity Scores es crear grupos comparables entre aquellos que reciben el tratamiento y los que no, balanceando las covariables y minimizando el sesgo[16].

2.2.2. ¿Cómo funcionan?

Esto se logra a través de varios métodos como el emparejamiento, la ponderación y la estratificación, permitiendo una estimación más precisa del efecto causal del tratamiento en estudios donde los ensayos aleatorios no son factibles[17].

En el caso del **Emparejamiento (Matching)**: se seleccionan grupos de individuos tanto del grupo experimental (tratados) y del control, con la condición de que sean similares en base a sus características observadas, minimizando así el sesgo en la estimación del efecto del tratamiento. De esta manera se estaría intentando acercar el método al de un experimento aleatorio[18].

Por otro lado, la **Ponderación (Weighting)**: consiste en asignar pesos a los individuos en función de su probabilidad de recibir el tratamiento, permitiendo que todos los sujetos contribuyan al análisis, incluso aquellos que no han sido posibles de emparejar mediante el matching[19].

Y la **Estratificación (Stratification)**: se centra en usar los PS para dividir a los sujetos en grupos o estratos, de manera que los individuos dentro de cada estrato sean comparables en términos de las covariables observadas donde cada estrato actúa como un subconjunto homogéneo respecto al riesgo de recibir el tratamiento, permitiendo estimar el efecto causal dentro de cada grupo. Posteriormente, estos efectos se combinan para obtener una estimación global ajustada[20].

2.2.3. Comparación con métodos tradicionales

Si comparamos los PS con otros métodos tradicionales como los modelos de regresión veríamos que los modelos de regresión ajustan directamente el efecto del tratamiento incluyendo covariables como predictores, mientras que los PS transforman el análisis en un problema de balanceo, igualando las distribuciones de covariables entre los grupos de tratamiento y control para así reducir el sesgo antes de realizar cualquier análisis causal, separando el diseño del análisis estadístico[21].

Por otro lado, los PS se centran en estimar efectos marginales (por ejemplo, el efecto promedio en la población) y los modelos de regresión suelen estimar efectos condicionales (el efecto promedio en individuos con ciertas características específicas). Además, los PS permiten la separación entre el diseño y el análisis del estudio. Al construir un modelo de PS, se pueden balancear las covariables entre los grupos de tratamiento y control antes de analizar el efecto del tratamiento sobre el resultado. Esto reduce el riesgo de ajustar el modelo de forma subjetiva en función de los resultados observados, algo que puede ocurrir con los modelos de regresión si se modifican iterativamente para ajustar los datos[15].

Sin embargo, la elección entre PS y regresión debe considerar tanto las características del estudio como los objetivos específicos de la investigación ya que la correcta implementación de los Propensity Scores (PS) es crucial para lograr mejores resultados en comparación con

métodos tradicionales como la regresión[22]. Además, aunque se presente mejoría al utilizar PS, la eficacia de estos depende también de la presencia de un diseño sólido del estudio y de la precisión de los datos, por lo que no corrigen fallos metodológicos ni inexactitudes en la recolección de información[23].

2.2.4. Aplicaciones prácticas

Los PS pueden ser una herramienta poderosa en contextos médicos y epidemiológicos. Recientemente, durante la pandemia de COVID-19, los Propensity Scores se utilizaron para evaluar la efectividad de diversos tratamientos en estudios observacionales[24]. También se utilizaron los PS para la valoración de efectividad de la Vacuna contra la Influenza recientemente en Australia[25].

Respecto a la investigación médica, los PS pueden equilibrar los perfiles de riesgo entre hombres y mujeres, ayudando a mitigar el sesgo de género en los estudios clínicos[26, 27]. Y también han mostrado ser efectivos para mitigar el sesgo de selección de los investigadores en el contexto de encuestas en línea[28]. Asimismo, como en investigaciones sobre intervención temprana, donde el uso de PS ha sido una técnica valiosa para reducir el sesgo de selección en estudios longitudinales y evaluar relaciones causales plausibles[29].

Por otro lado, los PS pueden ser útiles también para ajustar correlaciones en clusters pre-existentes en sistemas de salud[30]. Es por ello que la aplicación adecuada de los PS permite obtener estimaciones más precisas y confiables, contribuyendo significativamente a la toma de decisiones basadas en evidencia en contextos donde los ensayos aleatorizados no son viables.

2.3. Propensity Scores y Simulación de datos

Simular datos en investigación ofrece ventajas significativas en términos de tiempo y coste. A través de la creación de conjuntos de datos hipotéticos, los investigadores pueden explorar una variedad de escenarios y prever resultados sin necesidad de recopilar grandes volúmenes de datos reales. Un ejemplo de su utilidad se observa en el estudio de Groenwold et al. (2011), quienes utilizaron datos simulados para abordar el problema de datos faltantes en estudios tanto aleatorizados como observacionales, comparando diferentes métodos de imputación para evaluar su rendimiento[31].

El uso de simulaciones en los Propensity Scores tampoco es una novedad, habiéndose utilizado para evaluar riesgos de seguridad relacionados con la exposición a fármacos. Esto es lo que se realizó en parte en Ryan y Schuemie (2013), quienes diseñaron y evaluaron un marco probabilístico para generar datos observacionales simulados en el ámbito de la atención sanitaria. A través de estos datos, se evaluó el rendimiento de varios métodos para identificar asociaciones entre la exposición a fármacos y los resultados de salud, lo que demostró la utilidad de las simulaciones para validar enfoques estadísticos en contextos complejos[32].

Además, la simulación también se ha utilizado para generar marcos de evaluación que incluyen tanto datos simulados como reales para comparar diferentes enfoques de Propensity Score, demostrando su utilidad para contrastar metodologías en escenarios variados[33]. En Setoguchi et al. (2008) se compararon modelos de Propensity Scores (PS) basados en técnicas como regresión logística, particionamiento recursivo y redes neuronales. Simularon cohortes con

diferentes asociaciones no lineales y no aditivas entre exposición y covariables. Esto subraya cómo los datos simulados permiten analizar la eficacia de modelos avanzados en comparación con enfoques más tradicionales[34].

Por último, se ha investigado con datos simulados cómo las características del conjunto de datos (tamaño, prevalencia de exposición y desequilibrio en los PS) afectan al desempeño relativo de los PS frente a métodos tradicionales, como la regresión múltiple, en distintos escenarios. Estos estudios subrayan que la elección del método depende en gran medida del contexto y las características de los datos[35].

2.4. Sesgo de género

La mayoría de las investigaciones, incluso en temas de salud, se realizan con muestras mayoritariamente masculinas[36]. Este es un sesgo que se ha ido arrastrando durante décadas, convirtiendo así el género en un factor condicionante que puede afectar al acceso y a la calidad de la atención médica[37, 38, 39, 5].

Tal y como explicó Rubin (1984), los PS pueden extenderse para considerar interacciones complejas entre género y otros factores de confusión, lo cual respaldaría análisis más inclusivos[40]. En el debate de Guo et al., (2020) se subraya la posibilidad de personalizar modelos de PS para capturar interacciones complejas, como aquellas entre género y otros factores sociodemográficos[41].

Un ejemplo que ilustra este potencial es el uso de PS para corregir sesgos de género en estudios como el de Wikipedia Gender Gap. En este caso, los PS permitieron ajustar discrepancias en la tasa de respuesta de encuestas, logrando recalcular la proporción de mujeres editoras y reflejando una participación significativamente mayor a la estimada originalmente[42].

2.5. Objetivos e hipótesis

Por lo especificado, el objetivo principal de este trabajo es evaluar la efectividad de los Propensity Scores (PS) en la mejora de la validez de estudios observacionales, especialmente para mitigar el sesgo de género en la adherencia a tratamientos médicos.

Hipótesis:

- Los PS mejoran la validez interna de los estudios observacionales
- La implementación de PS puede reducir el sesgo de género en los estudios observacionales simulados

Capítulo 3

Materiales y Métodos

3.1. Diseño Experimental

Se simuló un diseño observacional de cohortes de adherencia al tratamiento para modelar la relación entre la exposición a un tratamiento (X) y un resultado (Y). Además, se indujo un sesgo explícito en la probabilidad de tratamiento, de manera que las mujeres tuvieron una menor probabilidad de ser tratadas. Este diseño permitió analizar tanto el impacto de los Propensity Scores en comparación con métodos tradicionales para mitigar el sesgo de género, como su efectividad para mejorar la validez interna de los estudios observacionales.

3.2. Materiales

- **Software:** RStudio 2024.09.1+394 y paquetes derivados (`simstudy`, `dplyr`, `ggplot2`, `reshape2`, `knitr`, `truncnorm`, `skimr`, `stats`, `caret`, `pROC`, `cobalt`, `tableone`, `MatchIt`, `Survey`)
- **Herramientas:** Visual Code Studio con LaTeX implementado para la redacción de la memoria del TFM, Zotero para la gestión bibliográfica.

3.3. Simulación de Datos

3.3.1. Distribuciones y Semillas

Se utilizaron distribuciones estadísticamente realistas para modelar las covariables. El uso de semillas se documentó en el código para asegurar la reproducibilidad exacta de los resultados.

3.3.2. Variables Simuladas

- **Exposición (X):** Variable binaria (0 = no tratado, 1 = tratado), cuya probabilidad se obtuvo mediante una función logística basada en las covariables (C).
- **Covariables (C):**

- **Sexo:** Variable binaria (0 = Mujer, 1 = Hombre), con un sesgo inducido que disminuye la probabilidad de tratamiento en mujeres ($B_{\text{Sexo}} = -0,7$).
 - **Edad:** Variable continua distribuida normalmente con una media de 50 años, y truncada para excluir valores menores de 18 años.
 - **Tabaquismo:** Variable binaria (0 = No, 1 = Sí).
 - **Nivel socioeconómico:** Variable ordinal (Bajo/Medio/Alto).
 - **Estado funcional:** Variable continua (escala 0-100).
 - **Comorbilidades:** Variable numérica (0-5).
 - **Cuidado de dependientes:** Variable binaria (0 = No, 1 = Sí).
 - **Apoyo familiar:** Variable ordinal (Bajo/Medio/Alto).
 - **Nivel de educación:** Variable ordinal (Básico/Intermedio/Avanzado).
- **Resultado (Y):** Variable binaria (0 = no mejora, 1 = mejora), cuya probabilidad de mejora se modeló usando una función logística basada en la exposición (X) y las covariables (C).

3.3.3. Parámetros de las Covariables

- **Sexo:**
 - Distribución: Binaria.
 - Parámetros: $P(\text{Hombre}) = 0,5$, $P(\text{Mujer}) = 0,5$.
 - Coeficiente en la fórmula logística (X): 0,4.
 - Coeficiente en la fórmula logística (Y): $-0,1$.
- **Edad:**
 - Distribución: Normal truncada.
 - Parámetros: $M(50)$, truncada en 18.
 - Coeficiente en la fórmula logística (X): 0,03.
 - Coeficiente en la fórmula logística (Y): $-0,04$.
- **Tabaquismo:**
 - Distribución: Binaria.
 - Parámetros: $P(\text{Sí}) = 0,3$, $P(\text{No}) = 0,7$.
 - Coeficiente en la fórmula logística (X): $-0,05$.
 - Coeficiente en la fórmula logística (Y): $-0,08$.
- **Nivel socioeconómico:**
 - Distribución: Ordinal.

- Parámetros: $P(\text{Bajo}) = 0,3$, $P(\text{Medio}) = 0,5$, $P(\text{Alto}) = 0,2$.
- Coeficiente en la fórmula logística (X): 0,01.
- Coeficiente en la fórmula logística (Y): 0,05.
- **Estado funcional:**
 - Distribución: Uniforme.
 - Parámetros: $U(0, 100)$.
 - Coeficiente en la fórmula logística (X): 0,03.
 - Coeficiente en la fórmula logística (Y): 0,1.
- **Comorbilidades:**
 - Distribución: Poisson.
 - Parámetros: $\lambda = 2$ (media de 2 comorbilidades por paciente).
 - Coeficiente en la fórmula logística (X): -0,08.
 - Coeficiente en la fórmula logística (Y): -0,1.
- **Cuidado de dependientes:**
 - Distribución: Binaria.
 - Parámetros: $P(\text{Sí}) = 0,2$, $P(\text{No}) = 0,8$.
 - Coeficiente en la fórmula logística (X): -0,02.
 - Coeficiente en la fórmula logística (Y): -0,02.
- **Apoyo familiar:**
 - Distribución: Ordinal.
 - Parámetros: $P(\text{Bajo}) = 0,3$, $P(\text{Medio}) = 0,5$, $P(\text{Alto}) = 0,2$.
 - Coeficiente en la fórmula logística (X): 0,03.
 - Coeficiente en la fórmula logística (Y): 0,05.
- **Nivel de educación:**
 - Distribución: Ordinal.
 - Parámetros: $P(\text{Básico}) = 0,2$, $P(\text{Intermedio}) = 0,4$, $P(\text{Avanzado}) = 0,4$.
 - Coeficiente en la fórmula logística (X): 0,02.
 - Coeficiente en la fórmula logística (Y): 0,07.

3.3.4. Fórmulas Logísticas

Para modelar la probabilidad de exposición (X) y calcular los log-odds para el resultado (Y), se utilizaron las siguientes fórmulas:

Función de Exposición (X)

prob. de Exposición (X) = $\beta_0 + \beta_1 \cdot \text{sexo} + \beta_2 \cdot \text{edad} + \beta_3 \cdot \text{tabaquismo} + \beta_4 \cdot \text{comorbilidades}$
 $+ \beta_5 \cdot \text{estado funcional} + \beta_6 \cdot \text{nivel socioeconómico} + \beta_7 \cdot \text{cuidado depen.}$
 $+ \beta_8 \cdot \text{apoyo familiar} + \beta_9 \cdot \text{nivel de educación}$

Función del Resultado (Y)

log-odds del Resultado (Y) = $\gamma_0 + \gamma_1 \cdot \text{sexo} + \gamma_2 \cdot \text{edad} + \gamma_3 \cdot \text{tabaquismo} + \gamma_4 \cdot \text{comorbilidades}$
 $+ \gamma_5 \cdot \text{estado funcional} + \gamma_6 \cdot \text{nivel socioeconómico} + \gamma_7 \cdot \text{cuidado depen.}$
 $+ \gamma_8 \cdot \text{apoyo familiar} + \gamma_9 \cdot \text{nivel de educación} + \gamma_{10} \cdot \text{exposición}$

3.3.5. Justificación de las variables seleccionadas

Las variables seleccionadas para este estudio se basaron en su relevancia en estudios observacionales y su potencial impacto en la adherencia a tratamientos y resultados de salud. A continuación, se detalló la justificación para cada variable y los parámetros utilizados:

- **Sexo:** Al establecer una probabilidad equitativa de que el individuo sea hombre o mujer, podemos observar cómo, incluso en un escenario con igualdad de exposición, los resultados pueden seguir presentando sesgos debido a otros factores no controlados. Este enfoque permite evaluar la eficacia de los PS para mitigar sesgos relacionados con el género. El coeficiente positivo en la formula logística indica que los hombres (sexo = 1) tienen una mayor probabilidad de recibir el tratamiento en comparación con las mujeres (sexo = 0), de esta manera se indujo el sesgo en la simulación. Por otro lado, el coeficiente negativo presente en la formula del resultado indica que los hombres tienen una ligera menor probabilidad de mejorar.
- **Edad:** Se ha seleccionado como edad media los 50 años, con una desviación típica de 15 años, para tener diferentes rangos de edad de personas adultas (mayores de 18). Se ha establecido que la edad tenga un coeficiente positivo en la fórmula logística, ya que a más edad más propenso es uno a recibir tratamientos medicos. Sin embargo, en la formula del resultado, el coeficiente negativo indica que a más edad uno tiene una menor probabilidad de mejorar.
- **Tabaquismo:** Basado en datos globales[43], es razonable asumir que aproximadamente el 30 por ciento de la población fuma. Esta variable es importante dado su impacto conocido en la salud y la adherencia a tratamientos. Se ha establecido un coeficiente negativo debido a que fumar se correlaciona con peores resultados de adherencia al tratamiento[44, 45].
- **Nivel Socioeconómico:** La mayoría de la población suele encontrarse en el nivel socioeconómico medio. En estudios observacionales, los participantes de nivel bajo son más comunes que los de nivel alto, quienes tienen más recursos y, posiblemente, menos necesidad

de participar en estudios de adherencia a tratamientos. Sin embargo, se ha establecido un coeficiente positivo ya que se indica que los pacientes con un mayor nivel socioeconómico tienen una mayor probabilidad de recibir[46, 47].

- **Estado Funcional:** Entendiéndose éste como la capacidad para realizar actividades diarias el nivel de independencia física y mental de una persona. Se ha seleccionado un coeficiente positivo ya que los pacientes con un mejor estado funcional tienen una mayor probabilidad de recibir el tratamiento y mantenerse en él.
- **Comorbilidades:** Se ha colocado una media de 2 comorbilidades, ya que los individuos con patologías médicas suelen desarrollar otras que están de alguna manera interrelacionadas con la principal. Esta variable es importante ya que las comorbilidades influyen significativamente en la adherencia y en los resultados de salud. Es por ello que se establece un coeficiente negativo ya que a medida que aumenta el número de comorbilidades, disminuye la probabilidad de recibir el tratamiento.
- **Cuidado de Dependientes:** Suele ser un factor que representa la cantidad de tiempo libre y responsabilidades que posee un individuo. En este caso, se ha establecido un coeficiente negativo.
- **Apoyo Familiar:** Un coeficiente positivo indica que los pacientes con mayor apoyo familiar tienen una mayor probabilidad de recibir tratamiento[48].
- **Nivel de Educación:** Similar a las variables anteriores, el nivel de educación es un factor sociodemográfico relevante que puede influir en la adherencia a tratamientos. Se ha categorizado en niveles básico, intermedio y avanzado siguiendo los datos de eurostat (2025)[49]. Se ha establecido un coeficiente positivo ya que mayor conocimientos sobre medicina suele mejorar la adherencia al tratamiento[50].

3.3.6. Diseño y Método

El diseño incluyó un total de 1000 participantes, con las variables definidas anteriormente. Después, se realizaron análisis descriptivos, cálculo de correlaciones y visualizaciones gráficas para evaluar la calidad de los datos obtenidos.

Para todo ello se utilizó R. Se usó el paquete `simstudy` para definir las variables. Cada variable fue asignada a su distribución específica. La edad fue generada usando una distribución normal truncada para restringir valores por debajo de los 18 años.

Cálculo de Probabilidades de Exposición y Resultado

A partir de las covariables generadas, se modeló la probabilidad de exposición mediante la función `plogis`, incorporando coeficientes asignados a cada variable según su influencia teórica. Para el resultado, se aplicó un modelo similar ajustando los coeficientes y añadiendo el efecto directo de la exposición.

Las probabilidades calculadas para la exposición y el resultado se usaron para generar variables binarias (1 = expuesto/mejora; 0 = no expuesto/no mejora) mediante la función `rbinom`.

Exploración y Análisis Descriptivo

Se emplearon funciones del paquete `dplyr` para resumir y agrupar datos, como tasas de exposición por sexo y descripciones generales de las variables simuladas.

Los resultados fueron visualizados mediante gráficos de densidad y mapas de calor usando `ggplot2`.

3.4. Análisis de Datos

3.4.1. Métodos Tradicionales: Regresión Logística

Se empleó la regresión logística, sin balance de PS, como método tradicional para evaluar la relación entre las covariables y el resultado de exposición.

Importación y Exploración de los Datos

- **Importación:** Se cargaron datos simulados desde un archivo `.rds`, generados previamente en la etapa de simulación.
- **Exploración inicial:** Se verificó la estructura del dataframe (`class`, `str`) y se utilizó el paquete `skimr` para obtener un resumen general. Además, se generaron tablas de frecuencia para variables categóricas como `sexo`, `tabaquismo`, etc., permitiendo visualizar su distribución.

Transformación de Variables

Se duplicó el dataframe original y se convirtió una serie de variables en factores para facilitar el análisis. Entre ellas, `sexo`, `tabaquismo`, `nivel_socioeconomico` y `resultado`.

Análisis Preliminar de los Datos

1. Pruebas de Normalidad y Outliers:

- Se utilizó el test de Shapiro-Wilk para evaluar la normalidad de las variables numéricas.
- Se identificaron posibles outliers mediante el método IQR.

2. Visualización de Datos:

- Se emplearon gráficos de barras para variables categóricas y gráficos de densidad e histogramas para variables numéricas. Los boxplots se utilizaron para identificar patrones y variabilidad.

Evaluación de Relaciones entre Covariables

- Se analizó la relación entre covariables y el **Resultado** (Y), así como con **Exposición** (X) mediante:
 - **Gráficos de barras y boxplots**
 - **Pruebas estadísticas:**
 - Chi-cuadrado para evaluar asociaciones entre variables categóricas.
 - Mann-Whitney U para comparar variables numéricas entre niveles de exposición.
- **Matriz de correlación:** Se evaluaron relaciones entre variables numéricas para identificar posibles problemas de multicolinealidad.

Análisis de Regresión Logística: Modelo Inicial

Se ajustó un modelo de regresión logística considerando todas las covariables (edad, sexo, estado funcional, etc.) para predecir la exposición al que se le denominó **Modelo Inicial**. Se utilizó la función `glm` con familia binomial, obteniendo coeficientes y significancia estadística para cada variable.

Posteriormente, se evaluó el ajuste del modelo inicial mediante un análisis de residuos, distancias de Cook y una curva ROC.

Refinamiento del Modelo con Stepwise

Se aplicó un procedimiento de selección de variables stepwise, con dirección bidireccional, para simplificar el modelo inicial y excluir aquellas variables que no contribuían significativamente al ajuste. Este proceso fue realizado utilizando la función `step` en R y se le denominó **Modelo Refinado**.

El modelo refinado fue entonces validado utilizando los mismos procedimientos que el modelo inicial, incluyendo análisis de residuos, distancias de Cook y curva ROC.

Además, para evaluar la capacidad predictiva y la generalización del modelo refinado, se realizó una **validación cruzada con 10 pliegues**. La validación cruzada fue implementada con la función `train` del paquete `caret` en R, configurando un control de entrenamiento con probabilidades de clase y un resumen de las métricas de desempeño.

3.4.2. Propensity Scores: Emparejamiento

Generación de Propensity Scores

Se estableció una semilla aleatoria para garantizar la reproducibilidad de los resultados. A continuación, se copiaron los datos transformados para trabajar con ellos de manera independiente. Los Propensity Scores se calcularon utilizando el modelo inicial previamente ajustado, aplicando la predicción de la probabilidad de pertenecer al grupo de tratamiento para cada individuo. Para analizar la dispersión de los Propensity Scores, se calculó la desviación estándar de los mismos.

Evaluación del Balance Inicial

Para evaluar el balance entre los grupos de tratamiento y control antes de aplicar el ajuste de Propensity Scores, se utilizó la función `CreateTableOne` para generar una tabla de balance, que muestra las diferencias de medias estandarizadas (SMD) de cada covariable entre los dos grupos. Para complementar la tabla de balance, se generó un LovePlot para visualizar las diferencias de medias estandarizadas entre las covariables de los grupos de tratamiento y control. El umbral de diferencia de medias fue fijado en 0,1.

Matching (Emparejamiento) de las variables

Para el Matching se realizaron tres modelos diferentes que incluían diferentes variables a balancear dependiendo de los resultados obtenidos en la tabla de balance inicial.

Emparejamiento Inicial con Reemplazo

Se realizó un emparejamiento utilizando el método de vecino más cercano (nearest neighbor matching) con reemplazo, aplicando solo las tres covariables más desbalanceadas: sexo, edad y estado funcional. Se evaluó el balance mediante el cálculo de las SMD de nuevo.

Emparejamiento con Reemplazo de las Variables con SMD mayor a 0.1

Se incluyeron todas las covariables cuyo SMD fue superior a 0.1, lo que permitió un ajuste más agresivo. Se evaluó nuevamente el balance entre los grupos de tratamiento y control mediante la tabla de balance.

Emparejamiento Final con Sexo, Edad, Estado Funcional y Comorbilidades

Como último paso, se realizó un emparejamiento considerando las covariables sexo, edad, estado funcional y comorbilidades. Se evaluó de nuevo el balance según el SMD de las covariables.

Comparativa de los Modelos de Emparejamiento

Finalmente, se realizó una comparativa de los resultados de los cuatro modelos de emparejamiento (modelo original, emparejamiento con reemplazo, emparejamiento con todas las variables, y emparejamiento final con comorbilidades). Se decidió continuar trabajando con el **modelo de emparejamiento final con comorbilidades**. Se realizó entonces un Love Plot con las diferencias de las variables ajustadas y antes del ajuste.

3.4.3. Regresión Logística con PS: Emparejamiento

Se utilizó el conjunto de datos balanceado que incluía Sexo, Edad, Estado Funcional y Comorbilidades como se ha mencionado anteriormente. A partir de este conjunto de datos, se ajustó un modelo de regresión logística utilizando la función `glm` para evaluar las probabilidades de exposición en función de todas las covariables.

Evaluación del Modelo Balanceado

Se obtuvieron los coeficientes del modelo, así como los Odds Ratios (OR) y sus intervalos de confianza. Se generaron gráficos de residuos, distancias de Cook y la curva ROC.

Refinamiento del Modelo con Stepwise

Se aplicó el procedimiento Stepwise de la misma manera que se hizo durante el análisis con métodos tradicionales. Se obtuvieron los coeficientes del modelo refinado, junto con los Odds Ratios (OR) y sus intervalos de confianza. Así como sus gráficos de residuos, distancias de Cook y la curva ROC. Por último, se realizó una validación cruzada con 10 pliegues.

3.4.4. Propensity Scores: Ponderación

Cálculo de Pesos Inversos de Probabilidad de Tratamiento (IPW)

Se calcularon pesos inversos de probabilidad de tratamiento (IPW) basados en los propensity scores previamente estimados. Los pesos se asignaron de la siguiente manera:

$$peso_{ipw} = \begin{cases} \frac{1}{P(\text{exposición})} & \text{si el individuo está expuesto} \\ \frac{1}{1-P(\text{exposición})} & \text{si el individuo no está expuesto} \end{cases}$$

Se visualizó la distribución de estos pesos mediante un histograma.

Evaluación del Balance con Ponderación

El balance de las covariables después de aplicar la ponderación IPW fue evaluado utilizando el paquete `survey` en R. Se creó un diseño ponderado que permitió calcular una tabla de balance (*Table One*) para comparar la distribución de las covariables entre los grupos expuesto y no expuesto. Se reportaron las diferencias estandarizadas de medias (SMD).

3.4.5. Regresión Logística con PS: Ponderación

Para evaluar la asociación entre las covariables y la exposición después de aplicar los pesos IPW, se ajustó un modelo de regresión logística ponderado. Este modelo incluyó las mismas variables independientes consideradas en el modelo inicial. El ajuste del modelo fue evaluado mediante el análisis de residuos, distancias de Cook y la curva ROC. Además, se volvió a implementar una validación cruzada con 10 pliegues para evaluar la capacidad predictiva del modelo ponderado y su generalización a nuevos datos. Se definió una función personalizada para entrenar el modelo con los pesos IPW, y el desempeño se evaluó mediante la métrica del área bajo la curva (AUC) de la curva ROC. La validación cruzada fue configurada utilizando el paquete `caret` en R.

Capítulo 4

Resultados

Todos los resultados, gráficos extra y así como su código están presentados al completo en los Anexos A.2 y A.3

4.1. Simulación de Datos: Adherencia al Tratamiento

Se generaron datos simulados para 1000 observaciones, cada una correspondiente a un individuo. Las variables incluyen las características sociodemográficas y clínicas ya mencionadas así como las probabilidades y resultados de las variables **Exposición (X)** y **Resultado (Y)**. Un ejemplo de las primeras 6 observaciones de los datos simulados se muestra en la tabla 4.1.

id	sexo	tabaco	n._socio	funcional	comorb	c._depen	ap._familiar	n._educ	edad	p._expo	expo	log_odds_Y	prob._Y	resul (Y)
1	1	0	3	47.79	1	0	1	3	51	0.803	0	0.949	0.721	0
2	0	0	2	51.77	0	0	1	1	52	0.766	1	1.817	0.860	1
3	0	1	2	20.19	4	0	2	1	27	0.299	1	-0.771	0.316	1
4	1	0	2	89.86	3	1	3	1	60	0.941	1	4.986	0.993	1
5	0	1	2	34.01	1	0	2	3	70	0.756	1	-0.669	0.339	0
6	1	0	2	40.11	3	0	2	3	63	0.801	1	0.001	0.500	1

Cuadro 4.1: Primeras 6 observaciones de los datos simulados.

Tras el uso de las formulas logísticas, como puede observarse en la tabla 4.2, 707 participantes (70.7 %) estuvieron expuestos al tratamiento, mientras que 293 (29.3 %) no lo estuvieron.

Exposición (X)	Frecuencia
No	293
Sí	707

Cuadro 4.2: Frecuencia de la variable de exposición.

Un resumen estadístico de la variable **Prob. Exposición** puede encontrarse en la tabla 4.3. Observamos que la probabilidad media de exposición es 0.7207, indicando que, en promedio, los participantes tienen alta probabilidad de ser tratados. La mediana (0.7578) y el rango intercuartil (0.5944-0.8692) confirman que más del 50 % tienen alta probabilidad de exposición,

mientras que el rango completo (0.2012-0.9754) evidencia una variabilidad significativa, lo cual indica que el modelo simulado es apropiado.

	Mínimo	1er Cuartil	Mediana	Media	3er Cuartil	Máximo
Prob. Exposición	0.2012	0.5944	0.7578	0.7207	0.8692	0.9754

Cuadro 4.3: Resumen estadístico de la probabilidad de exposición.

Respecto al resultado expuesto en la tabla 4.4, 376 individuos mejoraron su salud tras la finalización del estudio simulado, mientras que 624 no lo hicieron.

Resultado (Y)	Frecuencia
No mejora	376
Sí mejora	624

Cuadro 4.4: Frecuencia de la variable Resultado.

En cuanto al sesgo de género, la tabla 4.5 muestra los participantes que han sido expuestos al tratamiento y los que no, separando por sexo.

Sexo	Exposición	Número de participantes (n)
Mujer	No	166
Mujer	Sí	333
Hombre	No	127
Hombre	Sí	374

Cuadro 4.5: Resumen de participantes divididos por Sexo y Exposición.

Si observamos la figura 4.1, se aprecia que se ha inducido correctamente un sesgo de género donde los hombres tienen mayor probabilidad de ser tratados. Mientras que la tabla 4.6, nos indica que los hombres tienen una mayor tasa de exposición al tratamiento que las mujeres.

Sexo	Tasa de Exposición
Hombre	0.7465
Mujer	0.6673

Cuadro 4.6: Tasa de exposición promedio según el sexo.




Figura 4.1: Probabilidad de Exposición por Sexo

Respecto a las correlaciones expuestas en la tabla 4.7, cuyo mapa de calor puede observarse en la figura 4.2, observamos que la correlación más alta se encuentra en la variable **estado funcional**, indicando que esta covariable es el factor con mayor peso en la probabilidad de exposición. Mientras que las correlaciones presentadas en la tabla 4.8, cuyo mapa de calor se observa en 4.3, nos indican que nuevamente la variable **estado funcional** tiene una correlación alta, en este caso con la mejoría tras la finalización del estudio.

Variable	Edad	Sexo	Tabaco	Comorb	Funcional	N Socio	C Depen	Ap Familiar	N Educ
Correlación	0.1891	0.0870	0.0206	-0.0624	0.3445	0.0157	0.0051	-0.0220	0.0624

Cuadro 4.7: Correlaciones entre las variables seleccionadas y la exposición.

Variable	Edad	Sexo	Tabaco	Comorb	Funcional	N Socio	C Depen	Ap Familiar	N Educ
Correlación	-0.1089	-0.0232	0.0246	0.0172	0.7400	0.0862	-0.0345	-0.0165	-0.0063

Cuadro 4.8: Correlaciones entre las covariables seleccionadas y el resultado.




Figura 4.2: Heatmap de las Correlaciones entre las variables seleccionadas y la exposición.




Figura 4.3: Heatmap de las Correlaciones entre las variables seleccionadas y el resultado.

4.2. Análisis de los Datos

Se trabajó con los datos simulados que se generaron en el apartado anterior. Se transformaron a factores las variables que lo requerían, por lo que se obtuvo una tabla de datos con la siguiente estructura:

Variable	Tipo	Niveles
id	Entero	—
sexo	Categórica	Femenino, Masculino
tabaquismo	Categórica	No, Sí
nivel_socioeconomico	Categórica	Bajo, Medio, Alto
estado_funcional	Numérica	—
comorbilidades	Entero	—
cuidado_dependientes	Categórica	No, Sí
apoyo_familiar	Categórica	Bajo, Medio, Alto
nivel_educacion	Categórica	Bajo, Medio, Alto
edad	Numérica	—
prob_exposicion	Numérica	—
exposicion	Categórica	No, Sí
log_odds_Y	Numérica	—
prob_Y	Numérica	—
resultado	Categórica	No mejora, Mejora

Cuadro 4.9: Resumen de las variables, tipo y niveles.

En el anexo A.1 se presentan las tablas de frecuencia correspondientes a las variables categóricas utilizadas en el estudio.

4.2.1. Exploración y Análisis Descriptivo de los Datos

Pruebas de Normalidad

Se evaluó la normalidad de las variables continuas mediante el test de Shapiro-Wilk (ver Tabla 4.10). Los resultados muestran que ninguna de las variables analizadas sigue una distribución normal ($p < 0,05$), lo cual es esperable dado el tipo de variables, especialmente `log_odds_Y` y `prob_Y`.

Variable	Estadístico (W)	p-valor
Estado funcional	0.950	< 0,001
Comorbilidades	0.923	< 0,001
Edad	0.993	< 0,001
Probabilidad de exposición	0.941	< 0,001
Log odds de Y	0.963	< 0,001
Probabilidad de Y	0.813	< 0,001

Cuadro 4.10: Resultados del test de Shapiro-Wilk para las variables continuas.

Presencia de Outliers

La detección de outliers se realizó utilizando el método del rango intercuartílico (IQR). No se identificaron valores atípicos en ninguna de las variables analizadas, como se muestra en la Tabla 4.11.

Variable	Límite inferior	Límite superior	Outliers
Estado funcional	-50.52	152.17	No
Edad	12.50	88.50	No
Probabilidad de exposición	0.18	1.28	No
Log odds de Y	-8.95	11.88	No
Comorbilidades	-2	6	No
Probabilidad de Y	-0.87	2.09	No

Cuadro 4.11: Límites intercuartílicos para detección de outliers.

Evaluación de Multicolinealidad

La multicolinealidad entre las variables numéricas se evaluó mediante el cálculo de la matriz de correlación (ver Tabla 4.12). Los resultados muestran fuertes correlaciones entre **estado funcional**, **probabilidad de exposición**, **log odds de Y** y **probabilidad de Y**. Por otro lado, las variables **comorbilidades** y **edad** presentan una menor correlación con las demás, lo cual es consistente con los hallazgos previos en la simulación de datos, donde se identificó al **estado funcional** como un factor clave en la probabilidad de exposición y el resultado.

Variable	E. Funcional	Comorb.	Edad	P. Expo	Log Odds Y	Prob. Y
Estado Funcional	—	0.039	-0.018	0.859	0.981	0.939
Comorbilidades	0.039	—	-0.023	-0.077	-0.009	0.005
Edad	-0.018	-0.023	—	0.389	-0.190	-0.156
Prob. Exposición	0.859	-0.077	0.389	—	0.779	0.779
Log Odds Y	0.981	-0.009	-0.190	0.779	—	0.952
Prob. Y	0.939	0.005	-0.156	0.779	0.952	—

Cuadro 4.12: Matriz de correlación entre las variables numéricas.

Para visualizar mejor estas relaciones, se presenta un mapa de calor en la Figura 4.4, donde las correlaciones más fuertes están marcadas con colores más intensos.




Figura 4.4: Mapa de calor de la matriz de correlación.

Evaluación de asociaciones con Exposición

Se realizaron análisis estadísticos para evaluar las asociaciones entre las covariables y la exposición, utilizando la prueba de Chi-cuadrado para las variables categóricas y la prueba de Mann-Whitney U para las variables numéricas.

La prueba de Chi-cuadrado se aplicó a las covariables categóricas para evaluar su asociación con la exposición. Los resultados se resumen en la Tabla 4.13.

Variable	X-squared	p-value
Sexo	7.187	0.007*
Tabaquismo	0.331	0.565
Nivel socioeconómico	4.023	0.134
Cuidado de dependientes	0.006	0.939
Apoyo familiar	3.542	0.170
Nivel educativo	5.866	0.053

Cuadro 4.13: Resultados de la prueba de Chi-cuadrado para las covariables categóricas. *Indica significancia estadística ($p < 0,05$).

Entre las variables categóricas, solo **sexo** muestra una asociación significativa con la exposición ($p = 0,007$), lo que indica que el sesgo de género fue correctamente inducido en las simulaciones. Las demás variables no presentan asociaciones significativas.

La prueba de Mann-Whitney U se utilizó para evaluar las diferencias en las variables numéricas entre los grupos de exposición. Los resultados se presentan en la Tabla 4.14.

Variable	W	p-value
Estado funcional	58202	$< 2,2 \times 10^{-16}*$
Comorbilidades	112015	0.038*
Edad	79154	$4,196 \times 10^{-9}*$
Probabilidad de exposición	50406	$< 2,2 \times 10^{-16}*$
Log odds de Y	55232	$< 2,2 \times 10^{-16}*$
Probabilidad de Y	55232	$< 2,2 \times 10^{-16}*$

Cuadro 4.14: Resultados de la prueba de Mann-Whitney U para las covariables numéricas. *Indica significancia estadística ($p < 0,05$).

Todas las variables numéricas muestran diferencias significativas entre los grupos de exposición ($p < 0,05$). En particular, los individuos expuestos presentan, en promedio:

- Mejor estado funcional.
- Menor número de comorbilidades.
- Mayor edad.
- Mayor probabilidad de mejora, como se refleja en log odds de Y y probabilidad de Y.

4.3. Análisis de Regresión Logística

Se llevó a cabo un análisis de regresión logística para evaluar la asociación entre las covariables y la probabilidad de exposición. El modelo inicial incluyó todas las covariables disponibles: sexo, edad, estado funcional, nivel socioeconómico, cuidado de dependientes, apoyo familiar, nivel educativo, tabaquismo y comorbilidades.

Variable	Coefficiente (Est.)	OR	IC 95 % (OR)
Intercepto	-2.744	–	(0.027, 0.150)
Sexo masculino	0.446	1.56	(1.15, 2.12)
Edad	0.038	1.04	(1.03, 1.05)
Estado funcional	0.031	1.03	(1.03, 1.04)
Nivel educativo alto	0.456	1.58	(1.03, 2.42)
Comorbilidades	-0.147	0.86	(0.78, 0.96)

Cuadro 4.15: Resultados **significativos** del modelo de regresión logística

El modelo mostró un buen ajuste general con una devianza residual de 1010,3 y un AIC de 1036,3. Más información sobre el ajuste del modelo puede observarse en las Figuras 4.5, 4.6, 4.7. Los resultados sugieren que las siguientes variables tienen un efecto significativo sobre las probabilidades de exposición:

- **Sexo masculino** incrementa las probabilidades de exposición ($OR = 1.56$, IC 95 %: 1.15 - 2.12, $p = 0,0043$).
- **Edad** está asociada positivamente con la exposición; a mayor edad, mayor probabilidad de exposición ($OR = 1.04$, IC 95 %: 1.03 - 1.05, $p < 0,001$).
- **Estado funcional** se asocia con mayores probabilidades de exposición ($OR = 1.03$, IC 95 %: 1.03 - 1.04, $p < 0,001$).
- Tener un **nivel educativo alto** aumenta la probabilidad de exposición en comparación con niveles bajos ($OR = 1.58$, IC 95 %: 1.03 - 2.42, $p = 0,037$).
- Tener más **comorbilidades** reduce las probabilidades de exposición ($OR = 0.86$, IC 95 %: 0.78 - 0.96, $p = 0,0061$).

Las demás variables (nivel socioeconómico, cuidado de dependientes, apoyo familiar y tabaquismo) no mostraron asociaciones significativas en el modelo.

4.3.1. Gráfico de residuos




Figura 4.5: Gráfico de residuos para el modelo inicial.

4.3.2. Distancias de Cook




Figura 4.6: Distancias de Cook para el modelo inicial.

4.3.3. Curva ROC




Figura 4.7: Curva ROC para el modelo inicial. Area bajo la curva: 0,7688

4.4. Modelo Refinado: Stepwise

Se realizó un procedimiento Stepwise con dirección "both" para refinar el modelo inicial, eliminando variables irrelevantes y reduciendo el AIC. Este análisis dio como resultado un modelo final con las siguientes variables:

- **Variables retenidas:** sexo, edad, estado funcional, nivel socioeconómico, nivel educativo y comorbilidades.
- **Variables eliminadas:** cuidado de dependientes, tabaquismo y apoyo familiar.

Variable	Coef. Estimado	Error Est.	p-valor	OR (IC 95 %)
Intercepto	-2.588	0.406	< 0,001	0.075 (0.034, 0.165)
Sexo masculino	0.432	0.155	0.005	1.54 (1.14, 2.09)
Edad	0.038	0.006	< 0,001	1.04 (1.03, 1.05)
Estado funcional	0.031	0.003	< 0,001	1.03 (1.03, 1.04)
Nivel socioeconómico medio	0.244	0.178	0.171	1.28 (0.90, 1.81)
Nivel socioeconómico alto	-0.136	0.216	0.530	0.87 (0.57, 1.33)
Nivel educativo medio	0.052	0.215	0.810	1.05 (0.69, 1.60)
Nivel educativo alto	0.459	0.218	0.035	1.58 (1.03, 2.43)
Comorbilidades	-0.149	0.053	0.005	0.86 (0.78, 0.96)

Cuadro 4.16: Coeficientes del modelo refinado

El modelo refinado tiene un AIC de 1032,2, con una devianza residual de 1014,2. Más información sobre el ajuste del modelo puede observarse en las Figuras 4.8, 4.9, 4.10. Los resultados clave son los siguientes:

- **Sexo masculino:** incrementa las probabilidades de exposición ($OR = 1.54$, IC 95 %: 1.14 - 2.09, $p = 0,005$).
- **Edad:** un aumento en la edad incrementa la probabilidad de exposición ($OR = 1.04$, IC 95 %: 1.03 - 1.05, $p < 0,001$).
- **Estado funcional:** un mejor estado funcional se asocia con un aumento en las probabilidades de exposición ($OR = 1.03$, IC 95 %: 1.03 - 1.04, $p < 0,001$).
- **Nivel educativo alto:** incrementa las probabilidades de exposición ($OR = 1.58$, IC 95 %: 1.03 - 2.43, $p = 0,035$).
- **Comorbilidades:** cada comorbilidad adicional reduce la probabilidad de exposición ($OR = 0.86$, IC 95 %: 0.78 - 0.96, $p = 0,005$).

El modelo refinado confirma las tendencias observadas en el modelo inicial y mantiene su consistencia al eliminar variables con baja relevancia estadística. Esto refuerza la interpretación de los efectos clave identificados.

4.4.1. Gráfico de residuos para el modelo refinado




Figura 4.8: Gráfico de residuos para el modelo refinado con Stepwise.

4.4.2. Distancias de Cook para el modelo refinado




Figura 4.9: Distancias de Cook para el modelo refinado con Stepwise.

4.4.3. Curva ROC para el modelo refinado




Figura 4.10: Curva ROC para el modelo refinado con Stepwise. Area bajo la curva: 0,7678

4.4.4. Validación cruzada con 10 pliegues

Se realizó una validación cruzada con 10 pliegues utilizando un Modelo Lineal Generalizado (GLM) con 6 predictores para clasificar entre las clases 'No' y 'Sí'.

- **Número de muestras:** 1000
- **Número de predictores:** 6
- **Clases:** 'No expuesto', 'Sí expuesto'
- **Método de partición:** Validación cruzada con 10 pliegues
- **Tamaño promedio de las muestras por pliegue:** Aproximadamente 900

Los resultados de la validación cruzada muestran las siguientes métricas:

- **Área bajo la curva ROC (ROC):** 0,7608
Este valor indica una buena capacidad del modelo para discriminar entre las clases 'No expuesto' y 'Sí expuesto', con un ROC cercano a 1 que refleja un modelo efectivo.
- **Sensibilidad (Sens):** 0,3791
La sensibilidad es relativamente baja, lo que indica que el modelo tiene dificultades para identificar correctamente los casos positivos ('Sí expuesto').
- **Especificidad (Spec):** 0,9080
La especificidad es alta, lo que sugiere que el modelo tiene un buen desempeño en la identificación de casos negativos ('No expuesto').

4.5. Propensity Scores

4.5.1. Cálculo de los Propensity Scores

Se llevó a cabo el cálculo de los *Propensity Scores* utilizando el modelo inicial presentado anteriormente. Se utilizaron los datos procesados previamente como entrada para el cálculo de los *Propensity Scores*.

Estadísticas descriptivas de los Propensity Scores

Se obtuvo el *summary* de los *Propensity Scores*, con los siguientes valores estadísticos descriptivos como puede verse en la tabla 4.17.

Estadística	Valor
Mínimo (Min)	0.1394
Primer cuartil (1st Qu.)	0.5684
Mediana (Median)	0.7563
Media (Mean)	0.7070
Tercer cuartil (3rd Qu.)	0.8790
Máximo (Max)	0.9855

Cuadro 4.17: Estadísticas descriptivas de los *Propensity Scores*.

Los valores de los *Propensity Scores* oscilan entre 0.1394 y 0.9855, lo que indica una distribución amplia de las probabilidades estimadas para pertenecer al grupo de exposición.

4.5.2. Análisis de Balance Inicial de las Covariables

Se realizó un análisis de balance inicial de las covariables para evaluar las diferencias de medias estandarizadas (*Standardized Mean Differences*, SMD) entre los grupos definidos por la exposición (No expuesto y Expuesto). Un SMD superior a 0.1 suele indicar existencia de desequilibrio potencial entre los grupos (ver tabla 4.18).

Covariable	No Expuesto	Expuesto	SMD
Sexo = Masculino (%)	127 (43.3)	374 (52.9)	0.192
Tabaquismo = Sí (%)	81 (27.6)	210 (29.7)	0.046
Nivel socioeconómico (%)			0.140
Bajo	97 (33.1)	201 (28.4)	
Medio	131 (44.7)	365 (51.6)	
Alto	65 (22.2)	141 (19.9)	
Estado funcional (media, DE)	34.35 (27.06)	56.46 (27.61)	0.809
Comorbilidades (media, DE)	2.16 (1.44)	1.97 (1.44)	0.137
Cuidado de dependientes = Sí (%)	60 (20.5)	148 (20.9)	0.011
Apoyo familiar (%)			0.130
Bajo	94 (32.1)	219 (31.0)	
Medio	128 (43.7)	349 (49.4)	
Alto	71 (24.2)	139 (19.7)	
Nivel educativo (%)			0.170
Bajo	55 (18.8)	120 (17.0)	
Medio	130 (44.4)	268 (37.9)	
Alto	108 (36.9)	319 (45.1)	
Edad (media, DE)	46.02 (13.35)	52.01 (14.49)	0.430

Cuadro 4.18: Tabla de balance inicial de las covariables.

- El **estado funcional** muestra un desequilibrio considerable entre los grupos (SMD = 0.809).
- La **edad** también presenta un desequilibrio moderado (SMD = 0.430).
- El **sexo** muestra un desequilibrio más pequeño (SMD = 0.192) con mayor exposición para el sexo masculino.
- Otras covariables, como el tabaquismo, cuidado de dependientes y apoyo familiar, muestran diferencias más pequeñas con valores de SMD cercanos a 0.

4.5.3. Love Plot del Balance Inicial




Figura 4.11: Love Plot del Balance Inicial.

El LovePlot muestra diferencias con la tabla de balance generada anteriormente. Esto puede ser debido a cómo calculan las diferencias cada uno. Se tendrá en cuenta **comorbilidades** como otra covariable cuyo balanceo está desequilibrado.

4.6. Balanceamiento con PS: Matching (Emparejamiento)

Se han realizado tres tipos de emparejamiento diferentes que se presentan a continuación y se ha seleccionado el que se ha considerado más apropiado para el estudio, denominado **Matching Final**.

4.6.1. Matching Inicial con Reemplazamiento

Se realizó un análisis de balance de datos utilizando el método de emparejamiento por el vecino más cercano (*nearest*) con reemplazo. Este emparejamiento se llevó a cabo considerando las tres covariables más desbalanceadas: **sexo**, **edad** y **estado funcional**.

Tamaño de la muestra

El tamaño de muestra tras el emparejamiento quedó distribuido de la siguiente forma como puede verse en la tabla 4.19.

Estado	Controles	Tratados
Original	293	707
Emparejados	184	707
No emparejados	109	0
Descartados	0	0

Cuadro 4.19: Distribución del tamaño muestral tras el emparejamiento.

Tabla de Balance del Matching Inicial con Reemplazamiento

Se realizó un análisis detallado de las covariables tras el emparejamiento inicial con reemplazamiento. Los resultados de la tabla de balance se presentan a continuación (ver tabla 4.20), mostrando las medias, desviaciones estándar (SD) y SMD para las variables incluidas.

Covariable	No Expuesto	Expuestos	SMD
Sexo (Masculino)	48.4 % (89)	52.9 % (374)	0.091
Tabaquismo (Sí)	29.3 % (54)	29.7 % (210)	0.008
Nivel socioeconómico			0.176
Bajo	32.6 % (60)	28.4 % (201)	
Medio	42.9 % (79)	51.6 % (365)	
Alto	24.5 % (45)	19.9 % (141)	
Estado funcional	41.79 (27.90)	56.46 (27.61)	0.529
Comorbilidades	2.28 (1.44)	1.97 (1.44)	0.216
Cuidado dependientes (Sí)	18.5 % (34)	20.9 % (148)	0.062
Apoyo familiar			0.163
Bajo	32.1 % (59)	31.0 % (219)	
Medio	42.4 % (78)	49.4 % (349)	
Alto	25.5 % (47)	19.7 % (139)	
Nivel de educación			0.193
Bajo	21.2 % (39)	17.0 % (120)	
Medio	42.9 % (79)	37.9 % (268)	
Alto	35.9 % (66)	45.1 % (319)	
Edad	48.67 (12.76)	52.01 (14.49)	0.244

Cuadro 4.20: Tabla de balance tras el emparejamiento inicial con reemplazamiento.

- Las variables **Sexo** (SMD = 0.091), **Tabaquismo** (SMD = 0.008) y **Cuidado de dependientes** (SMD = 0.062) presentan un balance adecuado tras el emparejamiento.
- Las covariables **Estado funcional** (SMD = 0.529) y **Edad** (SMD = 0.244) muestran un balance menos favorable.

4.6.2. Matching aplicando todas las variables con SMD mayor a 0.1

Se llevó a cabo un emparejamiento utilizando el método del vecino más cercano (*nearest*) con reemplazo, considerando todas las variables cuyo *Standardized Mean Difference* (SMD) superaba 0.1.

Tamaño de la muestra

El tamaño de la muestra tras el emparejamiento quedó distribuido de la siguiente forma como puede verse en la tabla 4.21.

Estado	Controles	Tratados
Original	293	707
Emparejados	178	707
No emparejados	115	0
Descartados	0	0

Cuadro 4.21: Distribución del tamaño muestral tras el emparejamiento (SMD mayor a 0.1).

Tabla de Balance del Matching con variables cuyo SMD es mayor a 0.1

Covariable	No Expuesto	Expuesto	SMD
Sexo = Masculino (%)	44.9 % (80)	52.9 % (374)	0.160
Tabaquismo = Sí (%)	29.2 % (52)	29.7 % (210)	0.011
Nivel socioeconómico (%)			0.100
- Bajo	31.5 % (56)	28.4 % (201)	
- Medio	46.6 % (83)	51.6 % (365)	
- Alto	21.9 % (39)	19.9 % (141)	
Estado funcional (media $\pm$ SD)	42.64 $\pm$ 27.83	56.46 $\pm$ 27.61	0.499
Comorbilidades (media $\pm$ SD)	2.16 $\pm$ 1.41	1.97 $\pm$ 1.44	0.138
Cuidado de dependientes = Sí (%)	19.7 % (35)	20.9 % (148)	0.032
Apoyo familiar (%)			0.056
- Bajo	30.3 % (54)	31.0 % (219)	
- Medio	47.8 % (85)	49.4 % (349)	
- Alto	21.9 % (39)	19.7 % (139)	
Nivel de educación (%)			0.112
- Bajo	16.3 % (29)	17.0 % (120)	
- Medio	43.3 % (77)	37.9 % (268)	
- Alto	40.4 % (72)	45.1 % (319)	
Edad (media $\pm$ SD)	47.76 $\pm$ 13.55	52.01 $\pm$ 14.49	0.303

Cuadro 4.22: Balance de Covariables tras el Matching (SMD mayor a 0.1)

- El balance tras el Matching muestra mejoras significativas en la mayoría de las covariables, con SMDs generalmente inferiores a 0.1, salvo en **estado funcional** (SMD = 0.499) y **edad** (SMD = 0.303), donde persisten diferencias moderadas.
- Las variables categóricas como **sexo** y **nivel socioeconómico** lograron un buen ajuste con SMDs de 0.160 y 0.100, respectivamente.
- Las **comorbilidades** presentan un leve desequilibrio residual (SMD = 0.138).

4.6.3. Matching con Sexo, Edad, Estado Funcional y Comorbilidades (Versión Final)

El último emparejamiento se realizó igual que el primero, pero añadiendo también la variable **comorbilidades** a la ecuación. De esta manera se estarían balanceando las variables que mayor desajuste y relación con exposición habían mostrado en un inicio.

Tamaño de la muestra

El tamaño de la muestra tras el emparejamiento quedó distribuido de la siguiente forma como puede verse en la tabla 4.23.

Estado	Controles	Tratados
Original	293	707
Emparejados	188	707
No emparejados	105	0
Descartados	0	0

Cuadro 4.23: Distribución del tamaño muestral tras el emparejamiento (Final).

Tabla de Balance del Matching Final

Covariable	Media Control	Media Tratados	SMD
Sexo: Masculino (%)	48.9 %	52.9 %	0.079
Tabaquismo: Sí (%)	30.3 %	29.7 %	0.013
Nivel Socioeconómico (%)			0.207
Bajo	33.0 %	28.4 %	-
Medio	41.5 %	51.6 %	-
Alto	25.5 %	19.9 %	-
Estado Funcional (Media)	41.85	56.46	0.529
Comorbilidades (Media)	2.19	1.97	0.158
Cuidado Dependientes: Sí (%)	22.3 %	20.9 %	0.034
Apoyo Familiar (%)			0.182
Bajo	33.5 %	31.0 %	-
Medio	41.0 %	49.4 %	-
Alto	25.5 %	19.7 %	-
Nivel Educación (%)			0.137
Bajo	20.7 %	17.0 %	-
Medio	40.4 %	37.9 %	-
Alto	38.8 %	45.1 %	-
Edad (Media)	48.74	52.01	0.239

Cuadro 4.24: Balance de las covariables tras el Matching Final

El balance final muestra que todavía siguen existiendo diferencias en la mayoría de covariables, aunque otras se han reducido bastante. Sin embargo, dentro de las covariables más importantes (Sexo, Estado Funcional, Edad y Comorbilidades), ha conseguido reducir exitosamente el desequilibrio de éstas.

4.6.4. Comparativa del Balance entre los tres tipos de Emparejamiento

Variable	Original	Reemplazo	Completo	Final
n	293/707	184/707	178/707	188/707
Sexo: Masculino (%)	0.192	0.091	0.160	0.079
Tabaquismo: Sí (%)	0.046	0.008	0.011	0.013
Nivel Socioeconómico	0.140	0.176	0.100	0.207
Estado Funcional	0.809	0.529	0.499	0.529
Comorbilidades	0.137	0.216	0.138	0.158
Cuidado Dependientes	0.011	0.062	0.032	0.034
Apoyo Familiar	0.130	0.163	0.056	0.182
Nivel Educación	0.170	0.193	0.112	0.137
Edad (Media)	0.430	0.244	0.303	0.239

Cuadro 4.25: Comparativa del balance de las covariables entre los modelos (SMD)

Al comparar los valores de SMD entre los diferentes emparejamientos, se observa que:

- El **Balance Original** presenta balances inadecuados, especialmente en variables como estado funcional (SMD = 0.809) y edad (SMD = 0.430).
- El **Emparejamiento Inicial** que ajusta Sexo, Edad y Estado Funcional, mejora considerablemente el balance, reduciendo el SMD en varias variables clave, aunque algunas aún presentan valores moderados (estado funcional = 0.529, edad = 0.244).
- El **Emparejamiento Completo** es aquel que equilibró todas las covariables que necesitaban un ajuste. Este Emparejamiento logra un balance mejorado en variables como apoyo familiar (SMD = 0.056) y nivel socioeconómico (SMD = 0.100), pero con peor desempeño en otras variables como sexo (SMD = 0.160) o edad (SMD = 0.303).
- El **Emparejamiento Final** mantiene un balance óptimo, especialmente en variables como sexo (SMD = 0.079) y edad (SMD = 0.239), reduce además el desbalance de Estado Funcional también (SMD = 0.529) pero tiene ligeros problemas en nivel socioeconómico (SMD = 0.207) y ajusta peor el resto de covariables.

Cuál es el mejor emparejamiento parece estar entre el **Emparejamiento Completo** y el **Emparejamiento Final**. Aunque el Emparejamiento Completo parece mostrar un mejor ajuste global (lo esperado al haber balanceado todas las variables), pierde un poco de fuerza en las variables que habíamos observado que tenían un desbalance mayor y más peso en la probabilidad de Exposición, como son Edad, Sexo, Estado Funcional y Comorbilidades (ver la Tabla 4.14 y la Tabla 4.13).

Así que vamos a observar los Love Plot de ambos modelos para ver cuál parece hacer un mejor trabajo (ver Figuras 4.12 y 4.13).

Love Plot del Emparejamiento Completo




Figura 4.12: Love Plot del Emparejamiento Completo.

Love Plot del Emparejamiento Final




Figura 4.13: Love Plot del Balance Final.

Así que tomando las variables Estado Funcional, Edad, Sexo y Comorbilidades como las variables clave, y siendo el Emparejamiento Final el que ha obtenido un mejor balance en éstas,

se va a proseguir con el uso de este Emparejamiento Final para los siguientes análisis.

4.6.5. Análisis de Asociación después del Emparejamiento

Variable	X-squared	p-value
Sexo	0.78268	0.3763
Tabaquismo	0.0055423	0.9407
Nivel socioeconómico	6.3253	0.04231*
Cuidado de dependientes	0.10172	0.7498
Apoyo familiar	4.9578	0.08383
Nivel educativo	2.776	0.2496

Cuadro 4.26: Resultados de la prueba de Chi-cuadrado para las covariables categóricas. *Indica significancia estadística ($p < 0,05$).

Variable	W	p-value
Estado funcional	46739	$3,868 \times 10^{-10}$ *
Comorbilidades	72774	0.04009*
Edad	57612	$4,976 \times 10^{-3}$ *
Probabilidad de exposición	43222	$1,636 \times 10^{-13}$ *
Log odds de Y	43007	$9,776 \times 10^{-14}$ *
Probabilidad de Y	43007	$9,776 \times 10^{-14}$ *

Cuadro 4.27: Resultados de la prueba de Mann-Whitney U para las covariables numéricas. *Indica significancia estadística ($p < 0,05$).

La principal diferencia es que al balancear con Propensity Scores, el sesgo de género desapareció y ahora Nivel Socioeconómico empezó a mostrar una asociación significativa con la exposición.

4.7. Análisis de Regresión Logística con los datos balanceados por Matching

Se llevó a cabo un análisis de regresión logística para evaluar la asociación entre las covariables y la probabilidad de exposición. El modelo balanceado incluyó las covariables: sexo, edad, estado funcional, nivel socioeconómico, cuidado de dependientes, apoyo familiar, nivel educativo, tabaquismo y comorbilidades.

Variable	Coeficiente (Est.)	OR	IC 95 % (OR)
Intercepto	-1.043	–	(0.135, 0.911)
Sexo masculino	0.227	1.25	(0.895, 1.761)
Edad	0.023	1.02	(1.010, 1.036)
Estado funcional	0.021	1.02	(1.015, 1.028)
Nivel socioeconómico medio	0.313	1.37	(0.923, 2.021)
Nivel socioeconómico alto	-0.191	0.83	(0.525, 1.305)
Nivel educativo medio	0.135	1.14	(0.715, 1.812)
Nivel educativo alto	0.401	1.49	(0.936, 2.362)
Cuidado de dependientes	-0.065	0.94	(0.627, 1.421)
Apoyo familiar medio	0.247	1.28	(0.864, 1.893)
Apoyo familiar alto	-0.199	0.82	(0.522, 1.290)
Tabaquismo	-0.012	0.99	(0.685, 1.436)
Comorbilidades	-0.136	0.87	(0.778, 0.980)

Cuadro 4.28: Resultados del Modelo Balanceado de regresión logística

El Modelo Balanceado mostró un buen ajuste general con una devianza residual de 847,1 y un AIC de 873,1. Más información sobre el ajuste del modelo puede observarse en las Figuras 4.14, 4.15, 4.16. Los resultados sugieren que las siguientes variables tienen un efecto significativo sobre las probabilidades de exposición:

- **Edad** está asociada positivamente con la exposición; a mayor edad, mayor probabilidad de exposición ($OR = 1.02$, IC 95 %: 1.010 - 1.036, $p < 0,001$).
- **Estado funcional** se asocia con mayores probabilidades de exposición ($OR = 1.02$, IC 95 %: 1.015 - 1.028, $p < 0,001$).
- Tener más **comorbilidades** reduce las probabilidades de exposición ($OR = 0.87$, IC 95 %: 0.778 - 0.980, $p = 0,021$).

Las demás variables (sexo, nivel socioeconómico, nivel educativo, cuidado de dependientes, apoyo familiar y tabaquismo) no mostraron asociaciones significativas en el Modelo Balanceado. Tras el balanceo con PS, el sexo ha perdido impacto en la probabilidad de exposición.

4.7.1. Gráfico de residuos del Modelo Balanceado




Figura 4.14: Gráfico de residuos para el Modelo Balanceado.

4.7.2. Distancias de Cook del Modelo Balanceado




Figura 4.15: Distancias de Cook para el Modelo Balanceado.

4.7.3. Curva ROC del Modelo Balanceado




Figura 4.16: Curva ROC para el Modelo Balanceado. Area bajo la curva: 0,6969

4.8. Modelo Balanceado refinado con Stepwise

Se realizó un procedimiento Stepwise con dirección "both" para refinar el Modelo Balanceado, eliminando variables irrelevantes y reduciendo el AIC. Este análisis dio como resultado un modelo con las siguientes variables:

- **Variables retenidas:** edad, estado funcional, nivel socioeconómico, apoyo familiar y comorbilidades.
- **Variables eliminadas:** sexo, nivel educativo, cuidado de dependientes y tabaquismo.

Variable	Coef. Estimado	OR	IC 95 % (OR)
Intercepto	-0.706	–	(0.212, 1.138)
Edad	0.022	1.02	(1.010, 1.035)
Estado funcional	0.020	1.02	(1.014, 1.027)
Nivel socioeconómico medio	0.313	1.37	(0.924, 2.017)
Nivel socioeconómico alto	-0.184	0.83	(0.529, 1.312)
Apoyo familiar medio	0.244	1.28	(0.864, 1.882)
Apoyo familiar alto	-0.193	0.82	(0.526, 1.295)
Comorbilidades	-0.130	0.88	(0.783, 0.986)

Cuadro 4.29: Coeficientes del modelo refinado balanceado

El Modelo Balanceado Refinado tiene un AIC de 868,4, con una devianza residual de 852,4. Más información sobre el ajuste del modelo puede observarse en las Figuras 4.17, 4.18, 4.19. Los resultados clave son los siguientes:

- **Edad:** un aumento en la edad incrementa la probabilidad de exposición ($OR = 1.02$, IC 95 %: 1.010 - 1.035, $p < 0,001$).
- **Estado funcional:** un mejor estado funcional se asocia con un aumento en las probabilidades de exposición ($OR = 1.02$, IC 95 %: 1.014 - 1.027, $p < 0,001$).
- **Comorbilidades:** cada comorbilidad adicional reduce la probabilidad de exposición ($OR = 0.88$, IC 95 %: 0.783 - 0.986, $p = 0,027$).

Las demás variables (nivel socioeconómico y apoyo familiar) no mostraron asociaciones significativas en el Modelo Balanceado Refinado.

4.8.1. Gráfico de residuos del Modelo Balanceado Refinado




Figura 4.17: Gráfico de residuos para el Modelo Balanceado Refinado.

4.8.2. Distancias de Cook del Modelo Balanceado Refinado




Figura 4.18: Distancias de Cook para el Modelo Balanceado Refinado.

4.8.3. Curva ROC del Modelo Balanceado Refinado




Figura 4.19: Curva ROC para el Modelo Balanceado Refinado. Area bajo la curva: 0,6846

4.8.4. Validación cruzada con 10 pliegues (Modelo Balanceado Refinado)

Se realizó una validación cruzada con 10 pliegues utilizando un Modelo Lineal Generalizado (GLM) con 5 predictores para clasificar entre las clases 'No' y 'Sí'.

- **Número de muestras:** 895
- **Número de predictores:** 5
- **Clases:** 'No expuesto', 'Sí expuesto'
- **Método de partición:** Validación cruzada con 10 pliegues
- **Tamaño promedio de las muestras por pliegue:** Aproximadamente 805

Los resultados de la validación cruzada muestran las siguientes métricas:

- **Área bajo la curva ROC (ROC):** 0,6728
Este valor indica una capacidad moderada del modelo para discriminar entre las clases 'No expuesto' y 'Sí expuesto', con un ROC superior a 0.5 que refleja un modelo con moderada eficacia. .
- **Sensibilidad (Sens):** 0,0532
La sensibilidad es muy baja, lo que indica que el modelo tiene muchas dificultades para identificar correctamente los casos positivos ('Sí expuesto').
- **Especificidad (Spec):** 0,9901
La especificidad es muy alta, lo que sugiere que el modelo es casi perfecto identificando casos negativos ('No expuesto').

4.9. Balanceamiento con PS: Weighting (Ponderación)

Para mitigar los sesgos de selección, a parte de utilizar el método de Emparejamiento, se va a utilizar ahora la Ponderación (*Weighting*). Para ello se van a utilizar los Pesos Inversos de Probabilidad de Tratamiento (*Inverse Probability of Treatment Weights*, IPW). Este método ajusta las diferencias entre grupos en función de las covariables mediante la ponderación de cada individuo según la probabilidad estimada de ser expuesto al tratamiento.

4.9.1. Distribución de los Pesos IPW

La distribución de los pesos calculados es la presentada en la Tabla 4.30 y en la Figura 4.20.

Estadístico	Valor
Mínimo	1.015
Primer Cuartil (1Q)	1.151
Mediana	1.413
Media	1.996
Tercer Cuartil (3Q)	1.960
Máximo	31.732

Cuadro 4.30: Resumen estadístico de los IPW




Figura 4.20: Distribución de los IPW

La media de los pesos es 1.996, lo que indica un equilibrio moderado en la asignación de la exposición tras aplicar la ponderación IPW. Sin embargo, el rango de valores es amplio, con un máximo de 31.732, lo que sugiere la existencia de algunos individuos con probabilidades extremadamente bajas o altas de estar expuestos.

4.9.2. Tabla de Balance tras la Ponderación

Los resultados de la tabla de balance se presentan a continuación en la Tabla 4.31. El balance antes de la Ponderación puede observarse en la Tabla 4.18.

Covariable	No Expuesto	Expuesto	SMD
n	997.3	998.6	
Sexo = Masculino (%)	474.9 (47.6)	493.0 (49.4)	0.035
Tabaquismo = Sí (%)	327.8 (32.9)	296.7 (29.7)	0.068
Nivel socioeconómico (%)			0.019
Bajo	288.2 (28.9)	297.1 (29.7)	
Medio	493.0 (49.4)	487.5 (48.8)	
Alto	216.1 (21.7)	214.0 (21.4)	
Estado funcional (media, DE)	51.16 (30.36)	50.34 (28.51)	0.028
Comorbilidades (media, DE)	2.14 (1.31)	2.03 (1.44)	0.083
Cuidado de dependientes = Sí (%)	183.3 (18.4)	204.5 (20.5)	0.053
Apoyo familiar (%)			0.094
Bajo	360.9 (36.2)	320.3 (32.1)	
Medio	431.8 (43.3)	474.6 (47.5)	
Alto	204.6 (20.5)	203.8 (20.4)	
Nivel educativo (%)			0.025
Bajo	178.2 (17.9)	184.0 (18.4)	
Medio	408.1 (40.9)	396.8 (39.7)	
Alto	411.0 (41.2)	417.8 (41.8)	
Edad (media, DE)	49.97 (13.39)	50.34 (14.33)	0.027

Cuadro 4.31: Tabla de balance tras el ajuste con IPW.

Se puede observar mediante los valores de SMD que todas las variables han sido equilibradas completamente. No hay ninguna variable desajustada (SMD mayor a 0.1).

4.10. Análisis de Regresión Logística con los datos balanceados por Ponderación

Se llevó a cabo un análisis de regresión logística utilizando los pesos IPW para evaluar la asociación entre las covariables y la probabilidad de exposición. El modelo incluyó las covariables: sexo, edad, estado funcional, nivel socioeconómico, nivel educativo, cuidado de dependientes, apoyo familiar, tabaquismo y comorbilidades.

Variable	Coeficiente (Est.)	OR	IC 95 % (OR)
Intercepto	-0.080	–	(0.212, 1.138)
Sexo masculino	0.070	1.07	(0.894, 1.761)
Edad	0.003	1.00	(1.010, 1.035)
Estado funcional	-0.000	1.00	(1.014, 1.027)
Nivel socioeconómico medio	-0.018	0.98	(0.924, 2.017)
Nivel socioeconómico alto	-0.040	0.96	(0.529, 1.312)
Nivel educativo medio	-0.077	0.93	(0.715, 1.812)
Nivel educativo alto	0.010	1.01	(0.936, 2.362)
Cuidado de dependientes	0.126	1.13	(0.627, 1.421)
Apoyo familiar medio	0.215	1.24	(0.864, 1.882)
Apoyo familiar alto	0.105	1.11	(0.526, 1.295)
Tabaquismo	-0.127	0.88	(0.685, 1.436)
Comorbilidades	-0.059	0.94	(0.783, 0.986)

Cuadro 4.32: Resultados del Modelo Ponderado

El modelo mostró un ajuste bajo con una devianza residual de 2754,0 y un AIC de 2693,3. Esto nos indica que el modelo no está mostrando un mejor ajuste que el modelo nulo. Más información sobre el ajuste del modelo puede encontrarse en las figuras 4.21, 4.22 y 4.23. Por otro lado, los resultados sugieren que las siguientes variables tienen un efecto significativo sobre las probabilidades de exposición:

- **Apoyo familiar medio** incrementa las probabilidades de exposición ($OR = 1.24$, IC 95 %: 0.864 - 1.882, $p = 0,0366$).
- **Comorbilidades** reducen marginalmente las probabilidades de exposición ($OR = 0.94$, IC 95 %: 0.783 - 0.986, $p = 0,077$).

Las demás variables (sexo, edad, estado funcional, nivel socioeconómico, nivel educativo, cuidado de dependientes y tabaquismo) no mostraron asociaciones significativas en el modelo ponderado.

4.10.1. Gráfico de residuos del Modelo Ponderado




Figura 4.21: Gráfico de residuos para el Modelo Ponderado.

4.10.2. Distancias de Cook del Modelo Ponderado




Figura 4.22: Distancias de Cook para el Modelo Ponderado.

4.10.3. Curva ROC del Modelo Ponderado




Figura 4.23: Curva ROC para el Modelo Ponderado. Area bajo la curva: 0,5616

4.10.4. Validación cruzada con 10 pliegues (Modelo Ponderado)

Se realizó una validación cruzada con 10 pliegues utilizando un Modelo Lineal Generalizado (GLM) con 9 predictores para clasificar entre las clases 'No' y 'Sí'.

- **Número de muestras:** 1000
- **Número de predictores:** 9
- **Clases:** 'No expuesto', 'Sí expuesto'
- **Método de partición:** Validación cruzada con 10 pliegues
- **Tamaño promedio de las muestras por pliegue:** Aproximadamente 900

Los resultados de la validación cruzada muestran las siguientes métricas:

- **Área bajo la curva ROC (ROC):** 0.4805
Este valor indica una capacidad limitada del modelo para discriminar entre las clases 'No expuesto' y 'Sí expuesto', con un ROC cercano a 0.5 que refleja un modelo no efectivo.
- **Sensibilidad (Sens):** 0.4176
La sensibilidad indica que el modelo tiene una capacidad baja para identificar correctamente los casos positivos ('Sí expuesto').
- **Especificidad (Spec):** 0.5345
La especificidad es baja, lo que sugiere que el modelo tiene dificultades en la identificación de casos negativos ('No expuesto').

4.11. Comparación de los resultados de los Modelos

Prueba/Modelo	Variable	Resultado
Chi-cuadrado	Sexo	Hombres mayor probabilidad de exposición.
Mann-Whitney U	Estado Funcional	Mejor E. Fun. en expuestos.
	Comorbilidades	Menor Comorb. en expuestos.
	Edad	Mayor Edad en expuestos.
Chi-cuadrado (PS)	Nivel Socioeconómico	Asociación con probabilidad de exposición
Mann-Whitney U (PS)	Estado Funcional	Igual que Mann-Whitney U sin PS
	Comorbilidades	Igual que Mann-Whitney U sin PS
	Edad	Igual que Mann-Whitney U sin PS
Modelo sin PS	Sexo	Hombres mayor probabilidad de exposición.
	Edad	Más Edad, mayor probabilidad de exposición.
	Estado Funcional	Mejor E. Fun., mayor probabilidad de exposición.
	Nivel Educativo	N. Educ. alto, mayor probabilidad de exposición.
	Comorbilidades	Más Comorb., menor probabilidad de exposición.
Modelo Refinado sin PS	Sexo	Igual que el Modelo sin PS
	Edad	Igual que el Modelo sin PS
	Estado Funcional	Igual que el Modelo sin PS
	Nivel Educativo	Igual que el Modelo sin PS
	Comorbilidades	Igual que el Modelo sin PS
Modelo con PS (Emparejamiento)	Edad	Más Edad, mayor probabilidad de exposición.
	Estado Funcional	Mejor E. Func., mayor probabilidad de exposición.
	Comorbilidades	Más Comorb., menor probabilidad de exposición.
Modelo con PS (Refinado y con Emparejamiento)	Edad	Igual que el Modelo con PS Refinado
	Estado Funcional	Igual que el Modelo con PS Refinado
	Comorbilidades	Igual que el Modelo con PS Refinado
Modelo con PS (Ponderación)	Apoyo Familiar	A. Fam. medio, mayor probabilidad de exposición.
	Comorbilidades	Más Comorb., menor probabilidad de exposición.

Cuadro 4.33: Resumen de Resultados con y sin Propensity Scores

Modelo	Área Bajo la Curva (AUC)
Sin PS	0.768
Sin PS: Refinado	0.767
Con PS: Emparejamiento	0.696
Con PS: Emparejamiento Refinado	0.684
Con PS: Ponderación	0.561

Cuadro 4.34: Área Bajo la Curva (AUC) para Diferentes Modelos de Regresión

Modelo	ROC	Sens	Spec
Sin PS: Refinado	0.760	0.379	0.908
Con PS: Emparejamiento Refinado	0.672	0.053	0.990
Con PS: Ponderación	0.480	0.417	0.534

Cuadro 4.35: Comparación de ROC, Sensibilidad y Especificidad para los Diferentes Modelos

Variable	No Exposición	Sí Exposición
Balance Inicial sin PS		
n	293	707
edad (mean (SD))	46.02 (13.35)	52.01 (14.49)
sexo = Masculino (%)	43.3	52.9
estado funcional (mean (SD))	34.35 (27.06)	56.46 (27.61)
comorbilidades (mean (SD))	2.16 (1.44)	1.97 (1.44)
PS con Emparejamiento		
n	188	707
edad (mean (SD))	48.74 (12.81)	52.01 (14.49)
sexo = Masculino (%)	48.9	52.9
estado funcional (mean (SD))	41.85 (27.65)	56.46 (27.61)
comorbilidades (mean (SD))	2.19 (1.41)	1.97 (1.44)
PS con Ponderación		
n	997.3	998.6
edad (mean (SD))	49.97 (13.39)	50.34 (14.33)
sexo = Masculino (%)	47.6	49.4
estado funcional (mean (SD))	51.16 (30.36)	50.34 (28.51)
comorbilidades (mean (SD))	2.14 (1.31)	2.03 (1.44)

Cuadro 4.36: Comparación de balances entre modelos para Edad, Sexo, Estado Funcional y Comorbilidades

Capítulo 5

Discusión

El uso de Propensity Scores, específicamente los métodos de Emparejamiento y Ponderación, permitió mejorar la validez interna de los estudios observacionales, generando también cambios en los diferentes Modelos de Regresión Logística realizados. Esto confirma la **primera hipótesis** de este trabajo (ver Tabla 4.25 y 4.31).

Respecto a la **segunda hipótesis**, los PS también demostraron ser efectivos para mitigar el sesgo de género en la adherencia a los tratamientos. En los modelos sin PS, el sexo mostró una asociación más fuerte con la probabilidad de exposición, lo que sugiere que el sesgo de género podría estar afectando los resultados sin no se realiza un ajuste adecuado (ver Tabla 4.33).

Estos resultados son consistentes con otros trabajos donde se utilizan los PS para el balance de covariables en ensayos clínicos como muestran Austin et al. (2021)[51] y D'Agostino (2007)[52], (vease Apartado 2.2.4). Por lo que el presente estudio también reafirma el importante papel de los PS en la corrección del sesgo de selección en estudios observacionales, como se observa en los balances obtenidos (Tabla 4.36).

Además, durante el trabajo se consiguió disminuir en parte el sesgo de selección asociado a las covariables estudiadas, lo cual es un uso habitual de los PS. Ya que el empleo de métodos como el emparejamiento y la ponderación por PS ha demostrado ser eficaz para reducir el impacto de las covariables que podrían confundir la relación entre el tratamiento y los resultados observados, especialmente en estudios no aleatorizados, como se menciona en Kane et al. (2020)[53] y Chen et al. (2022)[54].

5.1. Importancia de los Datos Simulados

Esta exploración de los datos fue posible gracias a que la simulación de los mismos resultó ser efectiva, generando variables con un peso significativo en las probabilidades de exposición y en la mejoría de los individuos. Al observar las Tablas de Correlaciones con Exposición y Resultado (4.7 y 4.8), se aprecia que la Edad y el Estado Funcional presentaban una asociación significativa que se mantuvo constante a lo largo del estudio. Esto es coherente con la premisa de que a mayor edad y mejor estado funcional, habría una mayor probabilidad de ser tratado. No obstante, esta representación también introduce un sesgo que se ha intentado mitigar utilizando Propensity Scores. El hecho de que los datos se basaran en justificaciones reales de otros estudios aumenta la validez externa, pero no implica que estas asociaciones no puedan crear tendencias que influyan negativamente en la probabilidad de las personas de recibir tratamiento médico

(vease Apartado 3.3.5). La importancia de identificar las fuentes de sesgo en la investigación es crucial, como se discute en el artículo de Sinnappah et al. (2023)[55], lo que proporciona un marco valioso para diseñar estudios de adherencia y desarrollar herramientas para mitigar los efectos del sesgo en la investigación sobre adherencia a la medicación.

5.2. Balance y Sesgo de Género

La tabla 4.36 muestra los cambios que ha habido en los balances de las principales variables con mayor impacto en la probabilidad de exposición. Al inicio del estudio nos encontramos con que los hombres estaban siendo sobreexpuestos al tratamiento en detrimento de las mujeres (Figura 4.6). Este sesgo, inducido durante la simulación, fue corregido tras el uso del Emparejamiento, donde vimos que la cantidad de hombres no expuestos aumentaba a un 48.9 % en comparación al 43.3 % antes del Emparejamiento. En el caso de la Ponderación, la diferencia de exposición fue casi mínima.

Tras este balanceo, en el caso del Emparejamiento, encontramos que la prueba de Chi-Cuadrado ya no indicaba una asociación entre la probabilidad de exposición y el género. Sin embargo, ahora sí aparecía una asociación con el Nivel Socioeconómico (ver Tabla 4.26 y 4.33). Esto sugiere que el desequilibrio inicial por sexo en la muestra podría haber enmascarado el verdadero efecto del nivel socioeconómico en la exposición o adherencia al tratamiento. El balance logrado permitió descubrir relaciones subyacentes más claras entre las covariables y el tratamiento. Este hallazgo sugiere, además, que se podría realizar un análisis más profundo de las influencias socioeconómicas

En el Modelo de Regresión Logística con PS, ya fuera Emparejamiento o Ponderación, el género del individuo no tenía un efecto significativo en la probabilidad de exposición. Suceso que sí ocurría en los modelos donde no se había aplicado PS (ver Tabla 4.33). Este balanceo del género conlleva implicaciones prácticas para el diseño de futuras intervenciones equitativas en salud, como ya se ha realizado aplicando PS en otros campos como la violencia hacia las mujeres[56] o el sesgo de género en encuestas[42].

En resumen, estos resultados muestran cómo los Propensity Scores mejoran significativamente el balance entre grupos de exposición. Mientras que el emparejamiento reduce notablemente las diferencias iniciales, la ponderación logra un equilibrio casi perfecto en todas las covariables clave. Esto resalta la efectividad de ambos métodos para minimizar el sesgo en estudios observacionales[57, 58].

5.3. Diferencias en los Modelos de Regresión Logística

Observando las covariables significativas en cada Modelo (Tabla 4.33), vemos que los Modelos sin Propensity Scores muestran patrones claros en la probabilidad de exposición al tratamiento según diversas covariables. Por ejemplo, los resultados indican que los hombres tienen una mayor probabilidad de exposición, mientras que una mayor edad, un mejor estado funcional y un mayor nivel educativo también se asocian con una mayor probabilidad de recibir tratamiento. En contraste, una mayor cantidad de comorbilidades se asocia con una menor probabilidad de exposición

Al balancear estos grupos, en el Modelo de PS con Emparejamiento, la relación con el sexo desaparece al igual que con el nivel educativo. Y si nos fijamos en el Modelo de PS con Ponderación, solo Comorbilidades presenta asociación, mientras que Apoyo Familiar emerge como covariable significativa también.

Una plausible explicación podría ser que, al aplicar el emparejamiento, las diferencias iniciales entre grupos respecto al sexo y al nivel educativo se equilibran, haciendo que estas variables dejen de ser estadísticamente significativas. Esto se debe a que el emparejamiento selecciona subconjuntos de datos donde las distribuciones de estas covariables son comparables entre los grupos tratados y no tratados, reduciendo el sesgo de selección. Otra posible razón es que exista una correlación de estas variables con otras covariables incluidas en el modelo y que hayan perdido su influencia debido a la colinealidad.

En el caso de la Ponderación, los cambios podrían explicarse también debido a que al asignar pesos ajustados a cada observación, amplifica la importancia de variables previamente menos destacadas y detecta relaciones más sutiles en el conjunto de datos balanceado.

Estos cambios subrayan la capacidad de los Propensity Scores no solo para equilibrar grupos sino también para redefinir las dinámicas de las covariables en el análisis, permitiendo identificar factores influyentes que podrían haber sido ignorados inicialmente debido al sesgo sistemático en los datos sin ajustar.

5.3.1. Diferencias en la validación de los Modelos

Si observamos los Modelos de Regresión Logística que se han generado, vemos que ha habido una disminución del AUC al aplicar PS (Tabla 4.34). Esto refleja en parte el éxito en el balanceo, aunque a costa de la capacidad predictiva del modelo. Es importante señalar que esta disminución no necesariamente implica que el modelo sea peor, sino que más bien el modelo balanceado ofrece una relación más realista entre las covariables y la exposición, sin las influencias causadas por los desequilibrios iniciales.

La Tabla 4.11 muestra las métricas ROC, sensibilidad y especificidad para los distintos modelos. El Modelo sin PS alcanza un equilibrio razonable entre sensibilidad (0.379) y especificidad (0.908) con un AUC de 0.76, lo que refleja una capacidad predictiva global adecuada aunque con una sensibilidad limitada para identificar pacientes que han sido expuestos al tratamiento.

Mientras que el Modelo con PS por Emparejamiento presenta una AUC reducida (0.672) con una especificidad muy alta (0.990) pero una sensibilidad extremadamente baja (0.053). Esto sugiere que el modelo se vuelve más conservador, clasificando correctamente a la mayoría de los no expuestos pero identificando incorrectamente a muchos de los expuestos.

El peor rendimiento lo presenta el Modelo con PS por Ponderación, ya que no solo muestra un AUC significativamente más bajo (0.480) sino también un mal equilibrio entre sensibilidad (0.417) y especificidad (0.534). Esto podría deberse a la mayor varianza introducida por la ponderación (debido a los pesos) y a una mayor sensibilidad a variaciones en los datos.

Estos hallazgos pueden colocarnos en la tesitura de decidir qué es más importante, si una mejor precisión predictiva o un mejor balance de covariables. En el caso de este estudio, los PS han logrado un equilibrio ético y metodológico superior al minimizar los sesgos, aunque esto se haya traducido en una reducción del rendimiento del Modelo Logístico.

Esta reducción de rendimiento no debería interpretarse únicamente como una desventaja. Más bien, podría explicarse como una consecuencia inherente al esfuerzo por equilibrar las

covariables, para obtener un análisis menos sesgado. Este enfoque sería particularmente crucial en estudios observacionales donde el sesgo por confusión puede distorsionar los resultados (vease el Apartado 2.1).

5.4. Limitaciones y Trabajos Futuros

Aunque el presente trabajo ha demostrado la utilidad de los PS para mejorar la validez de estudios observacionales mediante la simulación de datos, existen varias limitaciones y oportunidades para futuras investigaciones que podrían ampliar el alcance de este estudio.

5.4.1. Métodos Alternativos de Propensity Scores

Por ejemplo, en este estudio se han implementado dos métodos principales: Emparejamiento (Matching) con reemplazo y cercanía (Nearest Neighbor Matching) y Ponderación mediante IPW. Sin embargo, no se exploraron otras técnicas disponibles, como la Estratificación (Stratification)[20] y el Emparejamiento Genético[59], que podrían ofrecer ventajas adicionales según las características de los datos.

A esto se le añade, que para el Emparejamiento se utilizó Nearest Neighbor como único modelo de clasificación en el proceso de estimación de Propensity Scores. Dado que el rendimiento del balance de covariables puede ser sensible al método de clasificación seleccionado, explorar algoritmos alternativos como Support Vector Machines (SVM) o redes neuronales podría ser interesante como se hizo en Hasanah et al., (2018)[60] que obtuvo una reducción del sesgo del 16.65 % y una precisión del 70.00 % en su estudio utilizando SVM.

5.4.2. Limitaciones de la Simulación de Datos

Por otro lado, aunque la simulación de datos nos permitió controlar y analizar escenarios específicos, no representa completamente la complejidad de datos observacionales reales. Las relaciones entre covariables en estudios del mundo real pueden ser más complejas o involucrar factores desconocidos no reflejados en las simulaciones. Por tanto, futuros estudios deberían validar estos hallazgos utilizando datos observacionales reales de estudios clínicos para comprobar la efectividad de los PS en condiciones no controladas o con datos faltantes, como bien explica Zhao et al., (2021)[7].

5.4.3. Evaluación del Sesgo Interseccional

El presente estudio se centró principalmente en incluir en el análisis sesgo de género debido a que la mujer ha sido infrarepresentada en estudios de salud (vease 2.4). Sin embargo, otros factores demográficos como la etnia, situación laboral o inclusión en la sociedad podrían interactuar como variables confusoras. Futuros trabajos deberían aplicar modelos multivariantes que analicen estos factores desde una perspectiva interseccional para obtener una comprensión más completa del sesgo en los estudios observacionales.

5.4.4. Inclusión de Interacciones en los Modelos

Para simplificar el análisis, no se consideraron interacciones entre variables, como, por ejemplo, la interacción entre sexo y edad (**sexo*edad**). Incluir estos términos en futuros análisis permitiría capturar mejor las relaciones complejas entre las covariables y el tratamiento, proporcionando resultados más realistas y detallados.

5.4.5. Impacto de las Covariables en los Resultados Clínicos

Por último, mencionar que el objetivo principal era evaluar la efectividad de los PS para balancear covariables y mejorar la validez de estudios observacionales simulados, con un enfoque en la probabilidad de ser tratado (exposición al tratamiento) en función de las covariables seleccionadas. Aunque se logró el balance deseado en las covariables mediante el uso de PS, no se exploró el análisis detallado del impacto de dichas covariables en el resultado del tratamiento (si mejora o no mejora). Este enfoque se justificó por la prioridad de demostrar la validez del método de balanceo antes de abordar los efectos causales de las covariables sobre los resultados. En futuros trabajos, resultaría valioso analizar cómo las covariables balanceadas influyen directamente en los resultados clínicos simulados. Este análisis permitiría determinar no solo la validez del balance, sino también la efectividad del tratamiento ajustado por sesgos de género y otras variables de interés.

Capítulo 6

Conclusiones

- Este trabajo ha demostrado que el uso de Propensity Scores (PS) mejora la validez interna de los estudios observacionales al reducir el sesgo de selección y ajustar las covariables clave entre los grupos de tratamiento y control. Los métodos de Emparejamiento y Ponderación demostraron ser efectivos para mitigar el sesgo de género en la adherencia a los tratamientos, lo que refuerza la importancia de considerar el sesgo en la investigación médica.
- Los resultados obtenidos con los PS, aunque con una ligera disminución en la capacidad predictiva de los modelos, muestran que el balance alcanzado permite una interpretación más precisa y realista de los datos, lo que es esencial para obtener conclusiones válidas en estudios no aleatorizados.
- La simulación de datos facilitó el análisis controlado de las relaciones entre covariables, aunque se recomienda la validación de estos hallazgos con datos observacionales reales en investigaciones futuras. Además, es necesario explorar más a fondo los métodos alternativos de Propensity Scores y evaluar otros factores demográficos y las interacciones entre variables, lo cual podría mejorar aún más el ajuste y la efectividad de los modelos.

6.1. Reflexión crítica sobre el logro de los objetivos planteados inicialmente

A lo largo del curso, se ha intentado seguir la planificación propuesta en el apartado 1.6. Sin embargo, se han encontrado complicaciones, como puede observarse en el apartado 1.6.1. Afortunadamente, el análisis de riesgos presentado en el apartado 1.7 ayudó a solventar en parte estas complicaciones.

La metodología inicialmente propuesta resultó en ciertos aspectos insuficiente, ya que conforme se avanzaba en el trabajo, surgían nuevas preguntas, lo que requería delimitar la información necesaria para cumplir con los objetivos del trabajo principal. A esto se añadió la adquisición de nuevos conocimientos necesarios para obtener los resultados presentados, así como para mantener la estructura y enfoque del trabajo.

Los objetivos, tanto generales como específicos del trabajo (apartado 1.3), se han cumplido. Se generaron datos simulados sobre adherencia al tratamiento, lo que permitió utilizar los PS

para mitigar el desbalance de covariables y reducir el sesgo de género, además de presentar las diferencias de resultados entre un Método Tradicional de Regresión Logística y otro con PS.

Respecto al apartado 1.4, que trata sobre Ética y Responsabilidad, se lograron implementar todos los objetivos planteados, incluyendo la representación del sesgo de género y la disminución de costes mediante un estudio con Datos Simulados.

En cuanto a las líneas de trabajo futuro, la mayoría han sido exploradas en el apartado 5.4.

En conclusión, a pesar de los desafíos enfrentados durante el desarrollo del trabajo, los objetivos planteados inicialmente se han cumplido satisfactoriamente. El uso de PS demostró ser eficaz para mejorar el balance entre grupos de tratamiento y reducir el sesgo, permitiendo una evaluación más precisa y ética del tratamiento. La experiencia adquirida y los resultados obtenidos sirven de base sólida para futuras investigaciones en este campo, destacando la importancia de la metodología y el análisis riguroso en estudios observacionales.

Glosario

- **ap_familiar**: Apoyo familiar
- **AUC**: Área bajo la curva
- **c_depen**: Cuidado de dependientes
- **comorb**: Comorbilidades
- **CRISP-DM**: Cross Industry Standard Process for Data Mining
- **E. funcional**: Estado funcional
- **expo**: Exposición
- **IPW**: Pesos inversos de probabilidad de tratamiento
- **IQR**: Método del Rango Intercuartílico
- **n_educ**: Nivel de educación
- **n_socio**: Nivel socioeconómico
- **ODS**: Objetivos de Desarrollo Sostenible 2030, ONU
- **p_expo**: Probabilidad de exposición
- **prob_Y**: Probabilidad de Y
- **PS**: Propensity Scores
- **result (Y)**: Resultado (Y)
- **ROC**: Curva Característica Operativa del Receptor
- **SD**: Desviaciones Estándar
- **SMD**: Diferencias de Medias Estandarizadas
- **SVM**: Support Vector Machines
- **TFM**: Trabajo de Fin de Máster

Anexos

A.1. Tablas de Frecuencia

A continuación, se presentan las tablas de frecuencia de las variables analizadas en el estudio:

Sexo	Frecuencia
Femenino	499
Masculino	501

Cuadro A.1: Tabla de frecuencias de Sexo.

Tabaquismo	Frecuencia
No	709
Sí	291

Cuadro A.2: Tabla de frecuencias de Tabaquismo.

Nivel Socioeconómico	Frecuencia
Bajo	298
Medio	496
Alto	206

Cuadro A.3: Tabla de frecuencias de Nivel Socioeconómico.

Comorbilidades	Frecuencia
0	144
1	252
2	269
3	186
4	95
5	37
6	9
7	7
8	1

Cuadro A.4: Tabla de frecuencias de Comorbilidades.

Cuidado de Dependientes	Frecuencia
No	792
Sí	208

Cuadro A.5: Tabla de frecuencias de Cuidado de Dependientes.

Apoyo Familiar	Frecuencia
Bajo	313
Medio	477
Alto	210

Cuadro A.6: Tabla de frecuencias de Apoyo Familiar.

Nivel de Educación	Frecuencia
Bajo	175
Medio	398
Alto	427

Cuadro A.7: Tabla de frecuencias de Nivel de Educación.

Exposición	Frecuencia
No	293
Sí	707

Cuadro A.8: Tabla de frecuencias de Exposición.

Resultado	Frecuencia
No mejora	376
Mejora	624

Cuadro A.9: Tabla de frecuencias de Resultado.

A.2. RMarkdown de Datos Simulados

Datos Simulados - TFM Evaluación de Propensity Scores

Adrián Martínez Requena

2024-2025

Contents

Paquetes utilizados	1
Generación de Variable Exposición (X), Resultado (Y) y Covariables	1
Exploración de los datos	3
Gráficos	6
Distribución de sexos	6
Mapa de calor de las correlaciones	7

Paquetes utilizados

```
# Para maquetación
library(knitr)
# Simulación de datos
library(simstudy)
# Manipulación de datos
library(dplyr)
# Diseño de Gráficos
library(ggplot2)
# Transformación de datos para el mapa de calor
library(reshape2)
# Función para truncar una variable (en este caso la edad)
library(truncnorm)
truncar <- function(n, mean, sd, min_val) {
  valores <- rtruncnorm(n, a = min_val, mean = mean, sd = sd)
  return(round(valores))
}
```

Generación de Variable Exposición (X), Resultado (Y) y Covariables


```

# Se ha utilizado como semilla una fecha conocida por el
# autor
set.seed(19780301)

# Sexo donde 0 = Mujer, 1 = Hombre (misma probabilidad)
def <- defData(varname = "sexo", dist = "binary", formula = 0.5)

# Tabaquismo donde 0 = No, 1 = Sí (30% fumadores)
def <- defData(def, varname = "tabaquismo", dist = "binary",
  formula = 0.3)

# Nivel Socioeconómico donde 1 = Bajo, 2 = Medio, 3 = Alto
# (30%, 50%, 20%)
def <- defData(def, varname = "nivel_socioeconomico", dist = "categorical",
  formula = "0.3;0.5;0.2")

# Estado funcional, Uniforme entre 0 y 100
def <- defData(def, varname = "estado_funcional", dist = "uniform",
  formula = "0;100")

# Comorbilidades desde 0 a más, media de 2
def <- defData(def, varname = "comorbilidades", dist = "poisson",
  formula = 2)

# Cuidado de dependientes donde 0 = No, 1 = Sí (20%
# cuidadores)
def <- defData(def, varname = "cuidado_dependientes", dist = "binary",
  formula = 0.2)

# Apoyo familiar donde 1 = Bajo, 2 = Medio, 3 = Alto (30%,
# 50%, 20%)
def <- defData(def, varname = "apoyo_familiar", dist = "categorical",
  formula = "0.3;0.5;0.2")

# Nivel de educación: 1 = Básico, 2 = Intermedio, 3 =
# Avanzado (proporciones 20%, 40%, 40%)
def <- defData(def, varname = "nivel_educacion", dist = "categorical",
  formula = "0.2;0.4;0.4")

# Reunimos todas estas covariables en un dataframe y
# añadimos 1000 participantes
datos <- genData(1000, def)

# Ahora, añadimos en el dataframe la edad, truncandola con
# la función.
datos[, edad := truncar(.N, 50, 15, 18)] # Desviación típica de 15

# Damos valor a cada peso para la función de Exposición (X)
pesoX_sexo <- 0.4
pesoX_edad <- 0.03
pesoX_tabaquismo <- -0.05
pesoX_comorbilidades <- -0.08
pesoX_estadofuncional <- 0.03

```

```

pesoX_nivelsocioeconomico <- 0.01
pesoX_cuidadodependientes <- -0.02
pesoX_apoyofamiliar <- 0.03
pesoX_niveleduccion <- 0.02

# Establecemos el intercepto
intercepto <- -2

# Sacamos la probabilidad de exposición
datos[, prob_exposicion := plogis(intercepto + pesoX_sexo *
  sexo + pesoX_edad * edad + pesoX_tabaquismo * tabaquismo +
  pesoX_comorbilidades * comorbilidades + pesoX_estadofuncional *
  estado_funcional + pesoX_nivelsocioeconomico * nivel_socioeconomico +
  pesoX_cuidadodependientes * cuidado_dependientes + pesoX_apoyofamiliar *
  apoyo_familiar + pesoX_niveleduccion * nivel_educacion)]

# Generamos la variable Exposición (X)
datos[, exposicion := rbinom(.N, size = 1, prob = prob_exposicion)]

# Damos valor a cada peso para la función del Resultado (Y)
pesoY_sexo <- -0.1
pesoY_edad <- -0.04
pesoY_tabaquismo <- -0.08
pesoY_comorbilidades <- -0.1
pesoY_estadofuncional <- 0.1
pesoY_nivelsocioeconomico <- 0.05
pesoY_cuidadodependientes <- -0.02
pesoY_apoyofamiliar <- 0.05
pesoY_niveleduccion <- 0.07
pesoY_exposicion <- 0.5

# Calcular log-odds para el resultado (Y)
datos[, log_odds_Y := intercepto + pesoY_sexo * sexo + pesoY_edad *
  edad + pesoY_tabaquismo * tabaquismo + pesoY_comorbilidades *
  comorbilidades + pesoY_estadofuncional * estado_funcional +
  pesoY_nivelsocioeconomico * nivel_socioeconomico + pesoY_cuidadodependientes *
  cuidado_dependientes + pesoY_apoyofamiliar * apoyo_familiar +
  pesoY_niveleduccion * nivel_educacion + pesoY_exposicion *
  exposicion]

# Convertimos log-odds a probabilidades
datos[, prob_Y := plogis(log_odds_Y)]

# Generamos la variable binaria de resultado (0 = no
# mejora, 1 = mejora)
datos[, resultado := rbinom(.N, size = 1, prob = prob_Y)]

```

Exploración de los datos

```

# Exploramos los datos que se han generado
str(datos)

```

```
## Classes 'data.table' and 'data.frame': 1000 obs. of 15 variables:
## $ id : int 1 2 3 4 5 6 7 8 9 10 ...
## $ sexo : int 1 0 0 1 0 1 0 0 1 0 ...
## $ tabaquismo : int 0 0 1 0 1 0 0 0 0 0 ...
## $ nivel_socioeconomico: int 3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional : num 47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int 1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: int 0 0 0 1 0 0 1 0 0 0 ...
## $ apoyo_familiar : int 1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion : int 3 1 1 1 3 3 1 2 1 2 ...
## $ edad : num 51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion : num 0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion : int 0 1 1 1 1 1 0 0 1 1 ...
## $ log_odds_Y : num 0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y : num 0.721 0.86 0.316 0.993 0.339 ...
## $ resultado : int 0 1 1 1 0 1 0 0 1 0 ...
## - attr(*, ".internal.selfref")=<externalptr>
## - attr(*, "sorted")= chr "id"
```

```
head(datos) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
1	1	0	3	47.79371	1	0	1	3	51	0.8027880	0	0.9493709	0.7209886	0
2	0	0	2	51.77346	0	0	1	1	52	0.7655234	1	1.8173460	0.8602474	1
3	0	1	2	20.19209	4	0	2	1	27	0.2985447	1	-0.7707915	0.3163079	1
4	1	0	2	89.86442	3	1	3	1	60	0.9408069	1	4.9864423	0.9932164	1
5	0	1	2	34.01018	1	0	2	3	70	0.7558952	1	-0.6689822	0.3387248	0
6	1	0	2	40.11481	3	0	2	3	63	0.8011415	1	0.0014809	0.5003702	1

```
tail(datos) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
995	1	0	3	85.743637	1	0	2	2	41	0.9048495	1	5.624364	0.9964041	1
996	0	0	3	9.189060	1	0	1	3	84	0.6975529	0	-4.131094	0.0158113	0
997	0	0	3	11.126783	0	0	3	2	53	0.5209386	1	-2.067322	0.1123138	0
998	1	0	1	83.915613	0	0	2	1	43	0.9086672	1	5.291561	0.9949913	1
999	1	1	3	55.555770	4	1	2	2	27	0.6494615	0	2.265577	0.9059857	1
1000	1	0	1	6.638573	0	1	2	3	62	0.6385687	1	-3.076143	0.0441021	0

```
# Observamos la variable Exposición (X)
summary(datos$prob_exposicion)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.2012  0.5944  0.7578  0.7207  0.8692  0.9754
```

```
kable(table(datos$exposicion))
```

Var1	Freq
0	293
1	707

```
# Y los Resultados (Y)
kable(table(datos$resultado))
```

Var1	Freq
0	376
1	624

```
# Usamos Dplyr para generar nuevas tablas que nos permitan
# seguir explorando
id_prob_exposicion <- datos %>%
  select(id, prob_exposicion, exposicion)

# Seleccionamos a todos los participantes y los dividimos
# por sexo y si están expuestos o no
id_exposicion_sexo <- datos %>%
  select(id, sexo, prob_exposicion, exposicion)
resumen_exposicion <- id_exposicion_sexo %>%
  group_by(sexo, exposicion) %>%
  summarise(n = n()) %>%
  arrange(sexo, exposicion)
kable(resumen_exposicion)
```

sexo	exposicion	n
0	0	166
0	1	333
1	0	127
1	1	374

```
# Sacamos la tasa de exposición por sexo
tasas_exposicion_sexo <- datos[, .(tasa_exposicion = mean(exposicion)),
  by = sexo]
kable(tasas_exposicion_sexo)
```

sexo	tasa_exposicion
1	0.7465070
0	0.6673347

```
# Calculamos las correlaciones para la exposición (X)
correlaciones <- datos[, lapply(.SD, function(x) cor(x, exposicion,
  use = "complete.obs")), .SDcols = c("edad", "sexo", "tabaquismo",
  "comorbilidades", "estado_funcional", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")]
```

```
correlaciones %>%
  kable(format = "latex", booktabs = TRUE, caption = "Correlaciones de las covariables
    con la exposición (X)") %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```

Table 5: Correlaciones de las covariables con la exposición (X)

edad	sexo	tabaquismo	comorbilidades	estado_funcional	nivel_socioeconomico	cuidado_dependientes	apoyo_familiar	nivel_educacion
0.1891018	0.0869759	0.0206206	-0.0623909	0.3444763	0.0157432	0.0051102	-0.0220353	0.0623849

```
# Calculamos las correlaciones con el resultado (Y)
correlaciones_y <- datos[, lapply(.SD, function(x) cor(x, resultado,
  use = "complete.obs")), .SDcols = c("edad", "sexo", "tabaquismo",
  "comorbilidades", "estado_funcional", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")]
correlaciones_y %>%
  kable(format = "latex", booktabs = TRUE, caption = "Correlaciones de las covariables
    con el resultado (Y)") %>%
  kable_styling(latex_options = c("striped", "hold_position",
    "scale_down"))
```


Table 6: Correlaciones de las covariables con el resultado (Y)

edad	sexo	tabaquismo	comorbilidades	estado_funcional	nivel_socioeconomico	cuidado_dependientes	apoyo_familiar	nivel_educacion
-0.108946	-0.0232215	0.0246163	0.0172061	0.7399989	0.0862465	-0.0345475	-0.0165202	-0.0063244

Gráficos

Distribución de sexos

```
# Gráfico para ver cómo se han distribuido los dos sexos
ggplot(datos, aes(x = prob_exposicion, fill = as.factor(sexo))) +
  geom_density(alpha = 0.5) + scale_fill_manual(values = c(`0` = "red",
  `1` = "darkblue"), labels = c("Mujer", "Hombre")) + labs(title = "Probabilidad de
    exposición por sexo",
  fill = "Sexo", x = "Probabilidad de Exposición", y = "Densidad") +
  theme_minimal() + theme(plot.title = element_text(hjust = 0.5,
  size = 14), legend.position = "top")
```




Mapa de calor de las correlaciones

```
# Convertimos el data.table a data.frame para facilitar el
# manejo
correlaciones_df <- as.data.frame(t(correlaciones))

# Añadimos una columna con los nombres de las variables
correlaciones_df$Variable <- rownames(correlaciones_df)


# Generamos el Mapa de Calor
correlaciones_melt <- melt(correlaciones_df, id.vars = "Variable")
library(ggplot2)
ggplot(correlaciones_melt, aes(x = Variable, y = variable, fill = value)) +
  geom_tile(color = "white") + scale_fill_gradient2(low = "blue",
  high = "#C30E59", mid = "white", midpoint = 0, limit = c(-1,
  1), space = "Lab", name = "Correlación") + theme_minimal() +
  labs(title = "Mapa de calor de correlaciones con la exposición",
  x = "Covariables", y = "Exposición") + theme(axis.text.x = element_text(angle = 45,
  vjust = 1, hjust = 1), plot.title = element_text(hjust = 0.5,
  size = 14))
```



```
# Convertimos el data.table a data.frame para el mapa de
# calor
correlaciones_y_df <- as.data.frame(t(correlaciones_y))

# Añadimos una columna con los nombres de las variables
correlaciones_y_df$Variable <- rownames(correlaciones_y_df)

# Generamos el Mapa de Calor
correlaciones_y_melt <- melt(correlaciones_y_df, id.vars = "Variable")
ggplot(correlaciones_y_melt, aes(x = Variable, y = variable,
  fill = value)) + geom_tile(color = "white") + scale_fill_gradient2(low = "blue",
  high = "#C30E59", mid = "white", midpoint = 0, limit = c(-1,
  1), space = "Lab", name = "Correlación") + theme_minimal() +
  labs(title = "Mapa de calor de correlaciones con el resultado",
    x = "Covariables", y = "Resultado") + theme(axis.text.x = element_text(angle = 45,
  vjust = 1, hjust = 1), plot.title = element_text(hjust = 0.5,
  size = 14))
```



```
# Por último exportamos los datos en .csv y en .rds para
# trabajar con ellos durante el análisis
write.csv(datos, "C:/Users/navia/Desktop/TFM/Datos Simulados/datos.csv",
          row.names = FALSE)
saveRDS(datos, "C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
```


A.3. RMarkdown de Análisis de Datos

Análisis de Datos - TFM

Adrián Martínez Requena

2024-2025

Contents

Importación de los datos	3
Importación del .rds generado en la simulación de datos	3
Exploración del dataframe	3
Visualización y Análisis de los datos	5
Conversión de las variables a factores	5
Comprobación de normalidad y presencia de outliers	6
Test de Shapiro-Wilk	6
Presencia de Outliers con el método IQR	6
Gráficos de barras de variables categóricas	7
Gráficos de variables numéricas	11
Análisis de relación de covariables vs. resultado	17
Boxplots para variables numéricas según el resultado	17
Histogramas/densidades por nivel de resultado:	20
Evaluación de multicolinealidad entre las variables numéricas	22
Matriz de correlación	22
Análisis de relación de las covariables vs. exposición	24
Gráficos de barras y boxplots	24
Prueba Chi-cuadrado (Covariables categóricas vs Exposición)	29
Prueba Mann-Whitney U (Covariables numéricas vs Exposición)	30
Análisis de Regresión Logística	31
Modelo Inicial (Incluye todas las covariables)	31
Gráfico de residuos	34
Distancias de Cook	35
Curva ROC	36
Modelo refinado con Stepwise	36

Residuos del modelo	39
Distancias de Cook	40
Curva ROC	40
Validación cruzada con 10 pliegues	41
Propensity Scores	41
Generación de datos y calculo de Propensity Scores	41
Tabla de Balance Inicial	41
LovePlot del Balance Inicial	42
Matching (Emparejamiento)	43
Matching Inicial con Reemplazamiento	43
Tabla de balance del Matching Inicial con Reemplazamiento	45
Matching aplicando todas las variables cuyo SMD > 0.1	45
Tabla de Balance del Matching con variables cuyo SMD > 0.1	47
Matching con sexo, edad, estado funcional y comorbilidades (Version Final)	48
Tabla de balance del Matching Final	49
Comparativa del balance de los 4 modelos	49
Love Plot del Matching Completo	50
Love Plot del Matching Final	50
Análisis de Regresión Logística con los datos balanceados por PS Matching	51
Asociación de los nuevos datos con Exposición	52
Modelo balanceado con Matching (PS)	54
Gráfico de residuos	56
Distancias de Cook	57
Curva ROC	57
Modelo balanceado refinado con Stepwise	58
Residuos del modelo	61
Distancias de Cook	62
Curva ROC	62
Validación cruzada con 10 pliegues	63
Comparación Modelos con y sin Propensity Scores	63
Ponderación (Weighting)	64
Cálculo de Pesos Inversos de Probabilidad de Tratamiento (IPW)	64
Evaluación del Balance de Covariables Posterior a la Ponderación	64

Modelo ponderado usando los pesos IPW	65
Residuos del modelo	67
Distancias de Cook	67
Curva ROC	68
Validación cruzada con 10 pliegues	68
Apéndice	69
Código	69

```

# Maquetación del documento
library(knitr)
# Para maquetación de tablas
library(kableExtra)
# Para resúmenes detallados de datos
library(skimr)
# Manipulación y transformación de datos
library(dplyr)
# Creación de gráficos
library(ggplot2)
# Funciones estadísticas (incluye glm)
library(stats)
# Herramientas para la creación y evaluación de modelos
library(caret)
# Visualización y análisis de curvas ROC
library(pROC)
# Para mapas de calor
library(reshape2)
# Genera gráficos y tablas de equilibrio
library(cobalt)
# Para tablas de datos que nos permitan calcular SMD
library(tableone)
# Para Propensity Scores y Matching
library(MatchIt)
# Para manejo de estadísticas en modelos lineales
library(survey)

```

Importación de los datos

Importación del .rds generado en la simulación de datos

```
datos <- readRDS("C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
```

Exploración del dataframe

```
## Clase del dataframe
```

```
## [1] "data.table" "data.frame"
```

Primeras 3 filas

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
1	1	0	3	47.79371	1	0	1	3	51	0.8027880	0	0.9493709	0.7209886	0
2	0	0	2	51.77346	0	0	1	1	52	0.7655234	1	1.8173460	0.8602474	1
3	0	1	2	20.19209	4	0	2	1	27	0.2985447	1	-0.7707915	0.3163079	1

Últimas 3 filas

id	sexo	tabaquismo	nivel_socioeconomico	estado_funcional	comorbilidades	cuidado_dependientes	apoyo_familiar	nivel_educacion	edad	prob_exposicion	exposicion	log_odds_Y	prob_Y	resultado
998	1	0	1	83.915613	0	0	2	1	43	0.9086672	1	5.291561	0.9949913	1
999	1	1	3	55.555770	4	1	2	2	27	0.6494615	0	2.265577	0.9059857	1
1000	1	0	1	6.638573	0	1	2	3	62	0.6385687	1	-3.076143	0.0441021	0

Estructura del dataframe

Classes 'data.table' and 'data.frame': 1000 obs. of 15 variables:

```
## $ id          : int  1 2 3 4 5 6 7 8 9 10 ...
## $ sexo        : int  1 0 0 1 0 1 0 0 1 0 ...
## $ tabaquismo   : int  0 0 1 0 1 0 0 0 0 0 ...
## $ nivel_socioeconomico: int  3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional : num  47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int  1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: int  0 0 0 1 0 0 1 0 0 0 ...
## $ apoyo_familiar : int  1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion : int  3 1 1 1 3 3 1 2 1 2 ...
## $ edad         : num  51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion : num  0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion    : int  0 1 1 1 1 1 0 0 1 1 ...
## $ log_odds_Y    : num  0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y        : num  0.721 0.86 0.316 0.993 0.339 ...
## $ resultado     : int  0 1 1 1 0 1 0 0 1 0 ...
## - attr(*, ".internal.selfref")=<externalptr>
## - attr(*, "sorted")= chr "id"
```

Resumen general del dataframe

Table 1: Data summary

Name	datos
Number of rows	1000
Number of columns	15
Key	id
Column type frequency:	
numeric	15
Group variables	None

Variable type: numeric

skim_variable	n_missing	complete	rat	mean	sd	p0	p25	p50	p75	p100	hist
id	0	1	500.50	288.82	1.00	250.75	500.50	750.25	1000.00		
sexo	0	1	0.50	0.50	0.00	0.00	1.00	1.00	1.00		
tabaquismo	0	1	0.29	0.45	0.00	0.00	0.00	1.00	1.00		
nivel_socioeconomico	0	1	1.91	0.70	1.00	1.00	2.00	2.00	3.00		
estado_funcional	0	1	49.99	29.23	0.05	25.49	49.97	76.16	99.98		
comorbilidades	0	1	2.02	1.44	0.00	1.00	2.00	3.00	8.00		
cuidado_dependientes	0	1	0.21	0.41	0.00	0.00	0.00	0.00	1.00		
apoyo_familiar	0	1	1.90	0.72	1.00	1.00	2.00	2.00	3.00		
nivel_educacion	0	1	2.25	0.73	1.00	2.00	2.00	3.00	3.00		
edad	0	1	50.25	14.42	18.00	41.00	50.00	60.00	104.00		
prob_exposicion	0	1	0.72	0.18	0.20	0.59	0.76	0.87	0.98		
exposicion	0	1	0.71	0.46	0.00	0.00	1.00	1.00	1.00		
log_odds_Y	0	1	1.41	3.06	-	-1.14	1.48	4.07	7.62		
					4.73						
prob_Y	0	1	0.63	0.37	0.01	0.24	0.81	0.98	1.00		
resultado	0	1	0.62	0.48	0.00	0.00	1.00	1.00	1.00		

Visualización y Análisis de los datos

Conversión de las variables a factores

```
# Duplicamos el dataframe
datostransformados = data.frame(datos)

# Convertimos las variables a factores usando el paquete
# dplyr
datostransformados <- datostransformados %>%
  mutate(sexo = factor(sexo, levels = c(0, 1), labels = c("Femenino",
    "Masculino")), tabaquismo = factor(tabaquismo, levels = c(0,
    1), labels = c("No", "Sí")), nivel_socioeconomico = factor(nivel_socioeconomico,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
  cuidado_dependientes = factor(cuidado_dependientes, levels = c(0,
    1), labels = c("No", "Sí")), apoyo_familiar = factor(apoyo_familiar,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio",
    "Alto")), nivel_educacion = factor(nivel_educacion,
    levels = c(1, 2, 3), labels = c("Bajo", "Medio",
    "Alto")), exposicion = factor(exposicion, levels = c(0,
    1), labels = c("No", "Sí")), resultado = factor(resultado,
    levels = c(0, 1), labels = c("No mejora", "Mejora")))

# Vemos que se hayan convertido
str(datostransformados)

## 'data.frame':    1000 obs. of  15 variables:
## $ id              : int  1 2 3 4 5 6 7 8 9 10 ...
## $ sexo            : Factor w/ 2 levels "Femenino","Masculino": 2 1 1 2 1 2 1 1 2 1 ...
## $ tabaquismo      : Factor w/ 2 levels "No","Sí": 1 1 2 1 2 1 1 1 1 1 ...
## $ nivel_socioeconomico: Factor w/ 3 levels "Bajo","Medio",...: 3 2 2 2 2 2 2 2 2 1 ...
## $ estado_funcional  : num  47.8 51.8 20.2 89.9 34 ...
```

```
## $ comorbilidades      : int   1 0 4 3 1 3 0 4 3 1 ...
## $ cuidado_dependientes: Factor w/ 2 levels "No","Sí": 1 1 1 2 1 1 2 1 1 1 ...
## $ apoyo_familiar      : Factor w/ 3 levels "Bajo","Medio",...: 1 1 2 3 2 2 1 3 1 2 ...
## $ nivel_educacion     : Factor w/ 3 levels "Bajo","Medio",...: 3 1 1 1 3 3 1 2 1 2 ...
## $ edad                : num   51 52 27 60 70 63 62 35 57 56 ...
## $ prob_exposicion     : num   0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion          : Factor w/ 2 levels "No","Sí": 1 2 2 2 2 2 1 1 2 2 ...
## $ log_odds_Y          : num   0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y              : num   0.721 0.86 0.316 0.993 0.339 ...
## $ resultado           : Factor w/ 2 levels "No mejora","Mejora": 1 2 2 2 1 2 1 1 2 1 ...
```

Se ha duplicado el dataframe original para tenerlo intacto y se han transformado diversas variables en la copia llamada ahora 'datostransformados'. **Se han convertido las siguientes variables en factores:** sexo, tabaquismo, nivel_socioeconomico, cuidado_dependientes, apoyo_familiar, nivel_educacion, exposicion y resultado

Comprobación de normalidad y presencia de outliers

Test de Shapiro-Wilk

```
## Resultados test de Shapiro-Wilk
```

```
##          estado_funcional comorbilidades      edad prob_exposicion
## statistic.W    9.504027e-01  9.225290e-01 9.927595e-01  9.405449e-01
## p_value        7.555354e-18  2.966285e-22 8.460238e-05  1.413741e-19
##          log_odds_Y      prob_Y
## statistic.W 9.634191e-01 8.129798e-01
## p_value     3.849268e-15 1.668164e-32
```

Los datos no siguen la distribución normal, esto es normal para el estilo de variables que son, especialmente log_odds_Y y prob_Y

Presencia de Outliers con el método IQR

```
## Outliers de estado_funcional
```

```
## $limites
## inferior.25% superior.75%
##    -50.52325    152.17254
##
## $outliers
## integer(0)
```

```
## Outliers de edad
```

```
## $limites
## inferior.25% superior.75%
##      12.5      88.5
##
## $outliers
## integer(0)
```

```
## Outliers de prob_exposicion
```

```
## $limites
## inferior.25% superior.75%
##    0.1821079    1.2814788
##
## $outliers
## integer(0)
```

```
## Outliers de log_odds_Y
```

```
## $limites
## inferior.25% superior.75%
##   -8.94656    11.87617
##
## $outliers
## integer(0)
```

```
## Outliers de comorbilidades
```

```
## $limites
## inferior.25% superior.75%
##        -2         6
##
## $outliers
## integer(0)
```

```
## Outliers de prob_Y
```

```
## $limites
## inferior.25% superior.75%
##  -0.8680115    2.0938792
##
## $outliers
## integer(0)
```


No se han detectado outliers

Gráficos de barras de variables categóricas


```
# Creamos una lista que incluya todas las variables
# categóricas
categoricas <- c("sexo", "tabaquismo", "nivel_socioeconomico",
  "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")



# Hacemos un bucle for para sacar todos los gráficos
for (variable in categoricas) {
  plot_categoricas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_bar(fill = "slateblue3", color = "black") + labs(title = paste("Distribución de",
    variable), x = variable, y = "Frecuencia") + theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_categoricas)
}
```



Distribución de sexo



Distribución de tabaquismo









Gráficos de variables numéricas


Histograma y densidad de estado_funcional




Histograma y densidad de comorbilidades




Histograma y densidad de edad




Histograma y densidad de prob_exposicion




Histograma y densidad de log_odds_Y




Histograma y densidad de prob_Y




Boxplot de estado_funcional




Boxplot de comorbilidades




Boxplot de edad




Boxplot de prob_exposicion



Boxplot de log_odds_Y





Boxplot de prob_Y




Análisis de relación de covariables vs. resultado


Boxplots para variables numéricas según el resultado





Boxplot de edad según el resultado







Boxplot de prob_exposicion según el resultado







Histogramas/densidades por nivel de resultado:








Evaluación de multicolinealidad entre las variables numéricas

Matriz de correlación

	estado_funcional	comorbilidades	edad	prob_exposicion	log_odds_Y	prob_Y
estado_funcional	1.0000000	0.0392922	-0.0182999	0.8590554	0.9808638	0.9387940
comorbilidades	0.0392922	1.0000000	0.0234687	-0.0774455	-0.0090231	0.0046628
edad	-0.0182999	-0.0234687	1.0000000	0.3890940	0.1904099	0.1562687
prob_exposicion	0.8590554	-0.0774455	0.3890940	1.0000000	0.7786849	0.7788618
log_odds_Y	0.9808638	-0.0090231	0.1904099	0.7786849	1.0000000	0.9520679
prob_Y	0.9387940	0.0046628	0.1562687	0.7788618	0.9520679	1.0000000




Hay fuertes correlaciones entre estado_funcional, prob_exposicion, log_odds_Y y prob_Y, mientras que comorbilidades y edad muestran una menor correlación con las otras variables. Esto es lógico porque ya hemos ido viendo que en la simulación ha salido que el estado_funcional ha tenido mucho impacto a la hora de la exposición y resultado.


Análisis de relación de las covariables vs. exposición

Gráficos de barras y boxplots


Distribución de sexo por Exposición




Distribución de tabaquismo por Exposición







Distribución de nivel_socioeconomico por Exposición







Distribución de cuidado_dependientes por Exposición











Prueba Chi-cuadrado (Covariables categóricas vs Exposición)

```
## [1] "Prueba Chi-cuadrado para sexo"
##
```

```
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 7.1874, df = 1, p-value = 0.007342
##
## [1] "Prueba Chi-cuadrado para tabaquismo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 0.33132, df = 1, p-value = 0.5649
##
## [1] "Prueba Chi-cuadrado para nivel_socioeconomico"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 4.0228, df = 2, p-value = 0.1338
##
## [1] "Prueba Chi-cuadrado para cuidado_dependientes"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla
## X-squared = 0.0057768, df = 1, p-value = 0.9394
##
## [1] "Prueba Chi-cuadrado para apoyo_familiar"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 3.5424, df = 2, p-value = 0.1701
##
## [1] "Prueba Chi-cuadrado para nivel_educacion"
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 5.8662, df = 2, p-value = 0.05323
```

Solo sexo muestra una asociación significativa con exposicion (se ha inducido correctamente el sesgo), mientras que las otras variables categóricas no muestran asociaciones significativas con exposicion.

Prueba Mann-Whitney U (Covariables numéricas vs Exposición)

```
## [1] "Prueba de Mann-Whitney para estado_funcional"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 58202, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
```

```
## [1] "Prueba de Mann-Whitney para comorbilidades"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 112015, p-value = 0.0377
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para edad"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 79154, p-value = 4.196e-09
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_exposicion"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 50406, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para log_odds_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 55232, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datostransformados[[variable]] by datostransformados$exposicion
## W = 55232, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
```

Todas las variables numéricas muestran diferencias significativas entre los grupos de exposicion.

Los que han sido expuestos tienen un mejor estado funcional, menor comorbilidades, mayor edad. Además, como es lógico también tiene mayor probabilidad de mejora.

Análisis de Regresión Logística

Modelo Inicial (Incluye todas las covariables)

```
modelo_inicial <- glm(exposicion ~ sexo + edad + estado_funcional +
  nivel_socioeconomico + cuidado_dependientes + apoyo_familiar +
```

```
nivel_educacion + tabaquismo + comorbilidades, data = datostransformados,
family = binomial)
modelo_inicial
```

```
##
## Call: glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## cuidado_dependientes + apoyo_familiar + nivel_educacion +
## tabaquismo + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             (Intercept)                sexoMasculino
##                -2.74440                  0.44582
##                edad                estado_funcional
##                0.03833                  0.03149
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##                0.24390                  -0.13573
## cuidado_dependientesSí        apoyo_familiarMedio
##                0.01807                  0.24127
## apoyo_familiarAlto        nivel_educacionMedio
##                -0.10265                  0.06243
## nivel_educacionAlto        tabaquismoSí
##                0.45557                  0.10185
## comorbilidades
##                -0.14684
##
## Degrees of Freedom: 999 Total (i.e. Null); 987 Residual
## Null Deviance: 1210
## Residual Deviance: 1010 AIC: 1036
```

Según el modelo sexo, edad, estado_funcional, nivel_socioeconomico, apoyo_familiar y nivel_educacion tienen un efecto significativo sobre las probabilidades de exposicion.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## cuidado_dependientes + apoyo_familiar + nivel_educacion +
## tabaquismo + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -2.74440    0.438751  -6.255 3.97e-10 ***
## sexoMasculino    0.445821   0.156067   2.857 0.00428 **
## edad           0.038334   0.005818   6.589 4.43e-11 ***
## estado_funcional 0.031493   0.002969  10.607 < 2e-16 ***
## nivel_socioeconomicoMedio 0.243901   0.178713   1.365 0.17233
## nivel_socioeconomicoAlto -0.135730   0.216615  -0.627 0.53092
## cuidado_dependientesSí 0.018075   0.191209   0.095 0.92469
## apoyo_familiarMedio 0.241270   0.179993   1.340 0.18010
## apoyo_familiarAlto -0.102652   0.213028  -0.482 0.62990
## nivel_educacionMedio 0.062433   0.216231   0.289 0.77278
```



```
## nivel_educacionAlto      0.455566    0.218123    2.089  0.03675 *
## tabaquismoSí            0.101849    0.172154    0.592  0.55411
## comorbilidades          -0.146844    0.053540   -2.743  0.00609 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1209.6  on 999  degrees of freedom
## Residual deviance: 1010.3  on 987  degrees of freedom
## AIC: 1036.3
##
## Number of Fisher Scoring iterations: 4

## Odd Ratios

##              (Intercept)              sexoMasculino              edad
##              0.06428685              1.56177184              1.03907806
## estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##              1.03199432              1.27621779              0.87307844
## cuidado_dependientesSí apoyo_familiarMedio apoyo_familiarAlto
##              1.01823925              1.27286416              0.90244084
## nivel_educacionMedio nivel_educacionAlto tabaquismoSí
##              1.06442330              1.57706625              1.10721665
## comorbilidades
##              0.86342870

## Intervalos de Confianza para los Odds Ratios

##              2.5 %    97.5 %
## (Intercept)    0.0268764 0.1503480
## sexoMasculino  1.1514787 2.1240770
## edad          1.0274751 1.0512004
## estado_funcional 1.0261198 1.0381444
## nivel_socioeconomicoMedio 0.8982410 1.8110552
## nivel_socioeconomicoAlto 0.5711574 1.3364880
## cuidado_dependientesSí 0.7023681 1.4878275
## apoyo_familiarMedio 0.8938312 1.8113087
## apoyo_familiarAlto 0.5946386 1.3719286
## nivel_educacionMedio 0.6945459 1.6230558
## nivel_educacionAlto 1.0262031 2.4160927
## tabaquismoSí 0.7918679 1.5561521
## comorbilidades 0.7771861 0.9589514
```

Ser hombre aumenta las probabilidades de exposición (OR = 1.5618).


Cuanta más edad más probabilidades de exposición (OR = 1.0391).

Mejor estado funcional está asociado con mayores probabilidades de exposición (OR = 1.0320).

Tener un nivel alto de educación se asocia con un aumento en las probabilidades de exposición (OR = 1.5771).


Tener más comorbilidades disminuye las probabilidades de exposición (OR = 0.8634).

Gráfico de residuos




El modelo tiene un ajuste correcto

Distancias de Cook



El modelo tiene un ajuste bueno, con diversas muestras más influyentes que otras

Curva ROC



```
## Area under the curve: 0.7688
```

La curva ROC nos indica que el modelo está bien ajustado

Modelo refinado con Stepwise

```
# Aplicamos una regresión stepwise al modelo
modelo_refinado <- step(modelo_inicial, direction = "both")
```

```
## Start: AIC=1036.26
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##   cuidado_dependientes + apoyo_familiar + nivel_educacion +
##   tabaquismo + comorbilidades
##
##           Df Deviance    AIC
## - cuidado_dependientes  1   1010.3 1034.3
## - tabaquismo            1   1010.6 1034.6
## - apoyo_familiar        2   1013.8 1035.8
## <none>                  1010.3 1036.3
## - nivel_socioeconomico  2   1014.3 1036.3
## - nivel_educacion       2   1017.2 1039.2
## - comorbilidades        1   1017.8 1041.8
## - sexo                  1   1018.5 1042.5
## - edad                  1   1057.9 1081.9
```

```

## - estado_funcional      1    1144.9 1168.9
##
## Step:  AIC=1034.27
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + nivel_educacion + tabaquismo + comorbilidades
##
##              Df Deviance    AIC
## - tabaquismo      1    1010.6 1032.6
## - apoyo_familiar   2    1013.9 1033.8
## <none>              1010.3 1034.3
## - nivel_socioeconomico 2    1014.3 1034.3
## + cuidado_dependientes 1    1010.3 1036.3
## - nivel_educacion    2    1017.2 1037.2
## - comorbilidades     1    1017.8 1039.8
## - sexo               1    1018.6 1040.6
## - edad               1    1058.0 1080.0
## - estado_funcional   1    1144.9 1166.9
##
## Step:  AIC=1032.62
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + nivel_educacion + comorbilidades
##
##              Df Deviance    AIC
## - apoyo_familiar     2    1014.2 1032.2
## <none>                1010.6 1032.6
## - nivel_socioeconomico 2    1014.7 1032.7
## + tabaquismo         1    1010.3 1034.3
## + cuidado_dependientes 1    1010.6 1034.6
## - nivel_educacion    2    1017.7 1035.7
## - comorbilidades     1    1018.1 1038.1
## - sexo               1    1018.8 1038.8
## - edad               1    1058.2 1078.2
## - estado_funcional   1    1145.4 1165.4
##
## Step:  AIC=1032.19
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + comorbilidades
##
##              Df Deviance    AIC
## <none>              1014.2 1032.2
## - nivel_socioeconomico 2    1018.3 1032.3
## + apoyo_familiar     2    1010.6 1032.6
## + tabaquismo         1    1013.9 1033.8
## + cuidado_dependientes 1    1014.2 1034.2
## - nivel_educacion    2    1021.5 1035.5
## - comorbilidades     1    1022.0 1038.0
## - sexo               1    1022.0 1038.0
## - edad               1    1061.3 1077.3
## - estado_funcional   1    1148.9 1164.9

```

```

# Vemos el resultado
modelo_refinado

```

```

##

```

```
## Call: glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## nivel_educacion + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             (Intercept)              sexoMasculino
##             -2.58821              0.43230
##             edad              estado_funcional
##             0.03801              0.03139
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##             0.24419              -0.13578
## nivel_educacionMedio      nivel_educacionAlto
##             0.05168              0.45933
##             comorbilidades
##             -0.14903
##
## Degrees of Freedom: 999 Total (i.e. Null); 991 Residual
## Null Deviance: 1210
## Residual Deviance: 1014 AIC: 1032
```

El stepwise ha eliminado las variables: cuidado_dependientes, tabaquismo y apoyo_familiar

Las variables significativas en el modelo refinado son: sexoMasculino, edad, estado_funcional, nivel_educacionAlto y comorbilidades

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
## nivel_educacion + comorbilidades, family = binomial, data = datostransformados)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -2.588213   0.405924  -6.376 1.82e-10 ***
## sexoMasculino  0.432304   0.155074   2.788  0.00531 **
## edad          0.038005   0.005794   6.559 5.40e-11 ***
## estado_funcional 0.031394   0.002956  10.619 < 2e-16 ***
## nivel_socioeconomicoMedio 0.244186   0.178258   1.370  0.17074
## nivel_socioeconomicoAlto -0.135783   0.215978  -0.629  0.52955
## nivel_educacionMedio  0.051681   0.215356   0.240  0.81035
## nivel_educacionAlto  0.459331   0.218213   2.105  0.03529 *
## comorbilidades -0.149032   0.053361  -2.793  0.00522 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1209.6 on 999 degrees of freedom
## Residual deviance: 1014.2 on 991 degrees of freedom
## AIC: 1032.2
##
## Number of Fisher Scoring iterations: 4
##
## Odd Ratios
```

```
##           (Intercept)           sexoMasculino           edad
##           0.07515419           1.54080331           1.03873672
##           estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##           1.03189148           1.27658112           0.87303223
##           nivel_educacionMedio           nivel_educacionAlto           comorbilidades
##           1.05303983           1.58301474           0.86154127
```


```
## Intervalos de Confianza para los Odds Ratios
```

```
##           2.5 %    97.5 %
## (Intercept)    0.03353802 0.1649546
## sexoMasculino    1.13814619 2.0912896
## edad            1.02718375 1.0508030
## estado_funcional 1.02604159 1.0380135
## nivel_socioeconomicoMedio 0.89927969 1.8099026
## nivel_socioeconomicoAlto 0.57183511 1.3347228
## nivel_educacionMedio    0.68825440 1.6028269
## nivel_educacionAlto    1.02989492 2.4256297
## comorbilidades    0.77575224 0.9565043
```

Resultados parecidos a los del modelo sin refinar.


Residuos del modelo

Residuos de Deviance




Distancias de Cook

Distancia de Cook



Curva ROC

Curva ROC




```
## Area under the curve: 0.7678
```

Igual que el modelo inicial

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 1000 samples
##    6 predictor
##    2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 900, 900, 900, 900, 901, 900, ...
## Resampling results:
##
##      ROC          Sens          Spec
## 0.7607771 0.3790805 0.9080282
```

El valor de ROC es bueno, la sensibilidad es bastante baja y la especificidad es muy buena.

Propensity Scores

Generación de datos y calculo de Propensity Scores

```
# Establecemos semilla
set.seed(19780301)

# Copiamos los datos
datos_ps <- data.frame(datostransformados)

# Extraemos los Propensity Scores
datos_ps$propensity_score <- predict(modelo_inicial, type = "response")

# Calculamos la desviación estándar de los PS en caso de
# que sean necesarias
sd_ps <- sd(datos_ps$distance, na.rm = TRUE)

# Sacamos el summary
summary(datos_ps$propensity_score)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.1394  0.5684  0.7563  0.7070  0.8790  0.9855
```

Tabla de Balance Inicial

```
# Definimos las covariables a evaluar
covariables <- c("sexo", "tabaquismo", "nivel_socioeconomico",
  "estado_funcional", "comorbilidades", "cuidado_dependientes",
  "apoyo_familiar", "nivel_educacion", "edad")

# Creamos la tabla de balance inicial para ver las
# diferencias de medias estandarizadas (SMD)
tabla_balance <- CreateTableOne(vars = covariables, strata = "exposicion",
  data = datos_ps, test = FALSE)
```

```
## [1] "Tabla de Balance con los resultados de SMD"
```

```
##                               Stratified by exposicion
##                               No           Sí           SMD
##  n                               293           707
##  sexo = Masculino (%)           127 (43.3)       374 (52.9)   0.192
##  tabaquismo = Sí (%)            81 (27.6)       210 (29.7)   0.046
##  nivel_socioeconomico (%)
##    Bajo                        97 (33.1)       201 (28.4)
##    Medio                       131 (44.7)       365 (51.6)
##    Alto                        65 (22.2)       141 (19.9)
##  estado_funcional (mean (SD))  34.35 (27.06)  56.46 (27.61)  0.809
##  comorbilidades (mean (SD))   2.16 (1.44)   1.97 (1.44)   0.137
##  cuidado_dependientes = Sí (%)  60 (20.5)    148 (20.9)   0.011
##  apoyo_familiar (%)
##    Bajo                        94 (32.1)       219 (31.0)
##    Medio                       128 (43.7)       349 (49.4)
##    Alto                        71 (24.2)       139 (19.7)
##  nivel_educacion (%)
##    Bajo                        55 (18.8)       120 (17.0)
##    Medio                       130 (44.4)       268 (37.9)
##    Alto                        108 (36.9)       319 (45.1)
##  edad (mean (SD))             46.02 (13.35)  52.01 (14.49)  0.430
```

Las variables que presentan un peor balance son: Estado funcional (SMD = 0.809), Edad (SMD = 0.430) y Sexo (Masculino %, SMD = 0.192) Por otro lado, las variables que superan el umbral de SMD < 0.1 también incluyen: Nivel socioeconómico, Comorbilidades, Apoyo familiar y Nivel de educación:

LovePlot del Balance Inicial


```
# Establecemos la semilla
set.seed(19780301)

# Sacamos la formula del balance
formula_balance <- exposicion ~ sexo + tabaquismo + nivel_socioeconomico +
  estado_funcional + comorbilidades + cuidado_dependientes +
  apoyo_familiar + nivel_educacion + edad

# Utilizamos la formula para sacar los datos que nos
# permitan hacer el Love Plot
```

```
bal_tab <- bal.tab(formula_balance, data = datos_ps)

# Creamos el Love Plot para el balance inicial
love.plot(bal_tab, threshold = 0.1, var.order = "unadjusted",
  stat = "mean.diffs", abs = TRUE, colors = c("red", "blue"),
  stars = "raw")
```



El LovePlot muestra diferencias con la tabla de balance generada anteriormente. Esto puede ser debido a cómo calculan las diferencias cada uno. Así que en un principio vamos a tener en cuenta comorbilidades también para el balanceo.

Matching (Emparejamiento)

Se han realizado tres tipos de emparejamiento diferentes que se presentan a continuación y se ha seleccionado el que se ha considerado más apropiado para el estudio.

Matching Inicial con Reemplazamiento

Se realizó un análisis de balance de datos utilizando el método de emparejamiento por el vecino más cercano (nearest) con reemplazo.

```
# Establecemos la semilla
set.seed(19780301)

# Aplicamos el matching utilizando solo las 3 variables más
# desbalanceadas
```

```
matching_replace <- matchit(formula = exposicion ~ sexo + edad +
  estado_funcional, data = datos_ps, method = "nearest", distance = "logit",
  replace = TRUE)
```

```
# Mostramos los resultados
```

```
summary(matching_replace)
```

```
##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional,
## data = datos_ps, method = "nearest", distance = "logit",
## replace = TRUE)
##
## Summary of Balance for All Data:
##
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7578	0.5845	1.0757	0.6899
sexoFemenino	0.4710	0.5666	-0.1914	.
sexoMasculino	0.5290	0.4334	0.1914	.
edad	52.0057	46.0171	0.4133	1.1777
estado_funcional	56.4633	34.3543	0.8008	1.0409

```
##
## eCDF Mean eCDF Max
## distance 0.2529 0.3775
## sexoFemenino 0.0955 0.0955
## sexoMasculino 0.0955 0.0955
## edad 0.0773 0.1716
## estado_funcional 0.2190 0.3275
##
## Summary of Balance for Matched Data:
##
```

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio
distance	0.7578	0.7575	0.0019	0.9929
sexoFemenino	0.4710	0.4993	-0.0567	.
sexoMasculino	0.5290	0.5007	0.0567	.
edad	52.0057	50.2560	0.1207	1.2425
estado_funcional	56.4633	58.6774	-0.0802	0.8912

```
##
## eCDF Mean eCDF Max Std. Pair Dist.
## distance 0.0033 0.0325 0.0095
## sexoFemenino 0.0283 0.0283 0.9748
## sexoMasculino 0.0283 0.0283 0.9748
## edad 0.0258 0.0877 0.9555
## estado_funcional 0.0330 0.0948 0.6187
##
## Sample Sizes:
##
```

	Control	Treated
All	293.	707
Matched (ESS)	83.66	707
Matched	184.	707
Unmatched	109.	0
Discarded	0.	0

Se ha reducido el desbalance en Sexo (Masculino %), ahora hay una proporción similar de hombres en ambos grupos (52.9% en expuestos vs 50.07% en controles), con un SMD de 0.0567.

Lo mismo con media de edad en los grupos emparejados se equilibró mejor (52.01 años en expuestos vs 50.26 años en controles), SMD de 0.1207.

La diferencia en el estado funcional también se redujo (media de 56.46 en expuestos vs 58.68 en controles), SMD de -0.0802.

El proceso de emparejamiento mejoró significativamente el balance entre los grupos expuestos y no expuestos en términos de sexo, edad y estado funcional. Las diferencias estandarizadas medias (SMD) disminuyeron, indicando una mayor equivalencia entre los grupos.

Tabla de balance del Matching Inicial con Reemplazamiento

##	Stratified by exposicion		SMD
	No	Sí	
## n	184	707	
## sexo = Masculino (%)	89 (48.4)	374 (52.9)	0.091
## tabaquismo = Sí (%)	54 (29.3)	210 (29.7)	0.008
## nivel_socioeconomico (%)			0.176
## Bajo	60 (32.6)	201 (28.4)	
## Medio	79 (42.9)	365 (51.6)	
## Alto	45 (24.5)	141 (19.9)	
## estado_funcional (mean (SD))	41.79 (27.90)	56.46 (27.61)	0.529
## comorbilidades (mean (SD))	2.28 (1.44)	1.97 (1.44)	0.216
## cuidado_dependientes = Sí (%)	34 (18.5)	148 (20.9)	0.062
## apoyo_familiar (%)			0.163
## Bajo	59 (32.1)	219 (31.0)	
## Medio	78 (42.4)	349 (49.4)	
## Alto	47 (25.5)	139 (19.7)	
## nivel_educacion (%)			0.193
## Bajo	39 (21.2)	120 (17.0)	
## Medio	79 (42.9)	268 (37.9)	
## Alto	66 (35.9)	319 (45.1)	
## edad (mean (SD))	48.67 (12.76)	52.01 (14.49)	0.244

El balance de: Sexo, Estado Funcional y Edad ha disminuido, pero los demás han aumentado.

Matching aplicando todas las variables cuyo SMD > 0.1

```
# Semilla
set.seed(19780301)

# Modelo de Matching
matching_replace_all <- matchit(formula = exposicion ~ sexo +
  edad + estado_funcional + comorbilidades + nivel_socioeconomico +
  apoyo_familiar + nivel_educacion, data = datos_ps, method = "nearest",
  distance = "logit", replace = TRUE)

# Resultados
summary(matching_replace_all)
```

```
##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional +
##   comorbilidades + nivel_socioeconomico + apoyo_familiar +
```

```
## nivel_educacion, data = datos_ps, method = "nearest", distance = "logit",
## replace = TRUE)
```

```
##
## Summary of Balance for All Data:
```

	Means Treated	Means Control	Std. Mean Diff.
## distance	0.7630	0.5718	1.1246
## sexoFemenino	0.4710	0.5666	-0.1914
## sexoMasculino	0.5290	0.4334	0.1914
## edad	52.0057	46.0171	0.4133
## estado_funcional	56.4633	34.3543	0.8008
## comorbilidades	1.9661	2.1638	-0.1373
## nivel_socioeconomicoBajo	0.2843	0.3311	-0.1037
## nivel_socioeconomicoMedio	0.5163	0.4471	0.1384
## nivel_socioeconomicoAlto	0.1994	0.2218	-0.0561
## apoyo_familiarBajo	0.3098	0.3208	-0.0239
## apoyo_familiarMedio	0.4936	0.4369	0.1136
## apoyo_familiarAlto	0.1966	0.2423	-0.1150
## nivel_educacionBajo	0.1697	0.1877	-0.0479
## nivel_educacionMedio	0.3791	0.4437	-0.1332
## nivel_educacionAlto	0.4512	0.3686	0.1660

	Var. Ratio	eCDF Mean	eCDF Max
## distance	0.7293	0.2690	0.4079
## sexoFemenino	.	0.0955	0.0955
## sexoMasculino	.	0.0955	0.0955
## edad	1.1777	0.0773	0.1716
## estado_funcional	1.0409	0.2190	0.3275
## comorbilidades	0.9965	0.0248	0.0725
## nivel_socioeconomicoBajo	.	0.0468	0.0468
## nivel_socioeconomicoMedio	.	0.0692	0.0692
## nivel_socioeconomicoAlto	.	0.0224	0.0224
## apoyo_familiarBajo	.	0.0111	0.0111
## apoyo_familiarMedio	.	0.0568	0.0568
## apoyo_familiarAlto	.	0.0457	0.0457
## nivel_educacionBajo	.	0.0180	0.0180
## nivel_educacionMedio	.	0.0646	0.0646
## nivel_educacionAlto	.	0.0826	0.0826

```
##
## Summary of Balance for Matched Data:
```

	Means Treated	Means Control	Std. Mean Diff.
## distance	0.7630	0.7626	0.0024
## sexoFemenino	0.4710	0.4823	-0.0227
## sexoMasculino	0.5290	0.5177	0.0227
## edad	52.0057	53.2419	-0.0853
## estado_funcional	56.4633	58.3491	-0.0683
## comorbilidades	1.9661	2.3479	-0.2651
## nivel_socioeconomicoBajo	0.2843	0.2659	0.0408
## nivel_socioeconomicoMedio	0.5163	0.5050	0.0226
## nivel_socioeconomicoAlto	0.1994	0.2291	-0.0743
## apoyo_familiarBajo	0.3098	0.3055	0.0092
## apoyo_familiarMedio	0.4936	0.4371	0.1132
## apoyo_familiarAlto	0.1966	0.2574	-0.1530
## nivel_educacionBajo	0.1697	0.1980	-0.0754
## nivel_educacionMedio	0.3791	0.4229	-0.0904
## nivel_educacionAlto	0.4512	0.3791	0.1450

```
##                               Var. Ratio eCDF Mean eCDF Max Std. Pair Dist.
## distance                     0.9895    0.0043    0.0410          0.0111
## sexoFemenino                  .         0.0113    0.0113          0.9578
## sexoMasculino                 .         0.0113    0.0113          0.9578
## edad                         1.0064    0.0230    0.0962          0.9913
## estado_funcional              0.9358    0.0273    0.0778          0.6701
## comorbilidades                1.2701    0.0484    0.1881          1.0525
## nivel_socioeconomicoBajo      .         0.0184    0.0184          0.8560
## nivel_socioeconomicoMedio     .         0.0113    0.0113          0.9850
## nivel_socioeconomicoAlto      .         0.0297    0.0297          0.7965
## apoyo_familiarBajo            .         0.0042    0.0042          0.9085
## apoyo_familiarMedio           .         0.0566    0.0566          1.0072
## apoyo_familiarAlto            .         0.0608    0.0608          0.9075
## nivel_educacionBajo           .         0.0283    0.0283          0.7686
## nivel_educacionMedio          .         0.0438    0.0438          0.9475
## nivel_educacionAlto           .         0.0721    0.0721          0.8954
##
## Sample Sizes:
##                               Control Treated
## All                           293.        707
## Matched (ESS)                 61.22       707
## Matched                       178.        707
## Unmatched                     115.         0
## Discarded                      0.         0
```

El balanceo general ha mejorado, pero sigue habiendo valores altos de SMD que nos indican que la selección de todas las variables puede haber sido muy agresivo.

Tabla de Balance del Matching con variables cuyo SMD > 0.1

```
##                               Stratified by exposicion
##                               No      Sí      SMD
## n                             178      707
## sexo = Masculino (%)          80 (44.9) 374 (52.9) 0.160
## tabaquismo = Sí (%)           52 (29.2) 210 (29.7) 0.011
## nivel_socioeconomico (%)                                0.100
##   Bajo                        56 (31.5) 201 (28.4)
##   Medio                       83 (46.6) 365 (51.6)
##   Alto                        39 (21.9) 141 (19.9)
## estado_funcional (mean (SD)) 42.64 (27.83) 56.46 (27.61) 0.499
## comorbilidades (mean (SD))   2.16 (1.41) 1.97 (1.44) 0.138
## cuidado_dependientes = Sí (%) 35 (19.7) 148 (20.9) 0.032
## apoyo_familiar (%)                                0.056
##   Bajo                        54 (30.3) 219 (31.0)
##   Medio                       85 (47.8) 349 (49.4)
##   Alto                        39 (21.9) 139 (19.7)
## nivel_educacion (%)                                0.112
##   Bajo                        29 (16.3) 120 (17.0)
##   Medio                       77 (43.3) 268 (37.9)
##   Alto                        72 (40.4) 319 (45.1)
## edad (mean (SD))             47.76 (13.55) 52.01 (14.49) 0.303
```

Los valores de SMD son más bajos, indicando que ha habido un mejor balanceo que con el método que incluía solo 3 variables.

Matching con sexo, edad, estado funcional y comorbilidades (Version Final)

```

set.seed(19780301)
matching_replace_comorb <- matchit(formula = exposicion ~ sexo +
  edad + estado_funcional + comorbilidades, data = datos_ps,
  method = "nearest", distance = "logit", replace = TRUE)
summary(matching_replace_comorb)

##
## Call:
## matchit(formula = exposicion ~ sexo + edad + estado_funcional +
##   comorbilidades, data = datos_ps, method = "nearest", distance = "logit",
##   replace = TRUE)
##
## Summary of Balance for All Data:
##               Means Treated Means Control Std. Mean Diff. Var. Ratio
## distance           0.7595           0.5803           1.0989     0.6815
## sexoFemenino        0.4710           0.5666          -0.1914         .
## sexoMasculino        0.5290           0.4334           0.1914         .
## edad                52.0057          46.0171           0.4133     1.1777
## estado_funcional     56.4633          34.3543           0.8008     1.0409
## comorbilidades       1.9661           2.1638          -0.1373     0.9965
##               eCDF Mean eCDF Max
## distance           0.2575     0.3945
## sexoFemenino        0.0955     0.0955
## sexoMasculino        0.0955     0.0955
## edad                0.0773     0.1716
## estado_funcional     0.2190     0.3275
## comorbilidades       0.0248     0.0725
##
## Summary of Balance for Matched Data:
##               Means Treated Means Control Std. Mean Diff. Var. Ratio
## distance           0.7595           0.7589           0.0039     0.9951
## sexoFemenino        0.4710           0.4583           0.0255         .
## sexoMasculino        0.5290           0.5417          -0.0255         .
## edad                52.0057          52.2376          -0.0160     1.1654
## estado_funcional     56.4633          56.2264           0.0086     0.9536
## comorbilidades       1.9661           2.1358          -0.1178     1.3409
##               eCDF Mean eCDF Max Std. Pair Dist.
## distance           0.0040     0.0566           0.0115
## sexoFemenino        0.0127     0.0127           0.9549
## sexoMasculino        0.0127     0.0127           0.9549
## edad                0.0172     0.0523           0.9630
## estado_funcional     0.0143     0.0537           0.6668
## comorbilidades       0.0361     0.1216           1.0722
##
## Sample Sizes:
##               Control Treated
## All              293.       707
## Matched (ESS)     71.77      707
## Matched           188.       707
## Unmatched         105.         0
## Discarded          0.         0

```


Aunque todavía presenta leves desbalances, es el método que mejor ha balanceado globalmente todas las variable ya que las variables claves, que presentan más correlación con la exposición, han disminuído más.

Tabla de balance del Matching Final


##		Stratified by exposicion		SMD
		No	Sí	
##	n	188	707	
##	sexo = Masculino (%)	92 (48.9)	374 (52.9)	0.079
##	tabaquismo = Sí (%)	57 (30.3)	210 (29.7)	0.013
##	nivel_socioeconomico (%)			0.207
##	Bajo	62 (33.0)	201 (28.4)	
##	Medio	78 (41.5)	365 (51.6)	
##	Alto	48 (25.5)	141 (19.9)	
##	estado_funcional (mean (SD))	41.85 (27.65)	56.46 (27.61)	0.529
##	comorbilidades (mean (SD))	2.19 (1.41)	1.97 (1.44)	0.158
##	cuidado_dependientes = Sí (%)	42 (22.3)	148 (20.9)	0.034
##	apoyo_familiar (%)			0.182
##	Bajo	63 (33.5)	219 (31.0)	
##	Medio	77 (41.0)	349 (49.4)	
##	Alto	48 (25.5)	139 (19.7)	
##	nivel_educacion (%)			0.137
##	Bajo	39 (20.7)	120 (17.0)	
##	Medio	76 (40.4)	268 (37.9)	
##	Alto	73 (38.8)	319 (45.1)	
##	edad (mean (SD))	48.74 (12.81)	52.01 (14.49)	0.239

Comparativa del balance de los 4 modelos

##	Variable	Modelo_Original	Reemplazo	Reemplazo_Completo
## 1	n	293/707	184/707	178/707
## 2	sexo = Masculino (%)	0.192	0.091	0.160
## 3	tabaquismo = Sí (%)	0.046	0.008	0.011
## 4	nivel_socioeconomico	0.140	0.176	0.100
## 5	estado_funcional (mean (SD))	0.809	0.529	0.499
## 6	comorbilidades (mean (SD))	0.137	0.216	0.138
## 7	cuidado_dependientes = Sí (%)	0.011	0.062	0.032
## 8	apoyo_familiar	0.130	0.163	0.056
## 9	nivel_educacion	0.170	0.193	0.112
## 10	edad (mean (SD))	0.430	0.244	0.303
##	Reemplazo_Comorbilidades			
## 1	188/707			
## 2	0.079			
## 3	0.013			
## 4	0.207			
## 5	0.529			
## 6	0.158			
## 7	0.034			
## 8	0.182			
## 9	0.137			
## 10	0.239			


Love Plot del Matching Completo

```
love.plot(bal.tab(matching_replace_all), threshold = 0.1, var.order = "unadjusted",
  stat = "mean.diffs", abs = TRUE, colors = c("red", "blue"),
  stars = "raw")
```



Love Plot del Matching Final

```
# Visualizamos el Love Plot después del emparejamiento con
# comorbilidades
love.plot(bal.tab(matching_replace_comorb), threshold = 0.1,
  var.order = "unadjusted", stat = "mean.diffs", abs = TRUE,
  colors = c("red", "blue"), stars = "raw")
```



El emparejamiento con reemplazo añadiendo la variable comorbilidades parece ser la mejor opción en términos de balance y tamaño de muestra igualada.

Ya que este es el mejor balanceo para las variables más críticas, nos quedaremos con este.

Análisis de Regresión Logística con los datos balanceados por PS Matching

Vamos a trabajar con los datos que hemos obtenido del modelo que incluía el balanceo de edad, estado_funcional, sexo y comorbilidades.

```
## Classes 'matchdata' and 'data.frame': 895 obs. of 18 variables:
## $ id : int 1 2 3 4 5 6 7 9 10 11 ...
## $ sexo : Factor w/ 2 levels "Femenino","Masculino": 2 1 1 2 1 2 1 2 1 1 ...
## $ tabaquismo : Factor w/ 2 levels "No","Sí": 1 1 2 1 2 1 1 1 1 1 ...
## $ nivel_socioeconomico: Factor w/ 3 levels "Bajo","Medio",...: 3 2 2 2 2 2 2 2 1 2 ...
## $ estado_funcional : num 47.8 51.8 20.2 89.9 34 ...
## $ comorbilidades : int 1 0 4 3 1 3 0 3 1 2 ...
## $ cuidado_dependientes: Factor w/ 2 levels "No","Sí": 1 1 1 2 1 1 2 1 1 1 ...
## $ apoyo_familiar : Factor w/ 3 levels "Bajo","Medio",...: 1 1 2 3 2 2 1 1 2 1 ...
## $ nivel_educacion : Factor w/ 3 levels "Bajo","Medio",...: 3 1 1 1 3 3 1 1 2 2 ...
## $ edad : num 51 52 27 60 70 63 62 57 56 52 ...
## $ prob_exposicion : num 0.803 0.766 0.299 0.941 0.756 ...
## $ exposicion : Factor w/ 2 levels "No","Sí": 1 2 2 2 2 2 1 2 2 2 ...
## $ log_odds_Y : num 0.949 1.817 -0.771 4.986 -0.669 ...
## $ prob_Y : num 0.721 0.86 0.316 0.993 0.339 ...
## $ resultado : Factor w/ 2 levels "No mejora","Mejora": 1 2 2 2 1 2 1 2 1 2 ...
## $ propensity_score : num 0.792 0.755 0.255 0.928 0.871 ...
```

```
## $ distance          : num  0.803 0.784 0.235 0.941 0.781 ...
## $ weights           : num  1.86 1 1 1 1 ...
## - attr(*, "distance")= chr "distance"
## - attr(*, "weights")= chr "weights"
```

Asociación de los nuevos datos con Exposición

```
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
  tabla_balanceado <- table(datos_replace_comorb[[variable]],
    datos_replace_comorb$exposicion)
  prueba_chi_balanceado <- chisq.test(tabla_balanceado)
  print(paste("Prueba Chi-cuadrado para", variable))
  print(prueba_chi_balanceado)
}

## [1] "Prueba Chi-cuadrado para sexo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.78268, df = 1, p-value = 0.3763
##
## [1] "Prueba Chi-cuadrado para tabaquismo"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.0055423, df = 1, p-value = 0.9407
##
## [1] "Prueba Chi-cuadrado para nivel_socioeconomico"
##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 6.3253, df = 2, p-value = 0.04231
##
## [1] "Prueba Chi-cuadrado para cuidado_dependientes"
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabla_balanceado
## X-squared = 0.10172, df = 1, p-value = 0.7498
##
## [1] "Prueba Chi-cuadrado para apoyo_familiar"
##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 4.9578, df = 2, p-value = 0.08383
##
## [1] "Prueba Chi-cuadrado para nivel_educacion"
```

```
##
## Pearson's Chi-squared test
##
## data:  tabla_balanceado
## X-squared = 2.776, df = 2, p-value = 0.2496

# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon
# Rank-Sum Test)
for (variable in numericas) {
  wilcox_test_balanceado <- wilcox.test(datos_replace_comorb[[variable]] ~
    datos_replace_comorb$exposicion)

  print(paste("Prueba de Mann-Whitney para", variable))
  print(wilcox_test_balanceado)
}

## [1] "Prueba de Mann-Whitney para estado_funcional"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 46739, p-value = 3.868e-10
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para comorbilidades"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 72774, p-value = 0.04009
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para edad"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 57612, p-value = 0.004976
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_exposicion"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43222, p-value = 1.636e-13
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para log_odds_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43007, p-value = 9.776e-14
```

```
## alternative hypothesis: true location shift is not equal to 0
##
## [1] "Prueba de Mann-Whitney para prob_Y"
##
## Wilcoxon rank sum test with continuity correction
##
## data:  datos_replace_comorb[[variable]] by datos_replace_comorb$exposicion
## W = 43007, p-value = 9.776e-14
## alternative hypothesis: true location shift is not equal to 0
```

La principal diferencia es que al balancear los datos, el sexo ya no es significativo (se ha reducido el sesgo de género) y ha aparecido una asociación con el nivel socioeconómico.

Modelo balanceado con Matching (PS)

```
modelo_balanceado_matching <- glm(exposicion ~ sexo + edad +
  estado_funcional + nivel_socioeconomico + nivel_educacion +
  cuidado_dependientes + apoyo_familiar + tabaquismo + comorbilidades,
  data = datos_replace_comorb, family = binomial)
modelo_balanceado_matching

##
## Call:  glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##      (Intercept)              sexoMasculino
##      -1.04259                0.22680
##      edad              estado_funcional
##      0.02268                0.02083
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##      0.31308                -0.19085
##      nivel_educacionMedio nivel_educacionAlto
##      0.13461                0.40119
##      cuidado_dependientesSí apoyo_familiarMedio
##      -0.06475                0.24727
##      apoyo_familiarAlto      tabaquismoSí
##      -0.19941                -0.01229
##      comorbilidades
##      -0.13595
##
## Degrees of Freedom: 894 Total (i.e. Null); 882 Residual
## Null Deviance:      920.1
## Residual Deviance: 847.1      AIC: 873.1
```

Ser hombre, tener mayor edad o un nivel educativo alto aumenta las probabilidades de exposición, mientras que más comorbilidades las reducen. El AIC (873.1) sugiere que es un buen modelo.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.042590    0.486688  -2.142 0.032176 *
## sexoMasculino     0.226799    0.172535   1.315 0.188676
## edad              0.022684    0.006360   3.567 0.000361 ***
## estado_funcional  0.020825    0.003209   6.490 8.58e-11 ***
## nivel_socioeconomicoMedio 0.313077    0.199511   1.569 0.116595
## nivel_socioeconomicoAlto -0.190853    0.232068  -0.822 0.410849
## nivel_educacionMedio  0.134606    0.236773   0.569 0.569694
## nivel_educacionAlto   0.401187    0.235521   1.703 0.088493 .
## cuidado_dependientesSí -0.064755    0.208129  -0.311 0.755704
## apoyo_familiarMedio   0.247270    0.199837   1.237 0.215954
## apoyo_familiarAlto   -0.199413    0.230454  -0.865 0.386871
## tabaquismoSí        -0.012293    0.188451  -0.065 0.947988
## comorbilidades      -0.135954    0.058923  -2.307 0.021037 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 920.11  on 894  degrees of freedom
## Residual deviance: 847.09  on 882  degrees of freedom
## AIC: 873.09
##
## Number of Fisher Scoring iterations: 4

## Odd Ratios

##              (Intercept)              sexoMasculino              edad
##              0.3525403              1.2545773              1.0229428
##      estado_funcional nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##              1.0210435              1.3676271              0.8262541
##      nivel_educacionMedio      nivel_educacionAlto      cuidado_dependientesSí
##              1.1440857              1.4935959              0.9372975
##      apoyo_familiarMedio      apoyo_familiarAlto      tabaquismoSí
##              1.2805242              0.8192112              0.9877820
##      comorbilidades
##              0.8728831


## Intervalos de Confianza para los Odds Ratios

##              2.5 %    97.5 %
## (Intercept)    0.1349187 0.9113903
## sexoMasculino  0.8949286 1.7613805
## edad          1.0104141 1.0359478
## estado_funcional 1.0147272 1.0275877
## nivel_socioeconomicoMedio 0.9232237 2.0205138
```


```
## nivel_socioeconomicoAlto  0.5246048  1.3049727
## nivel_educacionMedio      0.7150578  1.8124305
## nivel_educacionAlto      0.9362904  2.3617349
## cuidado_dependientesSí    0.6273995  1.4210233
## apoyo_familiarMedio       0.8639118  1.8931801
## apoyo_familiarAlto        0.5218309  1.2898908
## tabaquismoSí              0.6853100  1.4361495
## comorbilidades            0.7778147  0.9802792
```

El modelo nos indica que la exposición está más relacionada con factores como la edad, el estado funcional y comorbilidades, mientras que las demás variables tienen menor impacto al no ser significativas.


Gráfico de residuos



Distancias de Cook



Curva ROC



```
## Area under the curve: 0.6969
```

Modelo balanceado refinado con Stepwise

```
modelo_refinado_balanceado <- step(modelo_balanceado_matching,  
  direction = "both")
```

```
## Start: AIC=873.09  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
## nivel_educacion + cuidado_dependientes + apoyo_familiar +  
## tabaquismo + comorbilidades
```

```
##  
##           Df Deviance    AIC  
## - tabaquismo      1   847.09 871.09  
## - cuidado_dependientes 1   847.19 871.19  
## - nivel_educacion   2   850.59 872.59  
## - sexo              1   848.82 872.82  
## <none>              847.09 873.09  
## - apoyo_familiar    2   851.50 873.50  
## - nivel_socioeconomico 2   852.94 874.94  
## - comorbilidades    1   852.35 876.35  
## - edad              1   860.32 884.32  
## - estado_funcional  1   892.39 916.39
```

```
## Step: AIC=871.09  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
## nivel_educacion + cuidado_dependientes + apoyo_familiar +  
## comorbilidades
```

```
##  
##           Df Deviance    AIC  
## - cuidado_dependientes 1   847.19 869.19  
## - nivel_educacion       2   850.60 870.60  
## - sexo                  1   848.84 870.84  
## <none>                  847.09 871.09  
## - apoyo_familiar        2   851.51 871.51  
## - nivel_socioeconomico  2   852.94 872.94  
## + tabaquismo            1   847.09 873.09  
## - comorbilidades        1   852.36 874.36  
## - edad                  1   860.35 882.35  
## - estado_funcional      1   892.39 914.39
```

```
## Step: AIC=869.19  
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +  
## nivel_educacion + apoyo_familiar + comorbilidades
```

```
##  
##           Df Deviance    AIC  
## - nivel_educacion       2   850.70 868.70  
## - sexo                  1   848.89 868.89  
## <none>                  847.19 869.19  
## - apoyo_familiar        2   851.60 869.60  
## - nivel_socioeconomico  2   853.09 871.09  
## + cuidado_dependientes  1   847.09 871.09
```

```

## + tabaquismo          1    847.19 871.19
## - comorbilidades      1    852.50 872.50
## - edad                1    860.36 880.36
## - estado_funcional    1    892.59 912.59
##
## Step: AIC=868.7
## exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades
##
##              Df Deviance    AIC
## - sexo              1    852.36 868.36
## <none>              1    850.70 868.70
## - apoyo_familiar     2    855.14 869.14
## + nivel_educacion     2    847.19 869.19
## - nivel_socioeconomico 2    856.43 870.43
## + cuidado_dependientes 1    850.60 870.60
## + tabaquismo         1    850.70 870.70
## - comorbilidades     1    855.79 871.79
## - edad              1    864.08 880.08
## - estado_funcional   1    895.55 911.55
##
## Step: AIC=868.36
## exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades
##
##              Df Deviance    AIC
## <none>              1    852.36 868.36
## - apoyo_familiar     2    856.63 868.63
## + sexo              1    850.70 868.70
## + nivel_educacion     2    848.89 868.89
## - nivel_socioeconomico 2    858.13 870.13
## + cuidado_dependientes 1    852.29 870.29
## + tabaquismo         1    852.35 870.35
## - comorbilidades     1    857.21 871.21
## - edad              1    865.44 879.44
## - estado_funcional   1    896.80 910.80

```

```

modelo_refinado_balanceado

```

```

##
## Call: glm(formula = exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              (Intercept)              edad
##              -0.70600              0.02235
##              estado_funcional nivel_socioeconomicoMedio
##              0.02047              0.31256
## nivel_socioeconomicoAlto      apoyo_familiarMedio
##              -0.18366              0.24422
##              apoyo_familiarAlto      comorbilidades
##              -0.19338              -0.12960
##
## Degrees of Freedom: 894 Total (i.e. Null); 887 Residual

```

```
## Null Deviance:      920.1
## Residual Deviance: 852.4      AIC: 868.4
```

El modelo refinado balanceado con Propensity Scores tiene un mejor ajuste (AIC más bajo) en comparación con el modelo inicial con Propensity Scores. Las variables clave que permanecen significativas son la edad, el estado funcional y las comorbilidades.

Las variables eliminadas son: sexo, nivel_educacion, tabaquismo, y cuidado_dependientes.

```
## Summary del modelo
```

```
##
## Call:
## glm(formula = exposicion ~ edad + estado_funcional + nivel_socioeconomico +
##      apoyo_familiar + comorbilidades, family = binomial, data = datos_replace_comorb)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.705997   0.427835  -1.650 0.098910 .
## edad             0.022353   0.006301   3.548 0.000389 ***
## estado_funcional  0.020473   0.003180   6.438 1.21e-10 ***
## nivel_socioeconomicoMedio 0.312562   0.199006   1.571 0.116272
## nivel_socioeconomicoAlto -0.183658   0.231182  -0.794 0.426944
## apoyo_familiarMedio  0.244221   0.198363   1.231 0.218254
## apoyo_familiarAlto  -0.193381   0.229435  -0.843 0.399309
## comorbilidades    -0.129595   0.058527  -2.214 0.026809 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 920.11  on 894  degrees of freedom
## Residual deviance: 852.36  on 887  degrees of freedom
## AIC: 868.36
##
## Number of Fisher Scoring iterations: 4
```

```
## Odd Ratios
```

```
##              (Intercept)              edad              estado_funcional
##              0.4936163              1.0226046              1.0206843
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto apoyo_familiarMedio
##              1.3669223              0.8322201              1.2766270
##              apoyo_familiarAlto              comorbilidades
##              0.8241682              0.8784508
```

```
## Intervalos de Confianza para los Odds Ratios
```


```
##              2.5 %    97.5 %
## (Intercept)    0.2122114 1.1376333
## edad           1.0101944 1.0354841
## estado_funcional 1.0144240 1.0271642
## nivel_socioeconomicoMedio 0.9235926 2.0173088
```

```
## nivel_socioeconomicoAlto  0.5293033  1.3120848
## apoyo_familiarMedio      0.8637861  1.8819535
## apoyo_familiarAlto      0.5261089  1.2952551
## comorbilidades           0.7833827  0.9857793
```


edad y estado_funcional son consistentemente significativos y positivos en todos los modelos.
comorbilidades es significativo y negativo en el modelo refinado balanceado.

Residuos del modelo


Residuos de Deviance



Distancias de Cook



Curva ROC



```
## Area under the curve: 0.6846
```

AUC igual de buena que el modelo no refinado.

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 895 samples
## 5 predictor
## 2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 806, 805, 805, 806, 806, 805, ...
## Resampling results:
##
## ROC      Sens      Spec
## 0.672776 0.05321637 0.9901408
```

Comparación Modelos con y sin Propensity Scores

```
# Creamos una tabla con la información de ambos modelos
comparacion_modelos_pliegues <- data.frame(Métrica = c("Tamaño de muestra",
  "Número de predictores", "ROC", "Sensibilidad", "Especificidad"),
  Modelo_1_Propensity_Scores = c(895, 5, 0.672776, 0.05321637,
    0.9901408), Modelo_2_Sin_Propensity_Scores = c(1000,
    6, 0.7607771, 0.3790805, 0.9080282))

kable(comparacion_modelos_pliegues)
```

Métrica	Modelo_1_Propensity_Scores	Modelo_2_Sin_Propensity_Scores
Tamaño de muestra	895.0000000	1000.0000000
Número de predictores	5.0000000	6.0000000
ROC	0.6727760	0.7607771
Sensibilidad	0.0532164	0.3790805
Especificidad	0.9901408	0.9080282

Modelo con Propensity Scores:

Ventajas: Alta especificidad, lo que significa que es excelente para identificar correctamente a los no expuestos.

Desventajas: Muy baja sensibilidad, lo que significa que no es efectivo en la identificación de los expuestos.

Modelo sin Propensity Scores:

Ventajas: Mejor capacidad predictiva global (ROC AUC), mayor sensibilidad, lo que significa que es más equilibrado en la identificación de expuestos y no expuestos.

Desventajas: Especificidad un poco más baja en comparación con el modelo con Propensity Scores, pero aún alta.

Ponderación (Weighting)

Se procede a realizar otro balanceo con Propensity Scores, esta vez utilizando el método de Weighting, también conocido como Ponderación.


Cálculo de Pesos Inversos de Probabilidad de Tratamiento (IPW)

```
# Calculamos los pesos
datos_ps$peso_ipw <- ifelse(datos_ps$exposicion == "Sí", 1/datos_ps$propensity_score,
  1/(1 - datos_ps$propensity_score))
summary(datos_ps$peso_ipw)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  1.015   1.151   1.413   1.996   1.960  31.732
```

Los pesos tienen una gran diversidad de rangos como puede observarse también en el histograma. Sin embargo, vamos a continuar analizando los pesos tal y como están, aunque la opción de truncar esta distribución estaría pendiente para futuros trabajos

Distribución de Pesos IPW



Evaluación del Balance de Covariables Posterior a la Ponderación

		Stratified by exposicion		
		No	Sí	SMD
##	n	997.3	998.6	
##	sexo = Masculino (%)	474.9 (47.6)	493.0 (49.4)	0.035


```
##   tabaquismo = Sí (%)           327.8 (32.9)   296.7 (29.7)   0.068
##   nivel_socioeconomico (%)           0.019
##     Bajo           288.2 (28.9)   297.1 (29.7)
##     Medio          493.0 (49.4)   487.5 (48.8)
##     Alto           216.1 (21.7)   214.0 (21.4)
##   estado_funcional (mean (SD))  51.16 (30.36)  50.34 (28.51)  0.028
##   comorbilidades (mean (SD))    2.14 (1.31)   2.03 (1.44)   0.083
##   cuidado_dependientes = Sí (%)  183.3 (18.4)   204.5 (20.5)  0.053
##   apoyo_familiar (%)           0.094
##     Bajo           360.9 (36.2)   320.3 (32.1)
##     Medio          431.8 (43.3)   474.6 (47.5)
##     Alto           204.6 (20.5)   203.8 (20.4)
##   nivel_educacion (%)           0.025
##     Bajo           178.2 (17.9)   184.0 (18.4)
##     Medio          408.1 (40.9)   396.8 (39.7)
##     Alto           411.0 (41.2)   417.8 (41.8)
##   edad (mean (SD))           49.97 (13.39)  50.34 (14.33)  0.027
```

Todas las variables han sido balanceadas correctamente, siendo éste el método que mejor ha balanceado.

Modelo ponderado usando los pesos IPW

```
modelo_ipw <- glm(exposicion ~ sexo + edad + estado_funcional +
  nivel_socioeconomico + nivel_educacion + cuidado_dependientes +
  apoyo_familiar + tabaquismo + comorbilidades, data = datos_ps,
  weights = peso_ipw, family = binomial)
modelo_ipw
```

```
##
## Call:  glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##   nivel_educacion + cuidado_dependientes + apoyo_familiar +
##   tabaquismo + comorbilidades, family = binomial, data = datos_ps,
##   weights = peso_ipw)
##
## Coefficients:
##             (Intercept)              sexoMasculino
##             -0.0803645                0.0700738
##             edad              estado_funcional
##             0.0025800              -0.0003704
## nivel_socioeconomicoMedio nivel_socioeconomicoAlto
##             -0.0183995              -0.0396119
## nivel_educacionMedio      nivel_educacionAlto
##             -0.0768244                0.0098788
## cuidado_dependientesSí      apoyo_familiarMedio
##             0.1258257                0.2151341
## apoyo_familiarAlto          tabaquismoSí
##             0.1049593              -0.1272392
## comorbilidades
##             -0.0585827
##
## Degrees of Freedom: 999 Total (i.e. Null); 987 Residual
```

```
## Null Deviance:      2767
## Residual Deviance: 2754 AIC: 2693
```

```
summary(modelo_ipw)
```

```
##
## Call:
## glm(formula = exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
##      nivel_educacion + cuidado_dependientes + apoyo_familiar +
##      tabaquismo + comorbilidades, family = binomial, data = datos_ps,
##      weights = peso_ipw)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -0.0803645   0.2429836  -0.331   0.7408
## sexoMasculino     0.0700738   0.0901850   0.777   0.4372
## edad             0.0025800   0.0032716   0.789   0.4303
## estado_funcional -0.0003704   0.0015414  -0.240   0.8101
## nivel_socioeconomicoMedio -0.0183995   0.1060445  -0.174   0.8623
## nivel_socioeconomicoAlto -0.0396119   0.1281254  -0.309   0.7572
## nivel_educacionMedio  -0.0768244   0.1281158  -0.600   0.5487
## nivel_educacionAlto   0.0098788   0.1270526   0.078   0.9380
## cuidado_dependientesSí  0.1258257   0.1144299   1.100   0.2715
## apoyo_familiarMedio    0.2151341   0.1029154   2.090   0.0366 *
## apoyo_familiarAlto     0.1049593   0.1268454   0.827   0.4080
## tabaquismoSí         -0.1272392   0.0985617  -1.291   0.1967
## comorbilidades       -0.0585827   0.0331270  -1.768   0.0770 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2766.9  on 999  degrees of freedom
## Residual deviance: 2754.0  on 987  degrees of freedom
## AIC: 2693.3
##
## Number of Fisher Scoring iterations: 5
```


apoyo_familiarMedio: Es la única covariable significativa con un valor $p < 0.05$. La estimación positiva (0.2151) sugiere que tener un apoyo familiar medio aumenta la probabilidad de exposición en comparación con el apoyo familiar bajo.

comorbilidades: Aunque no es estadísticamente significativo al nivel 0.05, está cerca ($p = 0.0770$) y su estimación negativa (-0.0586) sugiere que un mayor número de comorbilidades podría estar asociado con una menor probabilidad de exposición.

Por otro lado, el Residual Deviance sugiere que los predictores no están proporcionando un ajuste mucho mejor que el modelo nulo.


Residuos del modelo

Residuos de Deviance




Distancias de Cook

Distancia de Cook



Curva ROC



Area under the curve: 0.5616

Validación cruzada con 10 pliegues

```
## Generalized Linear Model
##
## 1000 samples
##   9 predictor
##   2 classes: 'No', 'Sí'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 900, 900, 900, 900, 901, 900, ...
## Resampling results:
##
##   ROC          Sens      Spec
## 0.4805103 0.4175862 0.5345473
```

El modelo no discrimina bien entre las clases de exposición. Esto se ve en la sensibilidad que indica que el el modelo identifica correctamente el 41.76% de los casos positivos y en la especificidad que indica que el modelo identifica correctamente el 53.45% de los casos negativos

Apéndice

Código

```
# Establecer opciones globales para todos los chunks
knitr::opts_chunk$set(
  warning = FALSE,
  message = FALSE,
  tidy.opts = list(width.cutoff = 60),
  tidy = TRUE
)

# Maquetación del documento
library(knitr)
# Para maquetación de tablas
library(kableExtra)
# Para resúmenes detallados de datos
library(skimr)
# Manipulación y transformación de datos
library(dplyr)
# Creación de gráficos
library(ggplot2)
# Funciones estadísticas (incluye glm)
library(stats)
# Herramientas para la creación y evaluación de modelos
library(caret)
# Visualización y análisis de curvas ROC
library(pROC)
# Para mapas de calor
library(reshape2)
# Genera gráficos y tablas de equilibrio
library(cobalt)
# Para tablas de datos que nos permitan calcular SMD
library(tableone)
# Para Propensity Scores y Matching
library(MatchIt)
# Para manejo de estadísticas en modelos lineales
library(survey)
datos <- readRDS("C:/Users/navia/Desktop/TFM/Datos Simulados/datos.rds")
# Clase del dataframe
cat("Clase del dataframe\n")
class(datos)

# Primeras y últimas 3 filas
cat("Primeras 3 filas\n")
head(datos, n = 3) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"))

cat("Últimas 3 filas\n")
tail(datos, n = 3) %>%
  kable(format = "latex", booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"))
```

```

# Estructura del dataframe
cat("Estructura del dataframe\n")
str(datos)

# Vemos la estructura de los datos usando el paquete skimr
cat("Resumen general del dataframe\n")
skim(datos)
kable(table(datos$sexo), caption = "Tabla de frecuencias de Sexo")
kable(table(datos$tabaquismo), caption = "Tabla de frecuencias de Tabaquismo")
kable(table(datos$nivel_socioeconomico), caption = "Tabla de frecuencias de Nivel Socioeconómico")
kable(table(datos$comorbilidades), caption = "Tabla de frecuencias de Comorbilidades")
kable(table(datos$cuidado_dependientes), caption = "Tabla de frecuencias de Cuidado de Dependientes")
kable(table(datos$apoyo_familiar), caption = "Tabla de frecuencias de Apoyo Familiar")
kable(table(datos$nivel_educacion), caption = "Tabla de frecuencias de Nivel de Educación")
kable(table(datos$exposicion), caption = "Tabla de frecuencias de Exposición")
kable(table(datos$resultado), caption = "Tabla de frecuencias de Resultado")
# Duplicamos el dataframe
datostransformados = data.frame(datos)

# Convertimos las variables a factores usando el paquete dplyr
datostransformados <- datostransformados %>%
  mutate(
    sexo = factor(sexo, levels = c(0, 1), labels = c("Femenino", "Masculino")),
    tabaquismo = factor(tabaquismo, levels = c(0, 1), labels = c("No", "Sí")),
    nivel_socioeconomico = factor(nivel_socioeconomico, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    cuidado_dependientes = factor(cuidado_dependientes, levels = c(0, 1), labels = c("No", "Sí")),
    apoyo_familiar = factor(apoyo_familiar, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    nivel_educacion = factor(nivel_educacion, levels = c(1, 2, 3), labels = c("Bajo", "Medio", "Alto")),
    exposicion = factor(exposicion, levels = c(0, 1), labels = c("No", "Sí")),
    resultado = factor(resultado, levels = c(0, 1), labels = c("No mejora", "Mejora"))
  )

# Vemos que se hayan convertido
str(datostransformados)
# Creamos una lista que incluya todas las variables numéricas
numericas <- c("estado_funcional", "comorbilidades", "edad",
               "prob_exposicion", "log_odds_Y", "prob_Y")

# Aplicamos el shapiro.test y guardamos en una variable
normalidad <- lapply(datostransformados[numericas], function(x) shapiro.test(x))

# Sacamos los resultados
normalidad_resultados <- sapply(normalidad, function(test) c(statistic = test$statistic, p_value = test$p.value))
cat("Resultados test de Shapiro-Wilk\n")
normalidad_resultados
# Detectamos outliers con el método IQR
outliers <- lapply(datostransformados[numericas], function(x) {
  iqr <- IQR(x, na.rm = TRUE)
  q1 <- quantile(x, 0.25, na.rm = TRUE)
  q3 <- quantile(x, 0.75, na.rm = TRUE)
  limites <- c(inferior = q1 - 1.5 * iqr, superior = q3 + 1.5 * iqr)
  outliers <- which(x < limites["inferior"] | x > limites["superior"])
  return(list(limites = limites, outliers = outliers))
})

```

```

})

# Vemos los resultados
cat("Outliers de estado_funcional\n")
outliers[["estado_funcional"]]
cat("Outliers de edad\n")
outliers[["edad"]]
cat("Outliers de prob_exposicion\n")
outliers[["prob_exposicion"]]
cat("Outliers de log_odds_Y\n")
outliers[["log_odds_Y"]]
cat("Outliers de comorbilidades\n")
outliers[["comorbilidades"]]
cat("Outliers de prob_Y\n")
outliers[["prob_Y"]]
# Creamos una lista que incluya todas las variables categóricas
categoricas <- c("sexo", "tabaquismo", "nivel_socioeconomico",
                 "cuidado_dependientes", "apoyo_familiar", "nivel_educacion")

# Hacemos un bucle for para sacar todos los gráficos
for (variable in categoricas) {
  plot_categoricas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_bar(fill = "slateblue3", color = "black") +
    labs(title = paste("Distribución de", variable), x = variable, y = "Frecuencia") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_categoricas)
}

# Histogramas de densidades
for (variable in numericas) {
  plot_hist_numericas <- ggplot(datostransformados, aes_string(x = variable)) +
    geom_histogram(aes(y = ..density..), bins = 30, fill = "#A88B5", color = "black", alpha = 0.7) +
    geom_density(color = "#441752", size = 1) +
    labs(title = paste("Histograma y densidad de", variable), x = variable, y = "Densidad") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_hist_numericas)
}

# Boxplots
for (variable in numericas) {
  plot_box_numericas <- ggplot(datostransformados, aes_string(y = variable)) +
    geom_boxplot(fill = "#EFB6C8", color = "black", outlier.color = "red", outlier.size = 2) +
    labs(title = paste("Boxplot de", variable), x = "", y = variable) +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_box_numericas)
}

# Creamos boxplots de cada variable continua según 'resultado'
for (variable in numericas) {
  plot_box_con_resultado <- ggplot(datostransformados, aes_string(x = "resultado", y = variable, fill =
    geom_boxplot(outlier.color = "red", outlier.size = 2) +
    labs(title = paste("Boxplot de", variable, "según el resultado"),

```

```

    x = "Resultado", y = variable) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5))
print(plot_box_con_resultado)
}

for (variable in numericas) {
  plot_hist_con_resultado <- ggplot(datostransformados, aes_string(x = variable, fill = "resultado")) +
    geom_density(alpha = 0.5) +
    labs(title = paste("Densidad de", variable, "según el resultado"),
         x = variable, y = "Densidad") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  print(plot_hist_con_resultado)
}

# Seleccionamos solos los datos numéricos y creamos otra tabla
datos_numericos <- datostransformados[numericas]

# Calculamos la matriz de correlación
cor_matrix_numericas <- cor(datos_numericos, use = "complete.obs")

# Mostramos la matriz de correlación
kable(cor_matrix_numericas)

# Visualizamos la matriz de correlación
cor_data <- melt(cor_matrix_numericas)
ggplot(cor_data, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(low = "#FABC3F", high = "#821131", mid = "#E85C0D",
                      midpoint = 0, limit = c(-1, 1), space = "Lab",
                      name = "Correlación") +
  theme_minimal() +
  labs(title = "Matriz de correlación") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
# Gráficos de barras para variables categóricas por exposición
for (variable in categoricas) {
  print(
    ggplot(datostransformados, aes_string(x = variable, fill = "exposicion")) +
    geom_bar(position = "dodge", color = "black") +
    labs(title = paste("Distribución de", variable, "por Exposición"),
         x = variable, y = "Frecuencia") +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
  )
}

# Boxplots para variables numéricas por exposición
for (variable in numericas) {
  print(
    ggplot(datostransformados, aes_string(x = "exposicion", y = variable, fill = "exposicion")) +
    geom_boxplot(outlier.color = "red", outlier.shape = 16) +
    labs(title = paste("Boxplot de", variable, "por Exposición"),

```



```

        x = "Exposición", y = variable) +
        theme_minimal() +
        theme(plot.title = element_text(hjust = 0.5))
    )
}
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
    tabla <- table(datostransformados[[variable]], datostransformados$exposicion)
    prueba_chi <- chisq.test(tabla)
    print(paste("Prueba Chi-cuadrado para", variable))
    print(prueba_chi)
}
# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon Rank-Sum Test)
for (variable in numericas) {
    wilcox_test <- wilcox.test(datostransformados[[variable]] ~ datostransformados$exposicion)
    print(paste("Prueba de Mann-Whitney para", variable))
    print(wilcox_test)
}
modelo_inicial <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + cuidado_dependiente,
                      data = datostransformados,
                      family = binomial)

modelo_inicial
cat("Summary del modelo\n")
summary(modelo_inicial)
cat("Odd Ratios\n")
exp(coef(modelo_inicial))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_inicial))
plot(residuals(modelo_inicial, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_inicial),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datostransformados) - length(coef(modelo_inicial))), col = "red", lty = 2)

roc_curve <- roc(datostransformados$exposicion, fitted(modelo_inicial))
plot(roc_curve, main = "Curva ROC")
auc(roc_curve)
# Aplicamos una regresión stepwise al modelo
modelo_refinado <- step(modelo_inicial, direction = "both")

# Vemos el resultado
modelo_refinado
cat("Summary del modelo\n")
summary(modelo_refinado)
cat("Odd Ratios\n")
exp(coef(modelo_refinado))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_refinado))

```

```

plot(residuals(modelo_refinado, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_refinado),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datostransformados) - length(coef(modelo_refinado))), col = "red", lty = 2)
roc_curve_refinado <- roc(datostransformados$exposicion, fitted(modelo_refinado))
plot(roc_curve_refinado, main = "Curva ROC")
auc(roc_curve_refinado)
# Configuramos la validación cruzada
train_control <- trainControl(
  method = "cv",
  number = 10,
  summaryFunction = twoClassSummary,
  classProbs = TRUE
)

# Entrenamos el modelo
set.seed(19780301)
modelo_cv <- train(
  exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico +
    nivel_educacion + comorbilidades,
  data = datostransformados,
  method = "glm",
  family = "binomial",
  trControl = train_control,
  metric = "ROC"
)

print(modelo_cv)
# Establecemos semilla
set.seed(19780301)

# Copiamos los datos
datos_ps <- data.frame(datostransformados)

# Extraemos los Propensity Scores
datos_ps$propensity_score <- predict(modelo_inicial, type = "response")

# Calculamos la desviación estándar de los PS en caso de que sean necesarias
sd_ps <- sd(datos_ps$distance, na.rm = TRUE)

# Sacamos el summary
summary(datos_ps$propensity_score)
# Definimos las covariables a evaluar
covariables <- c("sexo", "tabaquismo", "nivel_socioeconomico", "estado_funcional",
  "comorbilidades", "cuidado_dependientes", "apoyo_familiar",
  "nivel_educacion", "edad")

```

```

# Creamos la tabla de balance inicial para ver las diferencias de medias estandarizadas (SMD)
tabla_balance <- CreateTableOne(vars = covariables,
                                strata = "exposicion",
                                data = datos_ps,
                                test = FALSE)

# Mostramos los resultados
print("Tabla de Balance con los resultados de SMD")
print(tabla_balance, smd = TRUE)
# Establecemos la semilla
set.seed(19780301)

# Sacamos la formula del balance
formula_balance <- exposicion ~ sexo + tabaquismo + nivel_socioeconomico + estado_funcional + comorbili

# Utilizamos la formula para sacar los datos que nos permitan hacer el Love Plot
bal_tab <- bal.tab(formula_balance, data = datos_ps)

# Creamos el Love Plot para el balance inicial
love.plot(bal_tab,
           threshold = 0.1,
           var.order = "unadjusted",
           stat = "mean.diffs",
           abs = TRUE,
           colors = c("red", "blue"),
           stars = "raw")

# Establecemos la semilla
set.seed(19780301)

# Aplicamos el matching utilizando solo las 3 variables más desbalanceadas
matching_replace <- matchit(
  formula = exposicion ~ sexo + edad + estado_funcional,
  data = datos_ps,
  method = "nearest",
  distance = "logit",
  replace = TRUE
)

# Mostramos los resultados
summary(matching_replace)
# Extraemos los datos
datos_replace <- match.data(matching_replace)

# Creamos la tabla de balance
tabla_balance_replace <- CreateTableOne(
  vars = covariables,
  strata = "exposicion",
  data = datos_replace,
  test = FALSE
)

# Mostramos el balance
print(tabla_balance_replace, smd = TRUE)

```



```

        stat = "mean.diffs",
        abs = TRUE,
        colors = c("red", "blue"),
        stars = "raw")
# Visualizamos el Love Plot después del emparejamiento con comorbilidades
love.plot(bal.tab(matching_replace_comorb),
          threshold = 0.1,
          var.order = "unadjusted",
          stat = "mean.diffs",
          abs = TRUE,
          colors = c("red", "blue"),
          stars = "raw")
str(datos_replace_comorb)
# Para categóricas: Chi-cuadrado
for (variable in categoricas) {
  tabla_balanceado <- table(datos_replace_comorb[[variable]], datos_replace_comorb$exposicion)
  prueba_chi_balanceado <- chisq.test(tabla_balanceado)
  print(paste("Prueba Chi-cuadrado para", variable))
  print(prueba_chi_balanceado)
}

# Para numericas: Pruebas de Mann-Whitney U (Wilcoxon Rank-Sum Test)
for (variable in numericas) {
  wilcox_test_balanceado <- wilcox.test(datos_replace_comorb[[variable]] ~ datos_replace_comorb$exposicion)

  print(paste("Prueba de Mann-Whitney para", variable))
  print(wilcox_test_balanceado)
}

modelo_balanceado_matching <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + 1,
  data = datos_replace_comorb,
  family = binomial)
modelo_balanceado_matching
cat("Summary del modelo\n")
summary(modelo_balanceado_matching)
cat("Odd Ratios\n")
exp(coef(modelo_balanceado_matching))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_balanceado_matching))
plot(residuals(modelo_balanceado_matching, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)

plot(cooks.distance(modelo_balanceado_matching),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datos_replace_comorb) - length(coef(modelo_balanceado_matching))), col = "red", lty = 2)

roc_curve_balanceado <- roc(datos_replace_comorb$exposicion, fitted(modelo_balanceado_matching))
plot(roc_curve_balanceado, main = "Curva ROC")

```

```

auc(roc_curve_balanceado)
modelo_refinado_balanceado <- step(modelo_balanceado_matching, direction = "both")
modelo_refinado_balanceado
cat("Summary del modelo\n")
summary(modelo_refinado_balanceado)
cat("Odd Ratios\n")
exp(coef(modelo_refinado_balanceado))
cat("Intervalos de Confianza para los Odds Ratios\n")
exp(confint(modelo_refinado_balanceado))
plot(residuals(modelo_refinado_balanceado, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_refinado_balanceado),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datos_replace_comorb) - length(coef(modelo_refinado_balanceado))), col = "red", lty = 2)

roc_curve_refinado_balanceado <- roc(datos_replace_comorb$exposicion, fitted(modelo_refinado_balanceado))
plot(roc_curve_refinado_balanceado, main = "Curva ROC")
auc(roc_curve_refinado_balanceado)
# Entrenamos el modelo
set.seed(19780301)
modelo_cv_balanceado_refinado <- train(
  exposicion ~ edad + estado_funcional + nivel_socioeconomico +
    apoyo_familiar + comorbilidades,
  data = datos_replace_comorb,
  method = "glm",
  family = "binomial",
  trControl = train_control,
  metric = "ROC"
)

print(modelo_cv_balanceado_refinado)
# Creamos una tabla con la información de ambos modelos
comparacion_modelos_pliegues <- data.frame(
  Métrica = c("Tamaño de muestra", "Número de predictores", "ROC", "Sensibilidad", "Especificidad"),
  Modelo_1_Propensity_Scores = c(895, 5, 0.672776, 0.05321637, 0.9901408),
  Modelo_2_Sin_Propensity_Scores = c(1000, 6, 0.7607771, 0.3790805, 0.9080282)
)

kable(comparacion_modelos_pliegues)
# Calculamos los pesos
datos_ps$peso_ipw <- ifelse(datos_ps$exposicion == "Sí",
                           1 / datos_ps$propensity_score,
                           1 / (1 - datos_ps$propensity_score))
summary(datos_ps$peso_ipw)
# Histograma de Distribución de Pesos IPW
hist(datos_ps$peso_ipw, breaks = 50,
     main = "Distribución de Pesos IPW",
     xlab = "Peso IPW",

```

```

col = "skyblue", # Color de las barras
border = "darkblue", # Color del borde de las barras
ylim = c(0, max(hist(datos_ps$peso_ipw, plot = FALSE)$counts) * 1.1)) # Ajuste del eje Y
abline(v = mean(datos_ps$peso_ipw), col = "purple", lwd = 2, lty = 2)
legend("topright", legend = c("Densidad", "Media"),
      col = c("red", "purple"), lwd = 2, lty = c(1, 2))
# Utilizamos Survey para generar un diseño con los pesos que nos permita generar la Tabla One
design_ipw <- svydesign(ids = ~1, data = datos_ps, weights = ~peso_ipw)

# Creamos la tabla
table_balance_ipw <- svyCreateTableOne(vars = covariables,
                                       strata = "exposicion",
                                       data = design_ipw,
                                       test = FALSE)

# Mostramos los resultados
print(table_balance_ipw, smd = TRUE)
modelo_ipw <- glm(exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + nivel_educacion +
                 data = datos_ps,
                 weights = peso_ipw,
                 family = binomial)

modelo_ipw
summary(modelo_ipw)
plot(residuals(modelo_ipw, type = "deviance"),
     main = "Residuos de Deviance",
     ylab = "Residuos de Deviance",
     xlab = "Índice de observación")
abline(h = 0, col = "red", lty = 2)
plot(cooks.distance(modelo_ipw),
     main = "Distancia de Cook",
     ylab = "Distancia de Cook",
     xlab = "Índice de observación")
abline(h = 4/(nrow(datos_ps) - length(coef(modelo_ipw))), col = "red", lty = 2)
roc_curve_ponderado <- roc(datos_ps$exposicion, fitted(modelo_ipw))
plot(roc_curve_ponderado, main = "Curva ROC")
auc(roc_curve_ponderado)
# Definimos una función personalizada para entrenar el modelo con pesos
train_weighted_glm <- function(data, formula, weights) {
  glm(formula, data = data, family = "binomial", weights = weights)
}

# Usamos el modelo ponderado con validación cruzada
set.seed(19780301)
modelo_cv_ponderado <- train(
  exposicion ~ sexo + edad + estado_funcional + nivel_socioeconomico + nivel_educacion +
    cuidado_dependientes + apoyo_familiar + tabaquismo + comorbilidades,
  data = datos_ps,
  method = "glm",
  family = "binomial",
  weights = datos_ps$peso_ipw,
  trControl = train_control,
  metric = "ROC"
)

```

```
print(modelo_cv_ponderado)
```


A.4. Repositorio GitHub con los archivos del TFM

Este repositorio incluye todos los archivos relacionados con el Trabajo de Fin de Master. Entre estos archivos se encuentran:

- La Memoria Final del Trabajo
- El archivo que reúne toda la información de los Datos Simulados en formato .html y .pdf
- El archivo que reúne toda la información del Análisis de Datos en formato .html y .pdf
- La presentación de Power Point

Enlace al repositorio de GitHub: <https://github.com/RhysMoonbeam/TFM-MARTINEZ-REQUENA-ADRIAN>

Bibliografía

1. Williamson E, Morley R, Lucas A y Carpenter J. Propensity scores: From naïve enthusiasm to intuitive understanding. *Statistical Methods in Medical Research*. 2012 Jun; 21:273-93. DOI: 10.1177/0962280210394483
2. Glynn RJ, Schneeweiss S y Stürmer T. Indications for Propensity Scores and Review of their Use in Pharmacoepidemiology. *Basic & Clinical Pharmacology & Toxicology*. 2006 Mar; 98:253-9. DOI: 10.1111/j.1742-7843.2006.pto_293.x
3. Li M. Using the Propensity Score Method to Estimate Causal Effects: A Review and Practical Guide. *Organizational Research Methods*. 2013 Apr; 16:188-226. DOI: 10.1177/1094428112447816
4. quantzig. Benefits of Clinical Trial Propensity Score Matching Analytics. quantzig. 2024 Jul 9. [Accessed on: 2024 Nov 3]
5. Ortona E, Delunardo F, Baggio G y Malorni W. A sex and gender perspective in medicine: a new mandatory challenge for human health. *Annali dell'Istituto superiore di sanita*. 2016; 52:146-8
6. Xhyheri B y Bugiardini R. Diagnosis and treatment of heart disease: are women different from men? *Progress in cardiovascular diseases*. 2010; 53:227-36
7. Zhao QY, Luo JC, Su Y, Zhang YJ, Tu GW y Luo Z. Propensity score matching with R: conventional methods and new features. *Annals of translational medicine*. 2021; 9
8. Olmos A y Govindasamy P. A practical guide for using propensity score weighting in R. *Practical assessment, research, and evaluation*. 2019; 20:13
9. Haya P. La metodología CRISP-DM en ciencia de datos - IIC. Instituto de Ingeniería del Conocimiento. 2021 Nov 29. [Accessed on: 2024 Nov 3]
10. Rosenbaum PR. Observational study. *Encyclopedia of statistics in behavioral science*. 2005; 3:1451-62
11. Ramji S. Study Design: Observational Studies. *Indian Pediatrics*. 2022 Jun 1; 59:493-8. DOI: 10.1007/s13312-022-2541-2
12. Manterola C y Otzen T. Los Sesgos en Investigación Clínica. *International Journal of Morphology*. 2015 Sep; 33:1156-64. DOI: 10.4067/S0717-95022015000300056
13. Hilton Boon M, Burns J, Craig P, Griebler U, Heise TL, Vittal Katikireddi S, Rehfuess E, Shepperd S, Thomson H y Bero L. Value and Challenges of Using Observational Studies in Systematic Reviews of Public Health Interventions. *American Journal of Public Health*. 2022 Apr; 112:548-52. DOI: 10.2105/AJPH.2021.306658

14. ROSENBAUM PR y RUBIN DB. The central role of the propensity score in observational studies for causal effects. *Biometrika*. 1983 Apr 1; 70:41-55. DOI: 10.1093/biomet/70.1.41
15. Austin PC. An Introduction to Propensity Score Methods for Reducing the Effects of Confounding in Observational Studies. *Multivariate Behavioral Research*. 2011 May 31; 46:399-424. DOI: 10.1080/00273171.2011.568786
16. Rubin DB. For objective causal inference, design trumps analysis. 2008
17. Benedetto U, Head SJ, Angelini GD y Blackstone EH. Statistical primer: propensity score matching and its alternatives†. *European Journal of Cardio-Thoracic Surgery*. 2018 Jun 1; 53:1112-7. DOI: 10.1093/ejcts/ezy167
18. Stuart EA. Matching methods for causal inference: A review and a look forward. *Statistical science: a review journal of the Institute of Mathematical Statistics*. 2010; 25:1
19. Li L y Greene T. A Weighting Analogue to Pair Matching in Propensity Score Analysis. *The International Journal of Biostatistics*. 2013 Jan 1; 9. DOI: 10.1515/ijb-2012-0030
20. Brown DW, Greene TJ, Swartz MD, Wilkinson AV y DeSantis SM. Propensity score stratification methods for continuous treatments. *Statistics in Medicine*. 2021 Feb 28; 40:1189-203. DOI: 10.1002/sim.8835
21. Rosenbaum PR y Rubin DB. Propensity scores in the design of observational studies for causal effects. *Biometrika*. 2023 Mar 1; 110:1-13. DOI: 10.1093/biomet/asac054
22. Shah BR, Laupacis A, Hux JE y Austin PC. Propensity score methods gave similar results to traditional regression modeling in observational studies: a systematic review. *Journal of Clinical Epidemiology*. 2005 Jun 1; 58:550-9. DOI: 10.1016/j.jclinepi.2004.10.016
23. Amoah J, Stuart EA, Cosgrove SE, Harris AD, Han JH, Lautenbach E, Tamma PD y for the Antibacterial Resistance Leadership Group. Comparing Propensity Score Methods Versus Traditional Regression Analysis for the Evaluation of Observational Data: A Case Study Evaluating the Treatment of Gram-Negative Bloodstream Infections. *Clinical Infectious Diseases*. 2020 Nov 1; 71:e497-e505. DOI: 10.1093/cid/ciaa169
24. Hurwitz KE, Rathnayaka N, Hendrickson K y Brookhart MA. Propensity score methods for confounding control in observational studies of therapeutics for COVID-19 infection. *Clinical Infectious Diseases*. 2024 Oct 16 :ciae516. DOI: 10.1093/cid/ciae516
25. Nation ML, Moss R, Spittal MJ, Kotsimbos T, Kelly PM, Cheng AC y for the Influenza Complications Alert Network (FluCAN) Investigators. Influenza Vaccine Effectiveness Against Influenza-Related Mortality in Australian Hospitalized Patients: A Propensity Score Analysis. *Clinical Infectious Diseases*. 2021 Jan 1; 72:99-107. DOI: 10.1093/cid/ciz1238
26. Sabashnikov A, Heinen S, Deppe AC, Zeriouh M, Weymann A, Slottosch I, Eghbalzadeh K, Popov AF, Liakopoulos O, Rahmanian PB, Madershahian N, Kroener A, Choi YH, Kuhn-Régnier F, Simon AR, Wahlers T y Wippermann J. Impact of gender on long-term outcomes after surgical repair for acute Stanford A aortic dissection: a propensity score matched analysis†. *Interactive CardioVascular and Thoracic Surgery*. 2017 May 1; 24:702-7. DOI: 10.1093/icvts/ivw426

27. Tomassini F, Cerrato E, Rolfo C, Bianco M, Lo Savio L, Quirós Carretero A, Echevarria Pinto M, Giolitto S, Tizzani E, Corleto A, Quadri G, Tripodi R, Minniti D y Varbella F. Gender-related differences among patients with STEMI: a propensity score analysis. REC: interventional cardiology (English Edition). 2021 Jan; 2:15-21. DOI: 10.24875/RECICE.M19000061
28. Ferri-García R y Rueda MdM. Propensity score adjustment using machine learning classification algorithms to control selection bias in online surveys. PLOS ONE. 2020 Apr 22; 15:e0231500. DOI: 10.1371/journal.pone.0231500
29. Bishop CD, Leite WL y Snyder PA. Using Propensity Score Weighting to Reduce Selection Bias in Large-Scale Data Sets. Journal of Early Intervention. 2018 Dec 1; 40:347-62. DOI: 10.1177/1053815118793430
30. Chang TH y Stuart EA. Propensity score methods for observational studies with clustered data: A review. Statistics in Medicine. 2022 Aug 15; 41:3612-26. DOI: 10.1002/sim.9437
31. Groenwold RHH, Donders ART, Roes KCB, Harrell Jr FE y Moons KGM. Dealing With Missing Outcome Data in Randomized Trials and Observational Studies. American Journal of Epidemiology. 2012 Feb 1; 175:210-7. DOI: 10.1093/aje/kwr302
32. Ryan PB y Schuemie MJ. Evaluating Performance of Risk Identification Methods Through a Large-Scale Simulation of Observational Data. Drug Safety. 2013 Oct 1; 36:171-80. DOI: 10.1007/s40264-013-0110-2
33. Tian Y, Schuemie MJ y Suchard MA. Evaluating large-scale propensity score performance through real-world and synthetic data experiments. International Journal of Epidemiology. 2018 Dec 1; 47:2005-14. DOI: 10.1093/ije/dyy120
34. Setoguchi S, Schneeweiss S, Brookhart MA, Glynn RJ y Cook EF. Evaluating uses of data mining techniques in propensity score estimation: a simulation study. Pharmacoepidemiology and Drug Safety. 2008; 17:546-55. DOI: 10.1002/pds.1555
35. Wilkinson JD, Mamas MA y Kontopantelis E. Logistic regression frequently outperformed propensity score methods, especially for large datasets: a simulation study. Journal of Clinical Epidemiology. 2022 Dec 1; 152:176-84. DOI: 10.1016/j.jclinepi.2022.09.009
36. Perez CC. Invisible women: Data bias in a world designed for men. Abrams, 2019
37. Chapman KR, Tashkin DP y Pye DJ. Gender Bias in the Diagnosis of COPD. Chest. 2001 Jun 1; 119:1691-5. DOI: 10.1378/chest.119.6.1691
38. Kent JA, Patel V y Varela NA. Gender Disparities in Health Care. Mount Sinai Journal of Medicine: A Journal of Translational and Personalized Medicine. 2012; 79:555-9. DOI: 10.1002/msj.21336
39. Udoetuk S, Dongarwar D y Salihu HM. Racial and Gender Disparities in Diagnosis of Malingering in Clinical Settings. Journal of Racial and Ethnic Health Disparities. 2020 Dec 1; 7:1117-23. DOI: 10.1007/s40615-020-00734-6
40. Rosenbaum PR y Rubin DB. Reducing Bias in Observational Studies Using Subclassification on the Propensity Score. Journal of the American Statistical Association. 1984 Sep 1; 79:516-24. DOI: 10.1080/01621459.1984.10478078

41. Guo S, Fraser M y Chen Q. Propensity Score Analysis: Recent Debate and Discussion. *Journal of the Society for Social Work and Research*. 2020 Sep; 11:463-82. DOI: 10.1086/711393
42. Hill BM y Shaw A. The Wikipedia Gender Gap Revisited: Characterizing Survey Response Bias with Propensity Score Estimation. *PLOS ONE*. 2013 Jun 26; 8:e65782. DOI: 10.1371/journal.pone.0065782
43. Organization WH. WHO global report on trends in prevalence of tobacco use 2000-2025. World Health Organization, 2020 Feb 17. 121 págs.
44. Lavigne M, Rocher I, Steensma C y Brassard P. The impact of smoking on adherence to treatment for latent tuberculosis infection. *BMC Public Health*. 2006 Mar 14; 6:66. DOI: 10.1186/1471-2458-6-66
45. Sherman BW y Lynch WD. The association of smoking with medical treatment adherence in the workforce of a large employer. *Patient Preference and Adherence*. 2014 Apr 16; 8:477-86. DOI: 10.2147/PPA.S60927
46. Mejía-Lancheros C, Estruch R, Martínez-González MA, Salas-Salvadó J, Corella D, Gómez-Gracia E, Fiol M, Lapetra J, Covas MI y Arós F. Nivel socioeconómico y desigualdades de salud en la prevención cardiovascular de la población española de edad avanzada. *Revista Española de cardiología*. 2013; 66:803-11
47. Carreón AAT, Torres OG y Villaseñor ASÁ. Relación entre nivel socioeconómico y el apego al tratamiento farmacológico en pacientes con diabetes mellitus tipo 2. *Medicina general*. 2020; 9:4
48. Uchmanowicz B, Chudiak A, Uchmanowicz I, Rosińczuk J y Froelicher ES. Factors influencing adherence to treatment in older adults with hypertension. *Clinical Interventions in Aging*. 2018 Nov; Volume 13:2425-41. DOI: 10.2147/CIA.S182881
49. e eurostat eurostat. Educational attainment statistics. eurostat. 2025 May
50. Miller TA. Health literacy and adherence to medical treatment in chronic and acute illness: a meta-analysis. *Patient education and counseling*. 2016; 99:1079-86
51. Austin PC, Yu AXY, Vyas MV y Kapral MK. Applying Propensity Score Methods in Clinical Research in Neurology. *Neurology*. 2021 Nov 2; 97:856-63. DOI: 10.1212/WNL.0000000000012777
52. D'Agostino RB. Propensity Scores in Cardiovascular Research. *Circulation*. 2007 May; 115:2340-3. DOI: 10.1161/CIRCULATIONAHA.105.594952
53. Kane LT, Fang T, Galetta MS, Goyal DKC, Nicholson KJ, Kepler CK, Vaccaro AR y Schroeder GD. Propensity Score Matching: A Statistical Method. *Clinical Spine Surgery*. 2020 Apr; 33:120. DOI: 10.1097/BSD.0000000000000932
54. Chen JW, Maldonado DR, Kowalski BL, Miecznikowski KB, Kyin C, Gornbein JA y Domb BG. Best Practice Guidelines for Propensity Score Methods in Medical Research: Consideration on Theory, Implementation, and Reporting. A Review. *Arthroscopy: The Journal of Arthroscopic & Related Surgery*. 2022 Feb 1; 38:632-42. DOI: 10.1016/j.arthro.2021.06.037

55. Sinnappah KA, Hughes DA, Stocker SL, Vrijens B, Aronson JK y Wright DFB. A framework for understanding sources of bias in medication adherence research. *British Journal of Clinical Pharmacology*. 2023; 89:3444-53. DOI: 10.1111/bcp.15863
56. Vyas S y Heise L. Using Propensity Score Matching to Estimate an “Unbiased Effect-Size” Between Women’s Employment and Partner Violence in Tanzania. *Journal of Interpersonal Violence*. 2014 Nov 1; 29:2971-90. DOI: 10.1177/0886260514527823
57. Li F, Morgan KL y Zaslavsky AM. Balancing Covariates via Propensity Score Weighting. *Journal of the American Statistical Association*. 2018 Jan 2; 113:390-400. DOI: 10.1080/01621459.2016.1260466
58. Lee WS. Propensity score matching and variations on the balancing test. *Empirical Economics*. 2013 Feb 1; 44:47-80. DOI: 10.1007/s00181-011-0481-0
59. Greifer N. Genetic Matching, from the Ground Up. Noah Greifer. 2022 Oct 8. [Accessed on: 2024 Dec 13]
60. Hasanah S, Otok BW y Purhadi. Propensity Score Matching Using Support Vector Machine in Case of Type 2 Diabetes Mellitus (DM). *2018 2nd International Conference on Biomedical Engineering (IBIOMED)*. 2018 2nd International Conference on Biomedical Engineering (IBIOMED). 2018 Jul :132-7. DOI: 10.1109/IBIOMED.2018.8534909